

AI 数据分析 Agent 自主交付评测报告

NYC311 数据分析任务 两轮自主交付评测

摘要

项目 1 完成了一次纽约市 311 非紧急市政服务请求（NYC311）数据分析。本项目沿用这批数据，把选题、计算、制表和说明交给能够调用工具执行任务的 AI 系统，文中称为 AI Agent。检查从提交的文件开始，逐步核对数字和解释，再按说明重做结果，观察最多两轮机会内能交付到什么程度。

本报告用“自主交付总分”概括检查结果，表中简记为 S，满分 100。八个系统中，六个两轮都有可评分成果，平均总分由 71.67 升至 81.13，增加 9.46 分。GPT 第二轮得 98.5 分，达到第 1.2 节列出的参照要求；Claude 接管前工作得 72 分，Kimi 两轮未形成可评分成品。

进一步核查结论时，Qwen 的描述结构和时间窗口、Gemini 的地址统计和文本解释都出现了会影响主要结论的错误。Grok、DeepSeek 和 GLM 留下了一些可用的调查结果，但说明、终稿数字或专题定义还有缺口。各项得分及这些问题的来由在后文逐一展开。

费用也纳入比较。“目录价”按公布的模型单价和记录用量估算；“订阅额度计价”指平台按用量折算的额度消耗。GPT 第二轮目录价约 38.96 元；GLM 更快、价格较低，但热点定义要修。Claude 由 Grok 接续后，订阅额度计价合计约 165.69 元。它们均不能直接视为额外支付的现金，详见第 13 节。

研究问题

1. 有限两轮中，哪些系统独立完成可用交付？
2. 六个评分维度的差异，对应哪些具体分析与错误？
3. 人能否依据提交材料复现主要结果、更新数据并定位错误？
4. 第二轮实际改善了什么，哪些问题仍然存在？
5. 合并质量、时间、费用和人工接管后，本次如何选择？

1 评测设计

1.1 任务与样本

本次输入是 25 个 Parquet 格式的数据文件，共 7,525,498 条 NYC311 请求记录、44 个字段，也就是 44 列信息。一条记录表示一次服务请求，同一事件可能产生多次请求。八个系统使用同一批数据，自主选择问题，提交 Excel 和分析说明。评测检查这些文件能否供人阅读、核对和继续维护。

各系统最多运行两轮。第一轮使用基础任务提示，第二轮增加方法提示，Grok 和 Gemini 另有检查清单。两轮分别保留提交文件和运行记录，再比较完成的工作。每种条件只运行一次，提示、系统自身调整和运行环境都有可能影响结果。

运行结束后，GPT、Grok、DeepSeek、GLM、Qwen 和 Gemini 两轮都有可评分工作，后文用这六个系统比较两轮变化。Claude 第一轮后段由 Grok 接续，第二轮未运行，单独说明；Kimi 第一轮退出、第二轮失败，保留过程和已有费用记录，分数留空。

1.2 评分与核验

收到文件后，先核对问题、取数范围、计算和结论，再尝试按说明重做结果。“复现”指用保留的输入重做主要结果；“维护”还包括更新数据、找到出错位置并修改相关图表和文字。检查允许配置路径、安装所需软件及分步执行，由 AI 辅助审读和操作，未观察真人实际操作。

总分 S 由 25 个细项相加，满分 100，分为六组，A—F 是组别编号。A 数据基础与问题定义 15 分，看是否理解数据、选题能否回答；B 证据与计算正确性 20 分，看数字、比较和解释是否成立；C 调查深度与判断 20 分，看是否继续追查差异、检查其他解释；D 人工复现与维护 25 分，看能否读懂、重做和更新；E 成品实际可用性 10 分，看文件是否清楚、便于使用；F 自主性与资源纪律 10 分，看是否需要催促、接管和返工，以及如何处理失败、使用资源。

每项按完成程度给满分的 100%、75%、50%、25% 或 0：依次为完整满足、主要满足但有局部缺口、部分关键要求完成、仅有有限可用成果、已查明未完成或关键内容不可用。例如，满分 4 分的一项，主要满足得 3 分。得分相加后不再另设上限；缺少评分材料时保留空白，0 分表示已有材料支持该项为 0。

与项目 1 比较时，本项目约定总分至少 90 分，人工维护至少 22/25 分，成品至少 8/10 分，自主性至少 8/10 分；D5“原 AI 的成品检查”须得满分 3 分，即原运行已检查最终文件的数字、显示和必要交互，发现问题后重查。核心结论还须没有已确认而未处理的错误。这些是本项目的评审条件；评测方后来补做的工作不计入原成果。

1.3 模型与运行条件

参评模型、思考强度与 Harness				
AI	第一轮模型	第二轮模型	思考强度	Harness (执行环境)
GPT	gpt-6-astra	gpt-6-astra	中 (medium)	Codex
Grok	grok-4.6	grok-4.6	中 (medium)	Cursor
DeepSeek	deepseek-v4.1-flash	deepseek-v4.1-flash	high	Claude Code
GLM	glm-5.3	glm-5.3	high	Claude Code / Brain Router
Qwen	qwen3.8-max-0902	qwen3.8-max-0902	high	Claude Code
Gemini	gemini-3.8-flash	gemini-3.8-flash	中 (medium)	Antigravity
Claude	Claude Opus 5 → Grok	无独立运行	Claude medium; Grok high-fast	Cursor
Kimi	kimi-k3	kimi-k3	high	Claude Code
运行说明				
思考强度	参赛原运行：海外模型为中，国内模型为Claude Code的high；Grok接续阶段为high-fast。			
执行环境	Harness指模型使用的执行环境；GLM经Brain Router路由。同名强度设置不代表跨平台相同思考预算。			
版本与缺失	Gemini两轮为gemini-3.8-flash；Kimi两轮为kimi-k3；Claude第二轮未运行。			

表 1 模型、思考强度与 Harness。来源：Excel“字段说明”H2:L10。

数据整理、评审计算和报告编制使用了 AI 辅助。为便于回查，下文分别说明系统原来提交了什么，以及评测时又核对或重做了什么。

表中的 Harness 是模型使用工具、读写文件和执行任务的软件环境，如 Codex、Cursor、Claude Code。模型名称说明由谁生成回答，Harness 说明通过什么环境完成任务。medium、high、high-fast 是各环境的思考强度设置，同名档位不保证实际投入相同。Gemini 两轮模型已核实为 gemini-3.8-flash，Kimi 两轮均为 kimi-k3。

Claude 第一轮在 Grok 接续前已留下调查和交付文件。评分据此得到 72 分；Grok 后来订正的数字及重建结果另行记录，具体过程见第 8 节。

Kimi 两轮都没有留下必交成品，无法按 25 项核出完整分数。第 9 节说明退出和重复读取的过程；第二轮已发生的约 2.65 分钟和 1.48 元也保留在比较中。

2 GPT

第一轮的工作

GPT 先核对 25 个数据文件、文件哈希（用于识别文件内容是否变化的校验值）、主键（每条记录的唯一编号）和日期，发现文件名截止日期晚于最后一条记录。它用两年各 1—8 月作比较，按类别和行政区拆解 287,342 条净增量（后期总量减前期总量），重点分析街道、雪冰、供暖及布鲁克林和皇后区。第一轮主要说明增长来自哪里，对异常日期和地址追查较少。关闭时长指创建至关闭的记录时间差，其业务含义及类别改名的影响尚未确定，未据此判断效率或需求变化。

第二轮的工作

第二轮继续查雪冰增长：最高 5 天有 32,819 条请求，占同期 55,230 条的 59.42%。GPT 排除这 5 天，又单独排除雪冰中的 Snow Tracking 子类，检查增长是否集中在这些记录。渠道比较则使用固定的月份、类别和机构权重，减少构成变化的影响；ONLINE（在线渠道）份额仍由 42.5592% 升至 49.3007%，相差 6.7415 个百分点，即两个百分比直接相减。交付遇到 Excel 兼容问题后，它调整生成方式，重新检查公式、图表来源和页面。

GPT · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	14	15	1
证据计算	20	20	20	0
调查判断	20	14.25	20	5.75
人工维护	25	19.75	23.5	3.75
成品可用	10	10	10	0
自主资源	10	10	10	0
现行 S 合计	100	88	98.5	10.5

表 2 GPT 两轮现行 S 六维得分

2.1 GPT 评分依据

数据基础与问题定义（/15） 14→15。核对 44 个字段、记录粒度与同月窗口，第二轮将问题收至峰日和渠道构成。

证据与计算正确性（/20） 20→20。峰日排除、类别排除和固定构成的渠道结果均可回查，两轮得满分。

调查深度与判断（/20） 14.25→20。第一轮主要是增量贡献概览；第二轮补做排除检验与替代解释，达到 20 分。

人工复现与维护（/25） 19.75→23.5。留下 SQL 查询语句、CSV 格式的数据表及六步运行顺序；摘要中的静态数字不会随数据自动更新，维护时仍须逐处核对。

成品实际可用性（/10） 10→10。两轮 Excel 和说明齐全，第二轮有打开、公式及图表检查记录。

自主性与资源纪律

自主性与资源纪律两轮均为 10/10，运行中独立完成了任务。第一轮还缺少进一步调查和维护说明；第二轮已补查主要结果与文件显示。更新数据时仍要逐处核对静态摘要，因此更新与错误定位 D4 为 4.5/6。

第二轮补查了峰日和渠道构成，主要文件与结果也经过检查。如果这次任务优先考虑完整交付和较少返工，可优先选用。两轮目录价约 63.91 元，高于 Grok、DeepSeek、GLM、Qwen、Gemini 的费用参考值，低于 Claude 含接续的 165.69 元。GPT 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

3 Grok

第一轮的工作

Grok 选取两个各 11 个月的完整比较期，将 346,695 条净增量拆到供暖、雪冰、违停、道路、堵塞车道及其余类别，各项相加与全市增量一致。随后追查雪冰峰日、Street Condition（道路状况）的细分类别和机构关闭时长。它说明了残缺月份、分类变化及近期请求尚未关闭的影响，也没有把系统中的关闭状态直接解释成现实问题已解决。

第二轮的工作

第二轮检查积雪高量日、UNKNOWN（渠道未明确）中的坑洞、供暖集中地块和关闭时长。地块用 BBL 标识，这是税务地块编号，一个地块未必等于一栋建筑。剔除固定的前 10 个地块（Top10）后，供暖请求仍由 263,359 条增至 321,188 条，增长 21.96%。Grok 读回中间表并运行 qa_verify 检查脚本。评测时重建文件，205 行数据一致；Excel 文件包的 42 个内部部件中，40 个内容完全一致。

Grok · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	15	13	-2
证据计算	20	19	19	0
调查判断	20	15.75	19.25	3.5
人工维护	25	17	17	0
成品可用	10	8.5	7.75	-0.75
自主资源	10	9.25	9.25	0
现行 S 合计	100	84.5	85.25	0.75

表 3 Grok 两轮现行 S 六维得分

3.1 Grok 评分依据

数据基础与问题定义（/15） 15→13。第一轮对齐完整月份；第二轮把 BBL 地块称为建筑，定义出现偏差。

证据与计算正确性（/20） 19→19。互斥增量可以对账；未来关闭时间和类别含义仍需限定。

调查深度与判断（/20） 15.75→19.25。追查雪天、坑洞和供暖集中度，并剔除固定 Top10 地块再比较。

人工复现与维护（/25） 17→17。脚本能够构建文件，但其中一处文件存在检查会始终通过，无法发现文件缺失；维护步骤和检查说明也未补齐。

成品实际可用性（/10） 8.5→7.75。交付文件齐全；第二轮无效断言和终稿表述拉低成品分。

自主性与资源纪律

自主性与资源纪律两轮均为 9.25/10，第二轮用时约 11.71 分钟。本轮补充了调查，调查分由 15.75 升至 19.25；维护说明和最终检查仍有缺口，人工维护维持 17/25。接手时需要补查那处无效的文件检查及更新步骤。

供暖集中度等调查可供参考，接手后要补维护说明、有效检查和部分表述。第二轮 11.71 分钟，比 GPT 快；订阅内用量计价约 9.86 元，两轮合计 16.34 元。Grok 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

4 DeepSeek

第一轮的工作

DeepSeek 围绕总量变化分析冬季关闭时长、雪冰与坑洞、异常地址、机构差异、渠道和类别名称。固定机构与类型构成后，冬季时长倍数由 3.8667 降到 1.1537；它又排除异常地址重新比较。回查成品时发现，供暖与街道噪音合计混入了住宅噪音，1,533,142 条应为 1,000,893 条；异常地址计数也有错误。部分天气和机构流程解释尚未找到支持材料。

第二轮的工作

第二轮检查字段、时间边界、状态、负时长（关闭早于创建）、缺失值及近期未关闭记录，再拆解机构与类别增量。发现 ZIP 10466（邮政编码）和单地址集中后，DeepSeek 继续查其他类别，并比较每批请求创建后 30 天内的关闭比例，使观察时间相同。随后核对程序中的固定数值、DHS（无家可归者服务局）的统计范围和关键表，重建文件并运行 verify 检查脚本。终稿仍写错最大创建时间，即数据中最晚的请求创建时间，总览也有文字未显示完整。

DeepSeek · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	13.25	14	0.75
证据计算	20	13.75	17.5	3.75
调查判断	20	17.25	19.25	2
人工维护	25	19	20.5	1.5
成品可用	10	5.25	6.75	1.5
自主资源	10	8	9.25	1.25
现行 S 合计	100	76.5	87.25	10.75

表 4 DeepSeek 两轮现行 S 六维得分

4.1 DeepSeek 评分依据

数据基础与问题定义（/15） 13.25→14。检查分片、状态与观察窗口，第二轮进一步统一地址与 ZIP 口径。

证据与计算正确性（/20） 13.75→17.5。第一轮把住宅噪音错并进供暖与街道噪音；第二轮仍写错最大创建时间。

调查深度与判断（/20） 17.25→19.25。异常地址、邮编、关闭方式与固定 30 天观察互相对照。

人工复现与维护（/25） 19→20.5。保留 23 份 CSV 和检查记录，部分入口和说明仍需整理。

成品实际可用性（/10） 5.25→6.75。调查结果有用；第二轮总览截字及终稿时间错误仍影响直接使用。

自主性与资源纪律

自主性与资源纪律由 8 升至 9.25/10。第一轮同类数据框错误连续出现，第二轮这类返工减少。两轮总分分别为 76.5 和 87.25：地址和观察窗口调查更充分了，终稿时间错误和总览显示问题仍在，因此成品得 6.75/10，使用前需要修订。

第二轮留下了较深入的地址和观察窗口调查，估算费用较低。采用前仍要修正终稿时间和显示问题，并回查所引用的结果；第一轮类别错配也说明，主要合计数需要逐项核对。

DeepSeek 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

5 GLM

第一轮的工作

GLM 逐个文件汇总总量、季节变化、道路异常、机构时长、地区和渠道。道路调查从 Street Condition 月度变化继续查到 Pothole（坑洞）、Cave-in（路面塌陷）、DOT（交通局）受理、日期和五区分布，其他方向主要是汇总比较。它注意到近期请求的关闭观察时间较短，但对 DOHMH（卫生与心理健康局）流程和新旧类别关系的解释仍缺支持材料。

第二轮的工作

第二轮检查字段、分布、负时长和季节性后，增加同比类型增量分解，继续调查住宅噪声、热点地址、供暖季和关闭时长。GLM 修正月均值与关闭率所用的月份数，修改生成脚本，再复算聚合表、检查图表和月表。核查热点结果时发现，地址前缀筛选还纳入了其他街道和投诉类型，原文将其解释为两个地址的住宅噪声，范围对不上。这个专题仍需重新界定后计算。

GLM · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	12.25	13.25	1
证据计算	20	15.25	16.25	1
调查判断	20	12.5	17.75	5.25
人工维护	25	18	17	-1
成品可用	10	6.75	7.5	0.75
自主资源	10	9.25	9.25	0
现行 S 合计	100	74	81	7

表 5 GLM 两轮现行 S 六维得分

5.1 GLM 评分依据

数据基础与问题定义（/15） 12.25→13.25。覆盖全量数据并收至道路与热点问题；第二轮问题界定略有改善。

证据与计算正确性（/20） 15.25→16.25。547 条 Closed 子集负时长统计正确；热点前缀的实际纳入范围未讲清。

调查深度与判断（/20） 12.5→17.75。第二轮补做类型增量、热点与观察窗口，调查分提高 5.25。

人工复现与维护（/25） 18→17。专题增加后，聚合前置步骤未纳入完整复现入口，维护分下降。

成品实际可用性（/10） 6.75→7.5。交付速度快；热点定义和部分表头仍需改正。

自主性与资源纪律

自主性与资源纪律两轮均为 9.25/10，第二轮约 9.59 分钟、目录价 6.48 元。这轮新增的调查使调查分从 12.5 升至 17.75，但说明未完整交代聚合前置步骤，维护分由 18 降至 17。复核还确认，547 条 Closed（已关闭）状态负时长的统计是正确的。

第二轮 9.59 分钟、目录价约 6.48 元，比 GPT 省时省费。若采用这份成果，需要先重新界定热点范围、重算相关结果，并补齐维护步骤；GLM 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

6 Qwen

第一轮的工作

Qwen 比较总量、类别、地区和关闭时长，识别道路异常与分类变化，提交 Excel 和说明。第一轮对异常追查较少。回查 Drug Activity（涉毒活动请求类别）的描述时，在相同 11 个月内，室内描述占比由约 8% 升至 31%，与报告所写的“结构未变”不符。这里的结构指不同描述所占比例，需先修正这一判断，再解释该类请求的变化。

第二轮的工作

第二轮补查字段、唯一编号、缺失值、状态及时间异常，再拆解类别增量、行政区与渠道。Qwen 追查噪声尖峰、地点分布和违停结构，也检查分类变化与 Drug Activity。交付时多次修改标签和统计范围，读回文件并核对图表、说明及重算结果。评测时发现关闭时长仍用 11 个月与 9 个月比较；统一月份后，UNSANITARY（不卫生状况类别）增幅约 12.6%，低于原文约 18.2%。

Qwen · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	10.25	14.25	4
证据计算	20	15.25	12.75	-2.5
调查判断	20	8.75	14.75	6
人工维护	25	18	19	1
成品可用	10	6.75	6.75	0
自主资源	10	8.5	7.75	-0.75
现行 S 合计	100	67.5	75.25	7.75

表 6 Qwen 两轮现行 S 六维得分

6.1 Qwen 评分依据

数据基础与问题定义（/15） 10.25→14.25。第二轮补查唯一键、状态、缺失与时间异常，问题界定改善。

证据与计算正确性（/20） 15.25→12.75。第一轮称 Drug Activity 描述结构未变；第二轮关闭时长用了 11 个月对 9 个月。

调查深度与判断（/20） 8.75→14.75。第二轮扩至五项调查，增量与异常检查增加；主要时长比较仍须重做。

人工复现与维护（/25） 18→19。九张工作表和十五张图可查，重建与复现材料仍需统一口径。

成品实际可用性（/10） 6.75→6.75。正文、图表与比较时间窗未完全同步，两轮均为 6.75。

自主性与资源纪律

自主性与资源纪律由 8.5 降至 7.75/10。第二轮约 60.21 分钟、目录价 14.33 元，较多时间用于重建和检查文件。总分从 67.5 升至 75.25，但前述时间窗口问题尚未解决，接手后要重做主要时长比较，并同步修改图表和正文。

第二轮耗时 60.21 分钟、目录价约 14.33 元，均高于 GLM。两轮分别留下描述结构和时间窗口错误，主要比较还要重做。就这次个人使用而言，这次不再继续投入重试。Qwen 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

7 Gemini

第一轮的工作

Gemini 第一轮调查异常地址、供暖分布、违停与噪声时段、机构处置时长，并提出治理建议。回查地址表时，缺失地址被合并成了一个高频地址；每万人口的请求数也被算成实际的十分之一。再读解释部分，报告把聚集请求当作真实事件、把空间差异归于阶层差异，并据结案描述评价部门效能。这些解释缺少进一步证据，现有统计不足以支持相应建议。

第二轮的工作

第二轮核对日期、字段和异常计数，再拆解部门与类别增量，调查道路、DEP（环境保护局）、供暖集中度、空间及处置结果。Gemini 也检查近期未关闭记录、分类变化和生成文件。回查结案原句时，arrest（拘捕）命中 95,943 条，其中 95,784 条是否定表述，肯定仅 159 条。原文没有区分“未拘捕”等否定含义，用命中数量支持拘捕解释，结论需要重写。

Gemini · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	5.75	10.5	4.75
证据计算	20	6.5	10.5	4
调查判断	20	5.75	11.25	5.5
人工维护	25	10.75	14.25	3.5
成品可用	10	4.25	6	1.75
自主资源	10	6.5	7	0.5
现行 S 合计	100	39.5	59.5	20

表 7 Gemini 两轮现行 S 六维得分

7.1 Gemini 评分依据

数据基础与问题定义（/15） 5.75→10.5。第一轮把缺失地址合成高频地址，每万人口的请求数算成实际的十分之一；第二轮有所改善。

证据与计算正确性（/20） 6.5→10.5。第二轮 arrest 命中 95943 条，其中 95784 条是否定表述；肯定仅 159 条。

调查深度与判断（/20） 5.75→11.25。增长分解和集中度检查增多，但治理原因仍超出记录可支持范围。

人工复现与维护（/25） 10.75→14.25。维护入口有所改善，关键文本与口径仍需人工复核。

成品实际可用性（/10） 4.25→6。两轮都有工作簿，最终解释错误使成品不能直接用于决策。

自主性与资源纪律

自主性与资源纪律由 6.5 升至 7/10。运行记录中仍有搜索项目根目录、暴露其他目录路径的行为。两轮总分为 39.5 和 59.5；第二轮补充了增长分解和维护入口，但结案文本的误读仍影响主要解释，需在采用结果前处理。

两轮都有可回查的汇总结果，主要治理解释仍需重做。第二轮用时 6.07 分钟，但读回结案原句后发现的语义错误会改变相关结论，因此本次暂不采用其政策、人口或执法建议。

Gemini 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

8 Claude

第一轮的调查与交付

Claude 核对数据范围，调查高频地址、增长来源、类别、关闭时长、结案原句和重复记录，保存 30 张中间表、生成 13 个工作表。它按“同一地址、同一类别单日不少于 200 条”筛出 4 个住宅噪声组合，共 185,791 条，再比较剔除前后的趋势；用日均值处理 365 天与 364 天的差异，并检查已有足够时间观察关闭结果的请求批次（成熟队列）、机构时长及 NYPD（警察局）结案描述。接管前留下 15 份脚本和 34 页预览。高频记录为何要全部剔除，仍缺充分依据。

Claude 第一轮已完成主体调查、汇总、Excel 和说明。Cursor 额度用尽后，Grok 订正说明中的数字、重建并检查成品；这段接续工作单列。Claude 第二轮未运行。Claude 阶段订阅额度内计价 153.57 元，含 Grok 接续共 165.69 元。

Claude · S 六维得分				
维度	满分	第一轮	第二轮	变化
数据基础	15	11.25	—	—
证据计算	20	15.25	—	—
调查判断	20	15.75	—	—
人工维护	25	18.25	—	—
成品可用	10	6	—	—
自主资源	10	5.5	—	—
现行 S 合计	100	72	—	—

表 8 Claude 第一轮现行 S 六维得分

8.1 Claude 评分依据

数据基础与问题定义（/15） 11.25。核查全量范围和高频地址，但将聚集记录直接视作无效样本欠妥。

证据与计算正确性（/20） 15.25。30 张汇总表中 28 张可重做一致，另两张存在标签或口径差异。

调查深度与判断（/20） 15.75。调查增长、地址、成熟队列和结案文本，接管前形成主要分析。

人工复现与维护（/25） 18.25。15 份正式脚本可追溯到 Claude；末次订正与重建由 Grok 完成。

成品实际可用性（/10） 6。已有 13 表 13 图 Excel 及预览；关键筛选和交付一致性仍需核查。

自主性与资源纪律

自主性与资源纪律为 5.5/10。Claude 阶段订阅额度计价 153.57 元，后续由 Grok 接续，合计 165.69 元。按接管前材料核查，第一轮总分 72：原脚本重做 30 张中间表，其中 28 张一致，另两张有标签或口径差异；高频记录剔除、集中出现的一组记录及天气解释还需补证据。最后的数字订正和重建由 Grok 完成。

9 Kimi

第一轮为何退出

Kimi 第一轮多次提前结束，依赖人工催促，随后退出。现存记录不足以核出完整耗时、Token 及费用；目录中也没有必交 Excel 和分析说明，状态按“退出”保留。

第二轮补充复测

第二轮先遇到启动器故障，当时模型尚未启动，另行登记。实际启动后，Kimi 反复读取 data_manifest.json 输入文件清单；工具已提示文件未变化、重复读取没有收益，它仍未调整做法。评测方停止循环，未得到 Excel 或分析说明。

实际复测约 2.65 分钟，目录价估算 1.48 元。去掉计划、进度等管理动作后，共有 14 个处理任务的实质动作，其中 13 个被判为没有收益。Token 指模型处理文字时使用的计量单位，不能直接当作字数；第一轮这类用量记录不完整。

评分处理

两轮均缺少完整成品，不具备 25 项逐项评分所需的分析和交付材料；S 留空，不把失败填为 0 分。

第一轮退出、第二轮重复读取后停止，都是本次尝试的实际结果。因此，比较表中保留这两轮状态及已记录的资源使用，评分位置留空。

在本次 Claude Code 组合和两轮机会内，Kimi 未交付可用成果；收到重复读取提示后，也未调整做法。就这次个人使用而言，已有时间、费用和催促记录不足以支持继续付费重试。

10 成果质量与可维护性比较

第1轮 现行 S 六维								
AI	数据基础/15	证据计算/20	调查判断/20	人工维护/25	成品可用/10	自主资源/10	合计/100	状态
GPT	14	20	14.25	19.75	10	10	88	已完成
Grok	15	19	15.75	17	8.5	9.25	84.5	已完成
DeepSeek	13.25	13.75	17.25	19	5.25	8	76.5	已完成
GLM	12.25	15.25	12.5	18	6.75	9.25	74	已完成
Qwen	10.25	15.25	8.75	18	6.75	8.5	67.5	已完成
Gemini	5.75	6.5	5.75	10.75	4.25	6.5	39.5	已完成
Claude	11.25	15.25	15.75	18.25	6	5.5	72	已完成
Kimi	—	—	—	—	—	—	—	未评分

表 9 第一轮现行 S 六维得分

第2轮 现行 S 六维								
AI	数据基础/15	证据计算/20	调查判断/20	人工维护/25	成品可用/10	自主资源/10	合计/100	状态
GPT	15	20	20	23.5	10	10	98.5	已完成
Grok	13	19	19.25	17	7.75	9.25	85.25	已完成
DeepSeek	14	17.5	19.25	20.5	6.75	9.25	87.25	已完成
GLM	13.25	16.25	17.75	17	7.5	9.25	81	已完成
Qwen	14.25	12.75	14.75	19	6.75	7.75	75.25	已完成
Gemini	10.5	10.5	11.25	14.25	6	7	59.5	已完成
Claude	—	—	—	—	—	—	—	未运行
Kimi	—	—	—	—	—	—	—	未评分

表 10 第二轮现行 S 六维得分

10.1 六维差异与同分异因

先看数据范围和字段理解。GPT 第二轮的数据基础 A 为 15/15，DeepSeek 与 Qwen 分别为 14 和 14.25，Grok 为 13，Gemini 由 5.75 升至 10.5。检查范围较完整的成品也可能误解字段：Grok 把 BBL 地块写成建筑，Gemini 第一轮把缺失地址合并为一个地址，相应问题都计入这一维度。

沿着这些定义继续核对计算，Qwen 第二轮的时长比较用了 11 个月对 9 个月，Gemini 把 arrest 否定表述算入肯定解释，DeepSeek 第一轮则混入了错误类别。这些问题直接影响结论。证据计算 B 中，GPT 两轮均 20/20；第二轮 Grok19、DeepSeek17.5、GLM16.25、Qwen12.75、Gemini10.5。

再看系统是否沿着异常继续查。六系统调查判断 C 的均值由 12.38 升至 17.04，增加 4.67 分，约占总增量 49.3%。GPT 第二轮排除峰日、固定构成，得到 20/20；Grok 与 DeepSeek 进一步查地块和地址，均为 19.25。GLM 增加了热点调查，但筛选范围有混入，还需回到原始记录核对。

接着尝试按提交说明重做和更新结果。GPT 第二轮人工维护 D 为 23.5/25，DeepSeek20.5、Qwen19、GLM 与 Grok 各 17、Gemini14.25。差异主要出在具体步骤：Grok 一处文件检查始终通过，GLM 漏写新增专题的聚合前置步骤，Qwen 则需要先修正时间窗口再重做结果。

最后检查文件能否阅读，以及运行和接手过程还留下哪些问题。GPT 第二轮成品 E 与自主性 F 均为 10；DeepSeek 虽做了较深调查，终稿时间错误和总览截字使 E 为 6.75。Grok 的 E 为 7.75。Gemini 的 E 与 F 分别为 6 和 7，仍需修正结案解释并处理运行中的目录访问问题。

Grok85.25 与 DeepSeek87.25 相差 2 分，前者主要缺维护说明和有效检查，后者还要订正终稿时间与显示。GLM81 与 Qwen75.25 也各有问题：GLM 需重定热点范围，Qwen 需重做关键时长比较。

11 人工维护与自主性比较

第1轮 人工维护、成品与自主性				
AI	维护/25	成品/10	自主/10	S/100
GPT	19.75	10	10	88
Grok	17	8.5	9.25	84.5
DeepSeek	19	5.25	8	76.5
GLM	18	6.75	9.25	74
Qwen	18	6.75	8.5	67.5
Gemini	10.75	4.25	6.5	39.5
Claude	18.25	6	5.5	72
Kimi	—	—	—	—

表 11 第一轮人工维护、成品与自主性

第2轮 人工维护、成品与自主性				
AI	维护/25	成品/10	自主/10	S/100
GPT	23.5	10	10	98.5
Grok	17	7.75	9.25	85.25
DeepSeek	20.5	6.75	9.25	87.25
GLM	17	7.5	9.25	81
Qwen	19	6.75	7.75	75.25
Gemini	14.25	6	7	59.5
Claude	—	—	—	—
Kimi	—	—	—	—

表 12 第二轮人工维护、成品与自主性

人工维护的差别出现在交接时：GPT 留下输入、SQL、结果和更新顺序，第二轮 D 为 23.5；Grok 两轮均 17，脚本中一处文件存在检查始终通过且缺维护说明；GLM 第二轮新增热点专题后 D 从 18 降到 17，聚合前置步骤没有完整交代。

Claude 接管前 D 为 18.25，原脚本重做 28/30 张中间表一致，剩余两表存在标签或口径差异。Grok 接续的数字订正与重建不能记作 Claude 自行修好。Kimi 两轮没有成品，维度留空，但人工催促和读取循环属于明确的使用负担。

第二轮六系统运行期间均没有追加指令，交付后却仍登记了 10 项修正。自主性 F 中，GPT 为 10，Grok、DeepSeek、GLM 均为 9.25，Qwen7.75，Gemini7。这里的分数连同修正记录一起阅读，才能看清运行中需要多少介入，以及收到文件后还要做什么。

12 两轮变化

六系统配对·现行 S 平均变化				
维度	满分	第一轮	第二轮	增量
数据基础	15	11.75	13.33	1.58
证据计算	20	14.96	16	1.04
调查判断	20	12.38	17.04	4.67
人工维护	25	17.08	18.54	1.46
成品可用	10	6.92	7.46	0.54
自主资源	10	8.58	8.75	0.17

表 13 六系统现行 S 六维平均变化

将同样六个系统的两轮结果放在一起，S 均值由 71.67 升至 81.13，增加 9.46 分。各自变化为 GPT+10.5、Grok+0.75、DeepSeek+10.75、GLM+7、Qwen+7.75、Gemini+20。Gemini 增加最多，第二轮仍为 59.5 分，前文发现的文本解释问题尚未解决，后续还需结合分项查看。

拆开总分后，六维平均增量为 A+1.58、B+1.04、C+4.67、D+1.46、E+0.54、F+0.17。调查判断 C 约占一半，维护 D 和成品 E 的变化较小。结合各系统的提交材料，可以看到第二轮普遍增加了异常追查和对照计算，维护说明与终稿检查补充得较少。

Qwen 第二轮增加五项调查与图表，S 从 67.5 升至 75.25，主要时长比较仍用了不同月份。GLM 增加热点专题后，C 由 12.5 升至 17.75，但未补齐聚合前置说明，D 由 18 降至 17。这两份提交都增加了调查内容，同时留下了需要接手处理的具体问题。

GPT 第二轮围绕峰日和固定构成补查，调查判断得 20 分，人工维护 23.5 分，成品与自主性均为满分。结合原运行中的成品检查和核心结论核查，只有这一轮满足第 1.2 节列出的全部参照条件。

12.1 评分变化与实际动作

逐项回看，GPT 补了峰日排除与固定构成，Grok 剔除固定 Top10 地块，DeepSeek 加入地址与 30 天观察窗，GLM 增加增量和热点分析，Qwen 扩展调查，Gemini 增加贡献分解。调查分记录这些工作的完成程度；计算错误及成品中的解释问题，继续记在证据计算 B 和成品 E 的对应细项中。

13 耗时、费用与后续修正

第二轮交付与资源指标					
AI	S/100	分钟	费用参考/元	修正	状态
GPT	98.5	17.78	38.96	0	已完成
Grok	85.25	11.71	9.86	1	已完成
DeepSeek	87.25	21.7	1.37—2.74	1	已完成
GLM	81	9.59	6.48	1	已完成
Qwen	75.25	60.21	14.33	2	已完成
Gemini	59.5	6.07	5.12	5	已完成
Kimi	—	2.65	1.48	0	失败
Claude	—	—	—	—	未运行

表 14 第二轮交付与资源指标




图 1 第二轮原生耗时

第二轮费用参考值 (元)




图 2 第二轮费用参考值

第二轮费用参考值：GLM 目录价 6.48 元，GPT38.96 元，DeepSeek 按忙时、闲时单价列为 1.37—2.74 元，Qwen14.33 元；均按记录用量与公开单价估算。Grok 的 9.86 元是 Cursor 订阅额度消耗。Gemini 的 5.12 元则把 Token 用量按相应 API 单价折算，称为 Token 等价费用；API 指软件调用模型的接口。上述金额计价方式不同，均不直接等于本次现金扣款。

耗时从各轮运行记录取得：GLM9.59 分钟、GPT17.78、Grok11.71、DeepSeek21.70、Qwen60.21、Gemini6.07。GLM 的热点定义、DeepSeek 的终稿时间仍需修正；这些接手工作没有计入模型运行耗时。

13.1 无收益动作与后续修正




图3 第二轮无收益动作占比

图中 AWR 是无收益动作占比：确认无收益的动作数，除以实质动作数。实质动作包括直接推进交付、必要探索和确认无收益三类，计划或进度管理动作不计入分母；必要探索即使未进入终稿也不直接算浪费。六系统第二轮共 300 个实质动作，5 个确认无收益。Qwen 与 Gemini 这一比例均为 0，成品仍有 2 项和 5 项修正。

六系统第二轮运行期间均无追加指令。交后修正共 10 项，涉及类别和对象定义、比较窗口、数字转述、文本语义及原因解释。GPT 为 0；Grok、DeepSeek、GLM 各 1；Qwen2；Gemini5。

这些修正的工作量也不同。GLM 的字段数可以局部订正，热点定义则影响专题取数；Gemini 要按否定语境重查结案文本，Qwen 要统一时间窗口后重做比较。项目没有记录逐动作耗时和实际人工修正分钟，因此这里只列需要做的工作，不将任务数换算为人工工时。

个人选择时，除表中的时间与费用，还需要判断自己能否处理相应问题。例如，采用 Qwen 的时长结论前，要先完成窗口统一和重算；这部分投入尚未计入运行价格。

14 研究结论

回到开头的问题：这次给出相同数据、最多运行两轮后，六系统留下了两轮可评分成果，第二轮平均 81.13 分；Claude 第一轮由 Grok 接续，Kimi 两轮未形成成品。按前述检查和参照条件，GPT 第二轮达到要求。结论限于本次任务与运行条件。

14.1 独立交付与接管

GPT 第二轮已完成可供人接手的分析链，且未登记交后修正。Grok、DeepSeek、GLM 在无追加指令下完成成品，但交接或终稿仍需局部补查。Claude 第一轮主体工作已有价值，后段接管是实际使用成本；Kimi 在两轮内没有完成。

14.2 成果差距在哪里

前文逐项核查后，GPT 第二轮证据计算为 20/20、调查 20/20、维护 23.5/25，主要结果可回查，也留下了对照计算和更新顺序。Grok 与 DeepSeek 的调查同样有内容，但地块定义、维护检查、终稿时间或显示仍需补正。Qwen 的时间窗口和 Gemini 的文本语义则影响主要结论，采用前需要重做相应部分。

14.3 第二轮改善了什么

两轮之间，六系统平均增加 9.46 分，其中调查深度增加 4.67 分，维护增加 1.46 分、成品增加 0.54 分。从已有文件能看到调查更深入了，交接和终稿问题仍较集中。由于第二轮提示、自身调整及运行环境可能共同影响结果，而且各条件仅运行一次，本次无法分离方法提示带来的具体贡献。

14.4 各系统综合评价

GPT 第二轮补查了峰日和渠道构成，主要文件与结果也经过检查。如果这次任务优先考虑完整交付和较少返工，可优先选用。两轮目录价约 63.91 元，高于 Grok、DeepSeek、GLM、Qwen、Gemini 的费用参考值，低于 Claude 含接续的 165.69 元。

Grok 供暖集中度等调查可供参考，接手后要补维护说明、有效检查和部分表述。第二轮 11.71 分钟，比 GPT 快；订阅内用量计价约 9.86 元，两轮合计 16.34 元。

DeepSeek 第二轮留下了较深入的地址和观察窗口调查，估算费用较低。采用前仍要修正终稿时间和显示问题，并回查所引用的结果；第一轮类别错配也说明，主要合计数需要逐项核对。

GLM 第二轮 9.59 分钟、目录价约 6.48 元，比 GPT 省时省费。若采用这份成果，需要先重新界定热点范围、重算相关结果，并补齐维护步骤；

Qwen 第二轮耗时 60.21 分钟、目录价约 14.33 元，均高于 GLM。两轮分别留下描述结构和时间窗口错误，主要比较还要重做。就这次个人使用而言，这次不再继续投入重试。

Gemini 两轮都有可回查的汇总结果，主要治理解释仍需重做。第二轮用时 6.07 分钟，但读回结案原句后发现的语义错误会改变相关结论，因此本次暂不采用其政策、人口或执法建议。

Claude 接管前已完成较多调查和大部分交付，高频记录剔除及部分解释仍缺依据。Claude 阶段订阅额度计价 153.57 元，连同 Grok 接续共 165.69 元。在本次任务中，费用和接续工作都较多，个人使用暂不优先选用。

Kimi 两轮未获得可用交付，且已有时间、费用和人工催促记录。在本次工具组合下，暂不追加付费重试。

附录 评分明细与资料说明

本报告使用 v2.2 评分标准，对已保存的参赛成果逐项复核。“现行 S”指本次使用的自主交付总分，旧版评分另存。共 325 条评分依据在 Excel“评分与用量”的 S 分项中，得分批注附实际工作、缺口和原件位置，K 列编号可到“查证.html”查询。编号由组别和序号组成，如 D5 就是 D 组第 5 项。

表中“14→15”依次表示第一轮 14 分、第二轮 15 分，“/15”表示该组满分 15 分；变化等于第二轮减第一轮。六系统配对均值只对两轮都有评分的同样六个系统求平均。Claude 第二轮及 Kimi 两轮留空，空白不参与平均，也不按 0 分处理。Excel“评分细项”用 AI 下拉查看，“分维度比较”可选轮次、得分或得分率；得分率是得分除以该项满分。

A 组看数据和选题：A1 是否理解一条记录、字段和单位；A2 是否处理会影响结论的数据问题；A3 问题能否由已有数据回答；A4 是否有理由优先调查这些问题。

B 组看结果是否成立：B1 数字、筛选及分子分母是否正确；B2 比较的时间和对象是否可比；B3 能否从结论找到输入、计算和结果；B4 解释是否符合字段和原始记录。

C 组看调查怎样继续：C1 把总体差异拆到具体来源；C2 沿异常查到日期、类别、地点或记录；C3 改变筛选或加入对照后检查结论是否仍成立，并检查其他解释；C4 发现矛盾后核查并同步修改；C5 适时停止证据不足的方向，保留尚未解决的问题。

D 组看接手所需材料：D1 能否找到阅读入口与执行步骤；D2 能否理解处理和计算中的选择；D3 能否按现有材料重做主要结果；D4 能否更新数据、定位错误并核对受影响内容；D5 原 AI 是否检查过最终成品。

E 组看最终文件：E1 能否找到答案并完成比较；E2 文字、图表和筛选是否显示正常；E3 各文件是否一致，声称完成的工作是否实际留下。F 组看运行与负担：F1 是否需要指导或接管；F2 交付后还需修正哪些问题；F3 遇到失败能否调整做法；F4 是否复用已有结果、减少无效计算并清理自建应用。

原始参赛作品保留在各系统目录，输入清单在 input/data_manifest.json。人维护的代表任务由 AI 辅助审读和执行；本项目未观察真人实际操作。

本评测仅由一名评审给分，没有测量评审间一致性，也没有记录人工监督或修正工时。

附表 1 GPT 评分细项

GPT S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	4	4	0	D1	阅读入口与步骤	4	4	4	0
A2	数据质量判断	4	4	4	0	D2	过程可理解	6	4.5	6	1.5
A3	问题可回答性	3	3	3	0	D3	结果可重做	6	6	6	0
A4	问题优先级	4	3	4	1	D4	更新与错误定位	6	3	4.5	1.5
B1	数字与口径	6	6	6	0	D5	原AI的成品检查	3	2.25	3	0.75
B2	可比性	5	5	5	0	E1	阅读与比较	4	4	4	0
B3	来源链	5	5	5	0	E2	画面与交互	3	3	3	0
B4	解释成立	4	4	4	0	E3	文件一致与完成声明	3	3	3	0
C1	差异分解	4	4	4	0	F1	原运行独立性	3	3	3	0
C2	下钻调查	4	2	4	2	F2	交后修正负担	3	3	3	0
C3	稳健性与替代解释	5	1.25	5	3.75	F3	失败处理	2	2	2	0
C4	据证据修正	4	4	4	0	F4	资源使用	2	2	2	0
C5	范围与停止	3	3	3	0						

现行 S： 第一轮 88 第二轮 98.5 变化 10.5

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 15 GPT 现行 S 25 项得分

附表 2 Grok 评分细项

Grok S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	4	3	-1	D1	阅读入口与步骤	4	2	2	0
A2	数据质量判断	4	4	3	-1	D2	过程可理解	6	4.5	4.5	0
A3	问题可回答性	3	3	3	0	D3	结果可重做	6	6	6	0
A4	问题优先级	4	4	4	0	D4	更新与错误定位	6	3	3	0
B1	数字与口径	6	6	6	0	D5	原AI的成品检查	3	1.5	1.5	0
B2	可比性	5	5	5	0	E1	阅读与比较	4	4	4	0
B3	来源链	5	5	5	0	E2	画面与交互	3	1.5	1.5	0
B4	解释成立	4	3	3	0	E3	文件一致与完成声明	3	3	2.25	-0.75
C1	差异分解	4	4	4	0	F1	原运行独立性	3	3	3	0
C2	下钻调查	4	3	4	1	F2	交后修正负担	3	2.25	2.25	0
C3	稳健性与替代解释	5	2.5	5	2.5	F3	失败处理	2	2	2	0
C4	据证据修正	4	4	4	0	F4	资源使用	2	2	2	0
C5	范围与停止	3	2.25	2.25	0						
现行 S： 第一轮 84.5 第二轮 85.25 变化 0.75											

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 16 Grok 现行 S 25 项得分

附表 3 DeepSeek 评分细项

DeepSeek S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	4	4	0	D1	阅读入口与步骤	4	4	4	0
A2	数据质量判断	4	3	3	0	D2	过程可理解	6	4.5	4.5	0
A3	问题可回答性	3	2.25	3	0.75	D3	结果可重做	6	6	6	0
A4	问题优先级	4	4	4	0	D4	更新与错误定位	6	3	4.5	1.5
B1	数字与口径	6	3	4.5	1.5	D5	原AI的成品检查	3	1.5	1.5	0
B2	可比性	5	3.75	5	1.25	E1	阅读与比较	4	3	3	0
B3	来源链	5	5	5	0	E2	画面与交互	3	0.75	1.5	0.75
B4	解释成立	4	2	3	1	E3	文件一致与完成声明	3	1.5	2.25	0.75
C1	差异分解	4	4	4	0	F1	原运行独立性	3	3	3	0
C2	下钻调查	4	4	4	0	F2	交后修正负担	3	1.5	2.25	0.75
C3	稳健性与替代解释	5	5	5	0	F3	失败处理	2	1.5	2	0.5
C4	据证据修正	4	2	4	2	F4	资源使用	2	2	2	0
C5	范围与停止	3	2.25	2.25	0						
现行 S： 第一轮 76.5 第二轮 87.25 变化 10.75											

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 17 DeepSeek 现行 S 25 项得分

附表 4 GLM 评分细项

GLM S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	4	4	0	D1	阅读入口与步骤	4	3	2	-1
A2	数据质量判断	4	3	3	0	D2	过程可理解	6	4.5	4.5	0
A3	问题可回答性	3	2.25	2.25	0	D3	结果可重做	6	6	6	0
A4	问题优先级	4	3	4	1	D4	更新与错误定位	6	3	3	0
B1	数字与口径	6	4.5	4.5	0	D5	原AI的成品检查	3	1.5	1.5	0
B2	可比性	5	3.75	3.75	0	E1	阅读与比较	4	3	3	0
B3	来源链	5	5	5	0	E2	画面与交互	3	1.5	2.25	0.75
B4	解释成立	4	2	3	1	E3	文件一致与完成声明	3	2.25	2.25	0
C1	差异分解	4	3	4	1	F1	原运行独立性	3	3	3	0
C2	下钻调查	4	3	4	1	F2	交后修正负担	3	2.25	2.25	0
C3	稳健性与替代解释	5	1.25	3.75	2.5	F3	失败处理	2	2	2	0
C4	据证据修正	4	3	3	0	F4	资源使用	2	2	2	0
C5	范围与停止	3	2.25	3	0.75						

现行 S：第一轮 74 第二轮 81 变化 7

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 18 GLM 现行 S 25 项得分

附表 5 Qwen 评分细项

Qwen S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	3	4	1	D1	阅读入口与步骤	4	3	4	1
A2	数据质量判断	4	2	4	2	D2	过程可理解	6	4.5	4.5	0
A3	问题可回答性	3	2.25	2.25	0	D3	结果可重做	6	6	6	0
A4	问题优先级	4	3	4	1	D4	更新与错误定位	6	3	3	0
B1	数字与口径	6	4.5	4.5	0	D5	原AI的成品检查	3	1.5	1.5	0
B2	可比性	5	3.75	1.25	-2.5	E1	阅读与比较	4	3	3	0
B3	来源链	5	5	5	0	E2	画面与交互	3	1.5	1.5	0
B4	解释成立	4	2	2	0	E3	文件一致与完成声明	3	2.25	2.25	0
C1	差异分解	4	2	4	2	F1	原运行独立性	3	3	3	0
C2	下钻调查	4	3	4	1	F2	交后修正负担	3	1.5	0.75	-0.75
C3	稳健性与替代解释	5	1.25	2.5	1.25	F3	失败处理	2	2	2	0
C4	据证据修正	4	1	2	1	F4	资源使用	2	2	2	0
C5	范围与停止	3	1.5	2.25	0.75						
现行 S： 第一轮 67.5 第二轮 75.25 变化 7.75											

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 19 Qwen 现行 S 25 项得分

附表 6 Gemini 评分细项

Gemini S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	1	3	2	D1	阅读入口与步骤	4	1	3	2
A2	数据质量判断	4	2	3	1	D2	过程可理解	6	3	3	0
A3	问题可回答性	3	0.75	1.5	0.75	D3	结果可重做	6	4.5	6	1.5
A4	问题优先级	4	2	3	1	D4	更新与错误定位	6	1.5	1.5	0
B1	数字与口径	6	1.5	3	1.5	D5	原AI的成品检查	3	0.75	0.75	0
B2	可比性	5	2.5	3.75	1.25	E1	阅读与比较	4	2	3	1
B3	来源链	5	2.5	3.75	1.25	E2	画面与交互	3	1.5	2.25	0.75
B4	解释成立	4	0	0	0	E3	文件一致与完成声明	3	0.75	0.75	0
C1	差异分解	4	2	4	2	F1	原运行独立性	3	3	3	0
C2	下钻调查	4	2	3	1	F2	交后修正负担	3	0	0	0
C3	稳健性与替代解释	5	0	2.5	2.5	F3	失败处理	2	1.5	2	0.5
C4	据证据修正	4	1	1	0	F4	资源使用	2	2	2	0
C5	范围与停止	3	0.75	0.75	0						
现行 S： 第一轮 39.5 第二轮 59.5 变化 20											

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 20 Gemini 现行 S 25 项得分

附表 7 Claude 评分细项

Claude S 评分细项											
编号	评分项	满分	第一轮	第二轮	差	编号	评分项	满分	第一轮	第二轮	差
A1	粒度与语义	4	3	—	—	D1	阅读入口与步骤	4	4	—	—
A2	数据质量判断	4	2	—	—	D2	过程可理解	6	4.5	—	—
A3	问题可回答性	3	2.25	—	—	D3	结果可重做	6	4.5	—	—
A4	问题优先级	4	4	—	—	D4	更新与错误定位	6	3	—	—
B1	数字与口径	6	4.5	—	—	D5	原AI的成品检查	3	2.25	—	—
B2	可比性	5	3.75	—	—	E1	阅读与比较	4	3	—	—
B3	来源链	5	5	—	—	E2	画面与交互	3	1.5	—	—
B4	解释成立	4	2	—	—	E3	文件一致与完成声明	3	1.5	—	—
C1	差异分解	4	4	—	—	F1	原运行独立性	3	2.25	—	—
C2	下钻调查	4	4	—	—	F2	交后修正负担	3	0.75	—	—
C3	稳健性与替代解释	5	2.5	—	—	F3	失败处理	2	1	—	—
C4	据证据修正	4	3	—	—	F4	资源使用	2	1.5	—	—
C5	范围与停止	3	2.25	—	—						

现行 S：第一轮 72 第二轮 — 变化 —

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 21 Claude 现行 S 25 项得分