

# AI 数据分析 Agent 自主交付评测报告

NYC311 数据分析任务 两轮自主交付评测

## 摘要

项目 1 完成了一次纽约市 311 非紧急市政服务请求（NYC311）数据分析。本项目沿用这批数据，把选题、计算、制表和说明交给能够调用工具执行任务的 AI 系统，文中称为 AI Agent。检查从提交的文件开始，逐步核对数字和解释，再按说明重做结果，观察最多两轮机会内能交付到什么程度。

本报告用“自主交付总分”概括检查结果，表中简记为 S，满分 100。八个系统中，六个两轮都有可评分成果，平均总分由 71.67 升至 81.13，增加 9.46 分。GPT 第二轮得 98.5 分，达到第 1.2 节列出的参照要求；Claude 接管前工作得 72 分，Kimi 两轮未形成可评分成品。

进一步核查结论时，Qwen 的描述结构和时间窗口、Gemini 的地址统计和文本解释都出现了会影响主要结论的错误。Grok、DeepSeek 和 GLM 留下了一些可用的调查结果，但说明、终稿数字或专题定义还有缺口。各项得分及这些问题的来由在后文逐一展开。

费用也纳入比较。“目录价”按公布的模型单价和记录用量估算；“订阅额度计价”指平台按用量折算的额度消耗。GPT 第二轮目录价约 38.96 元；GLM 更快、价格较低，但热点定义要修。Claude 由 Grok 接续后，订阅额度计价合计约 165.69 元。它们均不能直接视为额外支付的现金，详见第 13 节。

## 研究问题

1. 有限两轮中，哪些系统独立完成可用交付？
2. 六个评分维度的差异，对应哪些具体分析与错误？
3. 人能否依据提交材料复现主要结果、更新数据并定位错误？
4. 第二轮实际改善了什么，哪些问题仍然存在？
5. 合并质量、时间、费用和人工接管后，本次如何选择？

# 1 评测设计

## 1.1 任务与样本

本次输入是 25 个 Parquet 格式的数据文件，共 7,525,498 条 NYC311 请求记录、44 个字段，也就是 44 列信息。一条记录表示一次服务请求，同一事件可能产生多次请求。八个系统使用同一批数据，自主选择问题，提交 Excel 和分析说明。评测检查这些文件能否供人阅读、核对和继续维护。

各系统最多运行两轮。第一轮使用基础任务提示，第二轮增加方法提示，Grok 和 Gemini 另有检查清单。两轮分别保留提交文件和运行记录，再比较完成的工作。每种条件只运行一次，提示、系统自身调整和运行环境都有可能影响结果。

运行结束后，GPT、Grok、DeepSeek、GLM、Qwen 和 Gemini 两轮都有可评分工作，后文用这六个系统比较两轮变化。Claude 第一轮后段由 Grok 接续，第二轮未运行，单独说明；Kimi 第一轮退出、第二轮失败，保留过程和已有费用记录，分数留空。

## 1.2 评分与核验

收到文件后，先核对问题、取数范围、计算和结论，再尝试按说明重做结果。“复现”指用保留的输入重做主要结果；“维护”还包括更新数据、找到出错位置并修改相关图表和文字。检查允许配置路径、安装所需软件及分步执行，由 AI 辅助审读和操作，未观察真人实际操作。

总分 S 由 25 个细项相加，满分 100，分为六组，A—F 是组别编号。A 数据基础与问题定义 15 分，看是否理解数据、选题能否回答；B 证据与计算正确性 20 分，看数字、比较和解释是否成立；C 调查深度与判断 20 分，看是否继续追查差异、检查其他解释；D 人工复现与维护 25 分，看能否读懂、重做和更新；E 成品实际可用性 10 分，看文件是否清楚、便于使用；F 自主性与资源纪律 10 分，看是否需要催促、接管和返工，以及如何处理失败、使用资源。

每项按完成程度给满分的 100%、75%、50%、25% 或 0：依次为完整满足、主要满足但有局部缺口、部分关键要求完成、仅有有限可用成果、已查明未完成或关键内容不可用。例如，满分 4 分的一项，主要满足得 3 分。得分相加后不再另设上限；缺少评分材料时保留空白，0 分表示已有材料支持该项为 0。

与项目 1 比较时，本项目约定总分至少 90 分，人工维护至少 22/25 分，成品至少 8/10 分，自主性至少 8/10 分；D5“原 AI 的成品检查”须得满分 3 分，即原运行已检查最终文件的数字、显示和必要交互，发现问题后重查。核心结论还须没有已确认而未处理的错误。这些是本项目的评审条件；评测方后来补做的工作不计入原成果。

1.3 模型与运行条件

| 参评模型、思考强度与 Harness |                                                          |                     |                                  |                            |
|--------------------|----------------------------------------------------------|---------------------|----------------------------------|----------------------------|
| AI                 | 第一轮模型                                                    | 第二轮模型               | 思考强度                             | Harness (执行环境)             |
| GPT                | gpt-6-astra                                              | gpt-6-astra         | 中 (medium)                       | Codex                      |
| Grok               | grok-4.6                                                 | grok-4.6            | 中 (medium)                       | Cursor                     |
| DeepSeek           | deepseek-v4.1-flash                                      | deepseek-v4.1-flash | high                             | Claude Code                |
| GLM                | glm-5.3                                                  | glm-5.3             | high                             | Claude Code / Brain Router |
| Qwen               | qwen3.8-max-0902                                         | qwen3.8-max-0902    | high                             | Claude Code                |
| Gemini             | gemini-3.8-flash                                         | gemini-3.8-flash    | 中 (medium)                       | Antigravity                |
| Claude             | Claude Opus 5 → Grok                                     | 无独立运行               | Claude medium;<br>Grok high-fast | Cursor                     |
| Kimi               | kimi-k3                                                  | kimi-k3             | high                             | Claude Code                |
| 运行说明               |                                                          |                     |                                  |                            |
| 思考强度               | 参赛原运行：海外模型为中，国内模型为Claude Code的high；Grok接续阶段为high-fast。   |                     |                                  |                            |
| 执行环境               | Harness指模型使用的执行环境；GLM经Brain Router路由。同名强度设置不代表跨平台相同思考预算。 |                     |                                  |                            |
| 版本与缺失              | Gemini两轮为gemini-3.8-flash；Kimi两轮为kimi-k3；Claude第二轮未运行。   |                     |                                  |                            |

表 1 模型、思考强度与 Harness。来源：Excel“字段说明” H2:L10。

数据整理、评审计算和报告编制使用了 AI 辅助。为便于回查，下文分别说明系统原来提交了什么，以及评测时又核对或重做了什么。

表中的 Harness 是模型使用工具、读写文件和执行任务的软件环境，如 Codex、Cursor、Claude Code。模型名称说明由谁生成回答，Harness 说明通过什么环境完成任务。medium、high、high-fast 是各环境的思考强度设置，同名档位不保证实际投入相同。Gemini 两轮模型已核实为 gemini-3.8-flash，Kimi 两轮均为 kimi-k3。

Claude 第一轮在 Grok 接续前已留下调查和交付文件。评分据此得到 72 分；Grok 后来订正的数字及重建结果另行记录，具体过程见第 8 节。

Kimi 两轮都没有留下必交成品，无法按 25 项核出完整分数。第 9 节说明退出和重复读取的过程；第二轮已发生的约 2.65 分钟和 1.48 元也保留在比较中。

## 2 GPT

### 第一轮的工作

GPT 先核对 25 个数据文件、文件哈希（用于识别文件内容是否变化的校验值）、主键（每条记录的唯一编号）和日期，发现文件名截止日期晚于最后一条记录。它用两年各 1—8 月作比较，按类别和行政区拆解 287,342 条净增量（后期总量减前期总量），重点分析街道、雪冰、供暖及布鲁克林和皇后区。第一轮主要说明增长来自哪里，对异常日期和地址追查较少。关闭时长指创建至关闭的记录时间差，其业务含义及类别改名的影响尚未确定，未据此判断效率或需求变化。

### 第二轮的工作

第二轮继续查雪冰增长：最高 5 天有 32,819 条请求，占同期 55,230 条的 59.42%。GPT 排除这 5 天，又单独排除雪冰中的 Snow Tracking 子类，检查增长是否集中在这些记录。渠道比较则使用固定的月份、类别和机构权重，减少构成变化的影响；ONLINE（在线渠道）份额仍由 42.5592% 升至 49.3007%，相差 6.7415 个百分点，即两个百分比直接相减。交付遇到 Excel 兼容问题后，它调整生成方式，重新检查公式、图表来源和页面。

| GPT · S 六维得分 |     |       |      |      |
|--------------|-----|-------|------|------|
| 维度           | 满分  | 第一轮   | 第二轮  | 变化   |
| 数据基础         | 15  | 14    | 15   | 1    |
| 证据计算         | 20  | 20    | 20   | 0    |
| 调查判断         | 20  | 14.25 | 20   | 5.75 |
| 人工维护         | 25  | 19.75 | 23.5 | 3.75 |
| 成品可用         | 10  | 10    | 10   | 0    |
| 自主资源         | 10  | 10    | 10   | 0    |
| 现行 S 合计      | 100 | 88    | 98.5 | 10.5 |

表 2 GPT 两轮现行 S 六维得分

## 2.1 GPT 评分依据

数据基础与问题定义 (/15) 14 → 15。核对 44 个字段、记录粒度与同月窗口，第二轮将问题收至峰日和渠道构成。

证据与计算正确性 (/20) 20 → 20。峰日排除、类别排除和固定构成的渠道结果均可回查，两轮得满分。

调查深度与判断 (/20) 14.25 → 20。第一轮主要是增量贡献概览；第二轮补做排除检验与替代解释，达到 20 分。

人工复现与维护 (/25) 19.75 → 23.5。留下 SQL 查询语句、CSV 格式的数据表及六步运行顺序；摘要中的静态数字不会随数据自动更新，维护时仍须逐处核对。

成品实际可用性 (/10) 10 → 10。两轮 Excel 和说明齐全，第二轮有打开、公式及图表检查记录。

### 自主性与资源纪律

自主性与资源纪律两轮均为 10/10，运行中独立完成了任务。第一轮还缺少进一步调查和维护说明；第二轮已补查主要结果与文件显示。更新数据时仍要逐处核对静态摘要，因此更新与错误定位 D4 为 4.5/6。

第二轮补查了峰日和渠道构成，主要文件与结果也经过检查。如果这次任务优先考虑完整交付和较少返工，可优先选用。两轮目录价约 63.91 元，高于

Grok、DeepSeek、GLM、Qwen、Gemini 的费用参考值，低于 Claude 含接续的 165.69 元。GPT 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

### 3 Grok

#### 第一轮的工作

Grok 选取两个各 11 个月的完整比较期，将 346,695 条净增量拆到供暖、雪冰、违停、道路、堵塞车道及其余类别，各项相加与全市增量一致。随后追查雪冰峰日、Street Condition（道路状况）的细分类别和机构关闭时长。它说明了残缺月份、分类变化及近期请求尚未关闭的影响，也没有把系统中的关闭状态直接解释成现实问题已解决。

#### 第二轮的工作

第二轮检查积雪高量日、UNKNOWN（渠道未明确）中的坑洞、供暖集中地块和关闭时长。地块用 BBL 标识，这是税务地块编号，一个地块未必等于一栋建筑。剔除固定的前 10 个地块（Top10）后，供暖请求仍由 263,359 条增至 321,188 条，增长 21.96%。Grok 读回中间表并运行 qa\_verify 检查脚本。评测时重建文件，205 行数据一致；Excel 文件包的 42 个内部部件中，40 个内容完全一致。

| Grok · S 六维得分 |     |       |       |       |
|---------------|-----|-------|-------|-------|
| 维度            | 满分  | 第一轮   | 第二轮   | 变化    |
| 数据基础          | 15  | 15    | 13    | -2    |
| 证据计算          | 20  | 19    | 19    | 0     |
| 调查判断          | 20  | 15.75 | 19.25 | 3.5   |
| 人工维护          | 25  | 17    | 17    | 0     |
| 成品可用          | 10  | 8.5   | 7.75  | -0.75 |
| 自主资源          | 10  | 9.25  | 9.25  | 0     |
| 现行 S 合计       | 100 | 84.5  | 85.25 | 0.75  |

表 3 Grok 两轮现行 S 六维得分

### 3.1 Grok 评分依据

数据基础与问题定义 (/15) 15 → 13。第一轮对齐完整月份；第二轮把 BBL 地块称为建筑，定义出现偏差。

证据与计算正确性 (/20) 19 → 19。互斥增量可以对账；未来关闭时间和类别含义仍需限定。

调查深度与判断 (/20) 15.75 → 19.25。追查雪天、坑洞和供暖集中度，并剔除固定 Top10 地块再比较。

人工复现与维护 (/25) 17 → 17。脚本能够构建文件，但其中一处文件存在检查会始终通过，无法发现文件缺失；维护步骤和检查说明也未补齐。

成品实际可用性 (/10) 8.5 → 7.75。交付文件齐全；第二轮无效断言和终稿表述拉低成品分。

#### 自主性与资源纪律

自主性与资源纪律两轮均为 9.25/10，第二轮用时约 11.71 分钟。本轮补充了调查，调查分由 15.75 升至 19.25；维护说明和最终检查仍有缺口，人工维护维持 17/25。接手时需要补查那处无效的文件检查及更新步骤。

供暖集中度等调查可供参考，接手后要补维护说明、有效检查和部分表述。第二轮 11.71 分钟，比 GPT 快；订阅内用量计价约 9.86 元，两轮合计 16.34 元。Grok 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

## 4 DeepSeek

### 第一轮的工作

DeepSeek 围绕总量变化分析冬季关闭时长、雪冰与坑洞、异常地址、机构差异、渠道和类别名称。固定机构与类型构成后，冬季时长倍数由 3.8667 降到 1.1537；它又排除异常地址重新比较。回查成品时发现，供暖与街道噪音合计混入了住宅噪音，1,533,142 条应为 1,000,893 条；异常地址计数也有错误。部分天气和机构流程解释尚未找到支持材料。

### 第二轮的工作

第二轮检查字段、时间边界、状态、负时长（关闭早于创建）、缺失值及近期末关闭记录，再拆解机构与类别增量。发现 ZIP 10466（邮政编码）和单地址集中后，DeepSeek 继续查其他类别，并比较每批请求创建后 30 天内的关闭比例，使观察时间相同。随后核对程序中的固定数值、DHS（无家可归者服务局）的统计范围和关键表，重建文件并运行 verify 检查脚本。终稿仍写错最大创建时间，即数据中最晚的请求创建时间，总览也有文字未显示完整。

| DeepSeek · S 六维得分 |     |       |       |       |
|-------------------|-----|-------|-------|-------|
| 维度                | 满分  | 第一轮   | 第二轮   | 变化    |
| 数据基础              | 15  | 13.25 | 14    | 0.75  |
| 证据计算              | 20  | 13.75 | 17.5  | 3.75  |
| 调查判断              | 20  | 17.25 | 19.25 | 2     |
| 人工维护              | 25  | 19    | 20.5  | 1.5   |
| 成品可用              | 10  | 5.25  | 6.75  | 1.5   |
| 自主资源              | 10  | 8     | 9.25  | 1.25  |
| 现行 S 合计           | 100 | 76.5  | 87.25 | 10.75 |

表 4 DeepSeek 两轮现行 S 六维得分

## 4.1 DeepSeek 评分依据

数据基础与问题定义 (/15) 13.25 → 14。检查分片、状态与观察窗口，第二轮进一步统一地址与 ZIP 口径。

证据与计算正确性 (/20) 13.75 → 17.5。第一轮把住宅噪音错并进供暖与街道噪音；第二轮仍写错最大创建时间。

调查深度与判断 (/20) 17.25 → 19.25。异常地址、邮编、关闭方式与固定 30 天观察互相对照。

人工复现与维护 (/25) 19 → 20.5。保留 23 份 CSV 和检查记录，部分入口和说明仍需整理。

成品实际可用性 (/10) 5.25 → 6.75。调查结果有用；第二轮总览截字及终稿时间错误仍影响直接使用。

### 自主性与资源纪律

自主性与资源纪律由 8 升至 9.25/10。第一轮同类数据框错误连续出现，第二轮这类返工减少。两轮总分分别为 76.5 和 87.25：地址和观察窗口调查更充分了，终稿时间错误和总览显示问题仍在，因此成品得 6.75/10，使用前需要修订。

第二轮留下了较深入的地址和观察窗口调查，估算费用较低。采用前仍要修正终稿时间和显示问题，并回查所引用的结果；第一轮类别错配也说明，主要合计数需要逐项核对。

DeepSeek 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

## 5 GLM

### 第一轮的工作

GLM 逐个文件汇总总量、季节变化、道路异常、机构时长、地区和渠道。道路调查从 Street Condition 月度变化继续查到 Pothole（坑洞）、Cave-in（路面塌陷）、DOT（交通局）受理、日期和五区分布，其他方向主要是汇总比较。它注意到近期请求的关闭观察时间较短，但对 DOHMH（卫生与心理健康局）流程和新旧类别关系的解释仍缺支持材料。

### 第二轮的工作

第二轮检查字段、分布、负时长和季节性后，增加同比类型增量分解，继续调查住宅噪声、热点地址、供暖季和关闭时长。GLM 修正月均值与关闭率所用的月份数，修改生成脚本，再复算聚合表、检查图表和月表。核查热点结果时发现，地址前缀筛选还纳入了其他街道和投诉类型，原文将其解释为两个地址的住宅噪声，范围对不上。这个专题仍需重新界定后计算。

| GLM · S 六维得分 |     |       |       |      |
|--------------|-----|-------|-------|------|
| 维度           | 满分  | 第一轮   | 第二轮   | 变化   |
| 数据基础         | 15  | 12.25 | 13.25 | 1    |
| 证据计算         | 20  | 15.25 | 16.25 | 1    |
| 调查判断         | 20  | 12.5  | 17.75 | 5.25 |
| 人工维护         | 25  | 18    | 17    | -1   |
| 成品可用         | 10  | 6.75  | 7.5   | 0.75 |
| 自主资源         | 10  | 9.25  | 9.25  | 0    |
| 现行 S 合计      | 100 | 74    | 81    | 7    |

表 5 GLM 两轮现行 S 六维得分

## 5.1 GLM 评分依据

数据基础与问题定义 (/15) 12.25 → 13.25。覆盖全量数据并收至道路与热点问题；第二轮问题界定略有改善。

证据与计算正确性 (/20) 15.25 → 16.25。547 条 Closed 子集负时长统计正确；热点前缀的实际纳入范围未讲清。

调查深度与判断 (/20) 12.5 → 17.75。第二轮补做类型增量、热点与观察窗口，调查分提高 5.25。

人工复现与维护 (/25) 18 → 17。专题增加后，聚合前置步骤未纳入完整复现入口，维护分下降。

成品实际可用性 (/10) 6.75 → 7.5。交付速度快；热点定义和部分表头仍需改正。

### 自主性与资源纪律

自主性与资源纪律两轮均为 9.25/10，第二轮约 9.59 分钟、目录价 6.48 元。这轮新增的调查使调查分从 12.5 升至 17.75，但说明未完整交代聚合前置步骤，维护分由 18 降至 17。复核还确认，547 条 Closed（已关闭）状态负时长的统计是正确的。

第二轮 9.59 分钟、目录价约 6.48 元，比 GPT 省时省费。若采用这份成果，需要先重新界定热点范围、重算相关结果，并补齐维护步骤；GLM 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

## 6 Qwen

### 第一轮的工作

Qwen 比较总量、类别、地区和关闭时长，识别道路异常与分类变化，提交 Excel 和说明。第一轮对异常追查较少。回查 Drug Activity（涉毒活动请求类别）的描述时，在相同 11 个月内，室内描述占比由约 8% 升至 31%，与报告所写的“结构未变”不符。这里的结构指不同描述所占比例，需先修正这一判断，再解释该类请求的变化。

### 第二轮的工作

第二轮补查字段、唯一编号、缺失值、状态及时间异常，再拆解类别增量、行政区与渠道。Qwen 追查噪声尖峰、地点分布和违停结构，也检查分类变化与 Drug Activity。交付时多次修改标签和统计范围，读回文件并核对图表、说明及重算结果。评测时发现关闭时长仍用 11 个月与 9 个月比较；统一月份后，UNSANITARY（不卫生状况类别）增幅约 12.6%，低于原文约 18.2%。

| Qwen · S 六维得分 |     |       |       |       |
|---------------|-----|-------|-------|-------|
| 维度            | 满分  | 第一轮   | 第二轮   | 变化    |
| 数据基础          | 15  | 10.25 | 14.25 | 4     |
| 证据计算          | 20  | 15.25 | 12.75 | -2.5  |
| 调查判断          | 20  | 8.75  | 14.75 | 6     |
| 人工维护          | 25  | 18    | 19    | 1     |
| 成品可用          | 10  | 6.75  | 6.75  | 0     |
| 自主资源          | 10  | 8.5   | 7.75  | -0.75 |
| 现行 S 合计       | 100 | 67.5  | 75.25 | 7.75  |

表 6 Qwen 两轮现行 S 六维得分

## 6.1 Qwen 评分依据

数据基础与问题定义 (/15) 10.25 → 14.25。第二轮补查唯一键、状态、缺失与时间异常，问题界定改善。

证据与计算正确性 (/20) 15.25 → 12.75。第一轮称 Drug Activity 描述结构未变；第二轮关闭时长用了 11 个月对 9 个月。

调查深度与判断 (/20) 8.75 → 14.75。第二轮扩至五项调查，增量与异常检查增加；主要时长比较仍须重做。

人工复现与维护 (/25) 18 → 19。九张工作表和十五张图可查，重建与复现材料仍需统一口径。

成品实际可用性 (/10) 6.75 → 6.75。正文、图表与比较时间窗未完全同步，两轮均为 6.75。

### 自主性与资源纪律

自主性与资源纪律由 8.5 降至 7.75/10。第二轮约 60.21 分钟、目录价 14.33 元，较多时间用于重建和检查文件。总分从 67.5 升至 75.25，但前述时间窗口问题尚未解决，接手后要重做主要时长比较，并同步修改图表和正文。

第二轮耗时 60.21 分钟、目录价约 14.33 元，均高于 GLM。两轮分别留下描述结构和时间窗口错误，主要比较还要重做。就这次个人使用而言，这次不再继续投入重试。Qwen 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

## 7 Gemini

### 第一轮的工作

Gemini 第一轮调查异常地址、供暖分布、违停与噪声时段、机构处置时长，并提出治理建议。回查地址表时，缺失地址被合并成了一个高频地址；每万人口的请求数也被算成实际的十分之一。再读解释部分，报告把聚集请求当作真实事件、把空间差异归于阶层差异，并据结案描述评价部门效能。这些解释缺少进一步证据，现有统计不足以支持相应建议。

### 第二轮的工作

第二轮核对日期、字段和异常计数，再拆解部门与类别增量，调查道路、DEP（环境保护局）、供暖集中度、空间及处置结果。Gemini 也检查近期未关闭记录、分类变化和生成文件。回查结案原句时，arrest（拘捕）命中 95,943 条，其中 95,784 条是否定表述，肯定仅 159 条。原文没有区分“未拘捕”等否定含义，用命中数量支持拘捕解释，结论需要重写。

| Gemini · S 六维得分 |     |       |       |      |
|-----------------|-----|-------|-------|------|
| 维度              | 满分  | 第一轮   | 第二轮   | 变化   |
| 数据基础            | 15  | 5.75  | 10.5  | 4.75 |
| 证据计算            | 20  | 6.5   | 10.5  | 4    |
| 调查判断            | 20  | 5.75  | 11.25 | 5.5  |
| 人工维护            | 25  | 10.75 | 14.25 | 3.5  |
| 成品可用            | 10  | 4.25  | 6     | 1.75 |
| 自主资源            | 10  | 6.5   | 7     | 0.5  |
| 现行 S 合计         | 100 | 39.5  | 59.5  | 20   |

表 7 Gemini 两轮现行 S 六维得分

## 7.1 Gemini 评分依据

数据基础与问题定义 (/15) 5.75 → 10.5。第一轮把缺失地址合成高频地址，每万人口的请求数算成实际的十分之一；第二轮有所改善。

证据与计算正确性 (/20) 6.5 → 10.5。第二轮 arrest 命中 95943 条，其中 95784 条是否定表述；肯定仅 159 条。

调查深度与判断 (/20) 5.75 → 11.25。增长分解和集中度检查增多，但治理原因仍超出记录可支持范围。

人工复现与维护 (/25) 10.75 → 14.25。维护入口有所改善，关键文本与口径仍需人工复核。

成品实际可用性 (/10) 4.25 → 6。两轮都有工作簿，最终解释错误使成品不能直接用于决策。

### 自主性与资源纪律

自主性与资源纪律由 6.5 升至 7/10。运行记录中仍有搜索项目根目录、暴露其他目录路径的行为。两轮总分为 39.5 和 59.5；第二轮补充了增长分解和维护入口，但结案文本的误读仍影响主要解释，需在采用结果前处理。

两轮都有可回查的汇总结果，主要治理解释仍需重做。第二轮用时 6.07 分钟，但读回结案原句后发现的语义错误会改变相关结论，因此本次暂不采用其政策、人口或执法建议。Gemini 的 25 项评分与原件位置见 Excel“评分与用量”的 S 分项。

## 8 Claude

### 第一轮的调查与交付

Claude 核对数据范围，调查高频地址、增长来源、类别、关闭时长、结案原句和重复记录，保存 30 张中间表、生成 13 个工作表。它按“同一地址、同一类别单日不少于 200 条”筛出 4 个住宅噪声组合，共 185,791 条，再比较剔除前后的趋势；用日均值处理 365 天与 364 天的差异，并检查已有足够时间观察关闭结果的请求批次（成熟队列）、机构时长及 NYPD（警察局）结案描述。接管前留下 15 份脚本和 34 页预览。高频记录为何要全部剔除，仍缺充分依据。

Claude 第一轮已完成主体调查、汇总、Excel 和说明。Cursor 额度用尽后，Grok 订正说明中的数字、重建并检查成品；这段接续工作单列。Claude 第二轮未运行。Claude 阶段订阅额度内计价 153.57 元，含 Grok 接续共 165.69 元。

| Claude · S 六维得分 |     |       |     |    |
|-----------------|-----|-------|-----|----|
| 维度              | 满分  | 第一轮   | 第二轮 | 变化 |
| 数据基础            | 15  | 11.25 | —   | —  |
| 证据计算            | 20  | 15.25 | —   | —  |
| 调查判断            | 20  | 15.75 | —   | —  |
| 人工维护            | 25  | 18.25 | —   | —  |
| 成品可用            | 10  | 6     | —   | —  |
| 自主资源            | 10  | 5.5   | —   | —  |
| 现行 S 合计         | 100 | 72    | —   | —  |

表 8 Claude 第一轮现行 S 六维得分

## 8.1 Claude 评分依据

数据基础与问题定义 (/15) 11.25。核查全量范围和高频地址，但将聚集记录直接视作无效样本欠妥。

证据与计算正确性 (/20) 15.25。30 张汇总表中 28 张可重做一致，另两张存在标签或口径差异。

调查深度与判断 (/20) 15.75。调查增长、地址、成熟队列和结案文本，接管前形成主要分析。

人工复现与维护 (/25) 18.25。15 份正式脚本可追溯到 Claude；末次订正与重建由 Grok 完成。

成品实际可用性 (/10) 6。已有 13 表 13 图 Excel 及预览；关键筛选和交付一致性仍需核查。

### 自主性与资源纪律

自主性与资源纪律为 5.5/10。Claude 阶段订阅额度计价 153.57 元，后续由 Grok 接续，合计 165.69 元。按接管前材料核查，第一轮总分 72：原脚本重做 30 张中间表，其中 28 张一致，另两张有标签或口径差异；高频记录剔除、集中出现的一组记录及天气解释还需补证据。最后的数字订正和重建由 Grok 完成。

## 9 Kimi

### 第一轮为何退出

Kimi 第一轮多次提前结束，依赖人工催促，随后退出。现存记录不足以核出完整耗时、Token 及费用；目录中也没有必交 Excel 和分析说明，状态按“退出”保留。

### 第二轮补充复测

第二轮先遇到启动器故障，当时模型尚未启动，另行登记。实际启动后，Kimi 反复读取 data\_manifest.json 输入文件清单；工具已提示文件未变化、重复读取没有收益，它仍未调整做法。评测方停止循环，未得到 Excel 或分析说明。

实际复测约 2.65 分钟，目录价估算 1.48 元。去掉计划、进度等管理动作后，共有 14 个处理任务的实质动作，其中 13 个被判为没有收益。Token 指模型处理文字时使用的计量单位，不能直接当作字数；第一轮这类用量记录不完整。

### 评分处理

两轮均缺少完整成品，不具备 25 项逐项评分所需的分析和交付材料；S 留空，不把失败填为 0 分。

第一轮退出、第二轮重复读取后停止，都是本次尝试的实际结果。因此，比较表中保留这两轮状态及已记录的资源使用，评分位置留空。

在本次 Claude Code 组合和两轮机会内，Kimi 未交付可用成果；收到重复读取提示后，也未调整做法。就这次个人使用而言，已有时间、费用和催促记录不足以支持继续付费重试。

10 成果质量与可维护性比较

| 第1轮 现行 S 六维 |         |         |         |         |         |         |        |     |
|-------------|---------|---------|---------|---------|---------|---------|--------|-----|
| AI          | 数据基础/15 | 证据计算/20 | 调查判断/20 | 人工维护/25 | 成品可用/10 | 自主资源/10 | 合计/100 | 状态  |
| GPT         | 14      | 20      | 14.25   | 19.75   | 10      | 10      | 88     | 已完成 |
| Grok        | 15      | 19      | 15.75   | 17      | 8.5     | 9.25    | 84.5   | 已完成 |
| DeepSeek    | 13.25   | 13.75   | 17.25   | 19      | 5.25    | 8       | 76.5   | 已完成 |
| GLM         | 12.25   | 15.25   | 12.5    | 18      | 6.75    | 9.25    | 74     | 已完成 |
| Qwen        | 10.25   | 15.25   | 8.75    | 18      | 6.75    | 8.5     | 67.5   | 已完成 |
| Gemini      | 5.75    | 6.5     | 5.75    | 10.75   | 4.25    | 6.5     | 39.5   | 已完成 |
| Claude      | 11.25   | 15.25   | 15.75   | 18.25   | 6       | 5.5     | 72     | 已完成 |
| Kimi        | —       | —       | —       | —       | —       | —       | —      | 未评分 |

表 9 第一轮现行 S 六维得分

| 第2轮 现行 S 六维 |         |         |         |         |         |         |        |     |
|-------------|---------|---------|---------|---------|---------|---------|--------|-----|
| AI          | 数据基础/15 | 证据计算/20 | 调查判断/20 | 人工维护/25 | 成品可用/10 | 自主资源/10 | 合计/100 | 状态  |
| GPT         | 15      | 20      | 20      | 23.5    | 10      | 10      | 98.5   | 已完成 |
| Grok        | 13      | 19      | 19.25   | 17      | 7.75    | 9.25    | 85.25  | 已完成 |
| DeepSeek    | 14      | 17.5    | 19.25   | 20.5    | 6.75    | 9.25    | 87.25  | 已完成 |
| GLM         | 13.25   | 16.25   | 17.75   | 17      | 7.5     | 9.25    | 81     | 已完成 |
| Qwen        | 14.25   | 12.75   | 14.75   | 19      | 6.75    | 7.75    | 75.25  | 已完成 |
| Gemini      | 10.5    | 10.5    | 11.25   | 14.25   | 6       | 7       | 59.5   | 已完成 |
| Claude      | —       | —       | —       | —       | —       | —       | —      | 未运行 |
| Kimi        | —       | —       | —       | —       | —       | —       | —      | 未评分 |

表 10 第二轮现行 S 六维得分

## 10.1 六维差异与同分异因

先看数据范围和字段理解。GPT 第二轮的数据基础 A 为 15/15，DeepSeek 与 Qwen 分别为 14 和 14.25，Grok 为 13，Gemini 由 5.75 升至 10.5。检查范围较完整的成品也可能误解字段：Grok 把 BBL 地块写成建筑，Gemini 第一轮把缺失地址合并为一个地址，相应问题都计入这一维度。

沿着这些定义继续核对计算，Qwen 第二轮的时长比较用了 11 个月对 9 个月，Gemini 把 arrest 否定表述算入肯定解释，DeepSeek 第一轮则混入了错误类别。这些问题直接影响结论。证据计算 B 中，GPT 两轮均 20/20；第二轮

Grok19、DeepSeek17.5、GLM16.25、Qwen12.75、Gemini10.5。

再看系统是否沿着异常继续查。六系统调查判断 C 的均值由 12.38 升至 17.04，增加 4.67 分，约占总增量 49.3%。GPT 第二轮排除峰日、固定构成，得到 20/20；Grok 与 DeepSeek 进一步查地块和地址，均为 19.25。GLM 增加了热点调查，但筛选范围有混入，还需回到原始记录核对。

接着尝试按提交说明重做和更新结果。GPT 第二轮人工维护 D 为

23.5/25，DeepSeek20.5、Qwen19、GLM 与 Grok 各 17、Gemini14.25。差异主要出在具体步骤：Grok 一处文件检查始终通过，GLM 漏写新增专题的聚合前置步骤，Qwen 则需要先修正时间窗口再重做结果。

最后检查文件能否阅读，以及运行和接手过程还留下哪些问题。GPT 第二轮成品 E 与自主性 F 均为 10；DeepSeek 虽做了较深调查，终稿时间错误和总览截字使 E 为 6.75。Grok 的 E 为 7.75。Gemini 的 E 与 F 分别为 6 和 7，仍需修正结案解释并处理运行中的目录访问问题。

Grok85.25 与 DeepSeek87.25 相差 2 分，前者主要缺维护说明和有效检查，后者还要订正终稿时间与显示。GLM81 与 Qwen75.25 也各有问题：GLM 需重定热点范围，Qwen 需重做关键时长比较。

## 11 人工维护与自主性比较

| 第1轮 人工维护、成品与自主性 |       |       |       |       |
|-----------------|-------|-------|-------|-------|
| AI              | 维护/25 | 成品/10 | 自主/10 | S/100 |
| GPT             | 19.75 | 10    | 10    | 88    |
| Grok            | 17    | 8.5   | 9.25  | 84.5  |
| DeepSeek        | 19    | 5.25  | 8     | 76.5  |
| GLM             | 18    | 6.75  | 9.25  | 74    |
| Qwen            | 18    | 6.75  | 8.5   | 67.5  |
| Gemini          | 10.75 | 4.25  | 6.5   | 39.5  |
| Claude          | 18.25 | 6     | 5.5   | 72    |
| Kimi            | —     | —     | —     | —     |

表 11 第一轮人工维护、成品与自主性

| 第2轮 人工维护、成品与自主性 |       |       |       |       |
|-----------------|-------|-------|-------|-------|
| AI              | 维护/25 | 成品/10 | 自主/10 | S/100 |
| GPT             | 23.5  | 10    | 10    | 98.5  |
| Grok            | 17    | 7.75  | 9.25  | 85.25 |
| DeepSeek        | 20.5  | 6.75  | 9.25  | 87.25 |
| GLM             | 17    | 7.5   | 9.25  | 81    |
| Qwen            | 19    | 6.75  | 7.75  | 75.25 |
| Gemini          | 14.25 | 6     | 7     | 59.5  |
| Claude          | —     | —     | —     | —     |
| Kimi            | —     | —     | —     | —     |

表 12 第二轮人工维护、成品与自主性

人工维护的差别出现在交接时：GPT 留下输入、SQL、结果和更新顺序，第二轮 D 为 23.5；Grok 两轮均 17，脚本中一处文件存在检查始终通过且缺维护说明；GLM 第二轮新增热点专题后 D 从 18 降到 17，聚合前置步骤没有完整交代。

Claude 接管前 D 为 18.25，原脚本重做 28/30 张中间表一致，剩余两表存在标签或口径差异。Grok 接续的数字订正与重建不能记作 Claude 自行修好。Kimi 两轮没有成品，维度留空，但人工催促和读取循环属于明确的使用负担。

第二轮六系统运行期间均没有追加指令，交付后却仍登记了 10 项修正。自主性 F 中，GPT 为 10，Grok、DeepSeek、GLM 均为 9.25，Qwen7.75，Gemini7。这里的分数连同修正记录一起阅读，才能看清运行中需要多少介入，以及收到文件后还要做什么。

## 12 两轮变化

| 六系统配对 · 现行 S 平均变化 |    |       |       |      |
|-------------------|----|-------|-------|------|
| 维度                | 满分 | 第一轮   | 第二轮   | 增量   |
| 数据基础              | 15 | 11.75 | 13.33 | 1.58 |
| 证据计算              | 20 | 14.96 | 16    | 1.04 |
| 调查判断              | 20 | 12.38 | 17.04 | 4.67 |
| 人工维护              | 25 | 17.08 | 18.54 | 1.46 |
| 成品可用              | 10 | 6.92  | 7.46  | 0.54 |
| 自主资源              | 10 | 8.58  | 8.75  | 0.17 |

表 13 六系统现行 S 六维平均变化

将同样六个系统的两轮结果放在一起，S 均值由 71.67 升至 81.13，增加 9.46 分。各自变化为 GPT+10.5、Grok+0.75、DeepSeek+10.75、GLM+7、Qwen+7.75、Gemini+20。Gemini 增加最多，第二轮仍为 59.5 分，前文发现的文本解释问题尚未解决，后续还需结合分项查看。

拆开总分后，六维平均增量为 A+1.58、B+1.04、C+4.67、D+1.46、E+0.54、F+0.17。调查判断 C 约占一半，维护 D 和成品 E 的变化较小。结合各系统的提交材料，可以看到第二轮普遍增加了异常追查和对照计算，维护说明与终稿检查补充得较少。

Qwen 第二轮增加五项调查与图表，S 从 67.5 升至 75.25，主要时长比较仍用了不同月份。GLM 增加热点专题后，C 由 12.5 升至 17.75，但未补齐聚合前置说明，D 由 18 降至 17。这两份提交都增加了调查内容，同时留下了需要接手处理的具体问题。

GPT 第二轮围绕峰日和固定构成补查，调查判断得 20 分，人工维护 23.5 分，成品与自主性均为满分。结合原运行中的成品检查和核心结论核查，只有这一轮满足第 1.2 节列出的全部参照条件。

### 12.1 评分变化与实际动作

逐项回看，GPT 补了峰日排除与固定构成，Grok 剔除固定 Top10 地块，DeepSeek 加入地址与 30 天观察窗，GLM 增加增量和热点分析，Qwen 扩展调查，Gemini 增加贡献分解。调查分记录这些工作的完成程度；计算错误及成品中的解释问题，继续记在证据计算 B 和成品 E 的对应细项中。

13 耗时、费用与后续修正

| 第二轮交付与资源指标 |       |       |           |    |     |
|------------|-------|-------|-----------|----|-----|
| AI         | S/100 | 分钟    | 费用参考/元    | 修正 | 状态  |
| GPT        | 98.5  | 17.78 | 38.96     | 0  | 已完成 |
| Grok       | 85.25 | 11.71 | 9.86      | 1  | 已完成 |
| DeepSeek   | 87.25 | 21.7  | 1.37-2.74 | 1  | 已完成 |
| GLM        | 81    | 9.59  | 6.48      | 1  | 已完成 |
| Qwen       | 75.25 | 60.21 | 14.33     | 2  | 已完成 |
| Gemini     | 59.5  | 6.07  | 5.12      | 5  | 已完成 |
| Kimi       | —     | 2.65  | 1.48      | 0  | 失败  |
| Claude     | —     | —     | —         | —  | 未运行 |

表 14 第二轮交付与资源指标




图 1 第二轮原生耗时




图 2 第二轮费用参考值

第二轮费用参考值：GLM 目录价 6.48 元，GPT38.96 元，DeepSeek 按忙时、闲时单价列为 1.37—2.74 元，Qwen14.33 元；均按记录用量与公开单价估算。Grok 的 9.86 元是 Cursor 订阅额度消耗。Gemini 的 5.12 元则把 Token 用量按相应 API 单价折算，称为 Token 等价费用；API 指软件调用模型的接口。上述金额计价方式不同，均不直接等于本次现金扣款。

耗时从各轮运行记录取得：GLM9.59 分钟、GPT17.78、Grok11.71、DeepSeek21.70、Qwen60.21、Gemini6.07。GLM 的热点定义、DeepSeek 的终稿时间仍需修正；这些接手工作没有计入模型运行耗时。

13.1 无收益动作与后续修正




图3 第二轮无收益动作占比

图中 AWR 是无收益动作占比：确认无收益的动作数，除以实质动作数。实质动作包括直接推进交付、必要探索和确认无收益三类，计划或进度管理动作不计入分母；必要探索即使未进入终稿也不直接算浪费。六系统第二轮共 300 个实质动作，5 个确认无收益。Qwen 与 Gemini 这一比例均为 0，成品仍有 2 项和 5 项修正。

六系统第二轮运行期间均无追加指令。交后修正共 10 项，涉及类别和对象定义、比较窗口、数字转述、文本语义及原因解释。GPT 为 0；Grok、DeepSeek、GLM 各 1；Qwen2；Gemini5。

这些修正的工作量也不同。GLM 的字段数可以局部订正，热点定义则影响专题取数；Gemini 要按否定语境重查结案文本，Qwen 要统一时间窗口后重做比较。项目没有记录逐动作耗时和实际人工修正分钟，因此这里只列需要做的工作，不将任务数换算为人工工时。

个人选择时，除表中的时间与费用，还需要判断自己能否处理相应问题。例如，采用 Qwen 的时长结论前，要先完成窗口统一和重算；这部分投入尚未计入运行价格。

## 14 研究结论

回到开头的问题：这次给出相同数据、最多运行两轮后，六系统留下了两轮可评分成果，第二轮平均 81.13 分；Claude 第一轮由 Grok 接续，Kimi 两轮未形成成品。按前述检查和参照条件，GPT 第二轮达到要求。结论限于本次任务与运行条件。

### 14.1 独立交付与接管

GPT 第二轮已完成可供人接手的分析链，且未登记交后修正。Grok、DeepSeek、GLM 在无追加指令下完成成品，但交接或终稿仍需局部补查。Claude 第一轮主体工作已有价值，后段接管是实际使用成本；Kimi 在两轮内没有完成。

### 14.2 成果差距在哪里

前文逐项核查后，GPT 第二轮证据计算为 20/20、调查 20/20、维护 23.5/25，主要结果可回查，也留下了对照计算和更新顺序。Grok 与 DeepSeek 的调查同样有内容，但地块定义、维护检查、终稿时间或显示仍需补正。Qwen 的时间窗口和 Gemini 的文本语义则影响主要结论，采用前需要重做相应部分。

### 14.3 第二轮改善了什么

两轮之间，六系统平均增加 9.46 分，其中调查深度增加 4.67 分，维护增加 1.46 分、成品增加 0.54 分。从已有文件能看到调查更深入了，交接和终稿问题仍较集中。由于第二轮提示、自身调整及运行环境可能共同影响结果，而且各条件仅运行一次，本次无法分离方法提示带来的具体贡献。

## 14.4 各系统综合评价

**GPT** 第二轮补查了峰日和渠道构成，主要文件与结果也经过检查。如果这次任务优先考虑完整交付和较少返工，可优先选用。两轮目录价约 63.91 元，高于

Grok、DeepSeek、GLM、Qwen、Gemini 的费用参考值，低于 Claude 含接续的 165.69 元。

**Grok** 供暖集中度等调查可供参考，接手后要补维护说明、有效检查和部分表述。第二轮 11.71 分钟，比 GPT 快；订阅内用量计价约 9.86 元，两轮合计 16.34 元。

**DeepSeek** 第二轮留下了较深入的地址和观察窗口调查，估算费用较低。采用前仍要修正终稿时间和显示问题，并回查所引用的结果；第一轮类别错配也说明，主要合计数需要逐项核对。

**GLM** 第二轮 9.59 分钟、目录价约 6.48 元，比 GPT 省时省费。若采用这份成果，需要先重新界定热点范围、重算相关结果，并补齐维护步骤；

**Qwen** 第二轮耗时 60.21 分钟、目录价约 14.33 元，均高于 GLM。两轮分别留下描述结构和时间窗口错误，主要比较还要重做。就这次个人使用而言，这次不再继续投入重试。

**Gemini** 两轮都有可回查的汇总结果，主要治理解释仍需重做。第二轮用时 6.07 分钟，但读回结案原句后发现的语义错误会改变相关结论，因此本次暂不采用其政策、人口或执法建议。

**Claude** 接管前已完成较多调查和大部分交付，高频记录剔除及部分解释仍缺依据。Claude 阶段订阅额度计价 153.57 元，连同 Grok 接续共 165.69 元。在本次任务中，费用和接续工作都较多，个人使用暂不优先选用。

**Kimi** 两轮未获得可用交付，且已有时间、费用和人工催促记录。在本次工具组合下，暂不追加付费重试。

## 附录 评分明细与资料说明

本报告使用 v2.2 评分标准，对已保存的参赛成果逐项复核。“现行 S”指本次使用的自主交付总分。共 325 条评分依据在 Excel“评分与用量”的 S 分项中，得分批注附实际工作、缺口和原件位置，K 列编号可到“查证.html”查询。编号由组别和序号组成，如 D5 就是 D 组第 5 项。

表中“14→15”依次表示第一轮 14 分、第二轮 15 分，“/15”表示该组满分 15 分；变化等于第二轮减第一轮。六系统配对均值只对两轮都有评分的同样六个系统求平均。Claude 第二轮及 Kimi 两轮留空，空白不参与平均，也不按 0 分处理。Excel“评分细项”用 AI 下拉查看，“分维度比较”可选轮次、得分或得分率；得分率是得分除以该项满分。

A 组看数据和选题：A1 是否理解一条记录、字段和单位；A2 是否处理会影响结论的数据问题；A3 问题能否由已有数据回答；A4 是否有理由优先调查这些问题。

B 组看结果是否成立：B1 数字、筛选及分子分母是否正确；B2 比较的时间和对象是否可比；B3 能否从结论找到输入、计算和结果；B4 解释是否符合字段和原始记录。

C 组看调查怎样继续：C1 把总体差异拆到具体来源；C2 沿异常查到日期、类别、地点或记录；C3 改变筛选或加入对照后检查结论是否仍成立，并检查其他解释；C4 发现矛盾后核查并同步修改；C5 适时停止证据不足的方向，保留尚未解决的问题。

D 组看接手所需材料：D1 能否找到阅读入口与执行步骤；D2 能否理解处理和计算中的选择；D3 能否按现有材料重做主要结果；D4 能否更新数据、定位错误并核对受影响内容；D5 原 AI 是否检查过最终成品。

E 组看最终文件：E1 能否找到答案并完成比较；E2 文字、图表和筛选是否显示正常；E3 各文件是否一致，声称完成的工作是否实际留下。F 组看运行与负担：F1 是否需要指导或接管；F2 交付后还需修正哪些问题；F3 遇到失败能否调整做法；F4 是否复用已有结果、减少无效计算并清理自建应用。

原始参赛作品保留在各系统目录，输入清单在 input/data\_manifest.json。人维护的代表任务由 AI 辅助审读和执行；本项目未观察真人实际操作。

本评测仅由一名评审给分，没有测量评审间一致性，也没有记录人工监督或修正工时。

附表 1 GPT 评分细项

| GPT   S 评分细项                  |          |    |      |     |      |    |           |    |      |     |      |
|-------------------------------|----------|----|------|-----|------|----|-----------|----|------|-----|------|
| 编号                            | 评分项      | 满分 | 第一轮  | 第二轮 | 差    | 编号 | 评分项       | 满分 | 第一轮  | 第二轮 | 差    |
| A1                            | 粒度与语义    | 4  | 4    | 4   | 0    | D1 | 阅读入口与步骤   | 4  | 4    | 4   | 0    |
| A2                            | 数据质量判断   | 4  | 4    | 4   | 0    | D2 | 过程可理解     | 6  | 4.5  | 6   | 1.5  |
| A3                            | 问题可回答性   | 3  | 3    | 3   | 0    | D3 | 结果可重做     | 6  | 6    | 6   | 0    |
| A4                            | 问题优先级    | 4  | 3    | 4   | 1    | D4 | 更新与错误定位   | 6  | 3    | 4.5 | 1.5  |
| B1                            | 数字与口径    | 6  | 6    | 6   | 0    | D5 | 原AI的成品检查  | 3  | 2.25 | 3   | 0.75 |
| B2                            | 可比性      | 5  | 5    | 5   | 0    | E1 | 阅读与比较     | 4  | 4    | 4   | 0    |
| B3                            | 来源链      | 5  | 5    | 5   | 0    | E2 | 画面与交互     | 3  | 3    | 3   | 0    |
| B4                            | 解释成立     | 4  | 4    | 4   | 0    | E3 | 文件一致与完成声明 | 3  | 3    | 3   | 0    |
| C1                            | 差异分解     | 4  | 4    | 4   | 0    | F1 | 原运行独立性    | 3  | 3    | 3   | 0    |
| C2                            | 下钻调查     | 4  | 2    | 4   | 2    | F2 | 交后修正负担    | 3  | 3    | 3   | 0    |
| C3                            | 稳健性与替代解释 | 5  | 1.25 | 5   | 3.75 | F3 | 失败处理      | 2  | 2    | 2   | 0    |
| C4                            | 据证据修正    | 4  | 4    | 4   | 0    | F4 | 资源使用      | 2  | 2    | 2   | 0    |
| C5                            | 范围与停止    | 3  | 3    | 3   | 0    |    |           |    |      |     |      |
| 现行 S： 第一轮 88 第二轮 98.5 变化 10.5 |          |    |      |     |      |    |           |    |      |     |      |

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 15 GPT 现行 S 25 项得分

附表 2 Grok 评分细项

| Grok   S 评分细项 |          |    |      |      |     |    |           |    |      |      |       |
|---------------|----------|----|------|------|-----|----|-----------|----|------|------|-------|
| 编号            | 评分项      | 满分 | 第一轮  | 第二轮  | 差   | 编号 | 评分项       | 满分 | 第一轮  | 第二轮  | 差     |
| A1            | 粒度与语义    | 4  | 4    | 3    | -1  | D1 | 阅读入口与步骤   | 4  | 2    | 2    | 0     |
| A2            | 数据质量判断   | 4  | 4    | 3    | -1  | D2 | 过程可理解     | 6  | 4.5  | 4.5  | 0     |
| A3            | 问题可回答性   | 3  | 3    | 3    | 0   | D3 | 结果可重做     | 6  | 6    | 6    | 0     |
| A4            | 问题优先级    | 4  | 4    | 4    | 0   | D4 | 更新与错误定位   | 6  | 3    | 3    | 0     |
| B1            | 数字与口径    | 6  | 6    | 6    | 0   | D5 | 原AI的成品检查  | 3  | 1.5  | 1.5  | 0     |
| B2            | 可比性      | 5  | 5    | 5    | 0   | E1 | 阅读与比较     | 4  | 4    | 4    | 0     |
| B3            | 来源链      | 5  | 5    | 5    | 0   | E2 | 画面与交互     | 3  | 1.5  | 1.5  | 0     |
| B4            | 解释成立     | 4  | 3    | 3    | 0   | E3 | 文件一致与完成声明 | 3  | 3    | 2.25 | -0.75 |
| C1            | 差异分解     | 4  | 4    | 4    | 0   | F1 | 原运行独立性    | 3  | 3    | 3    | 0     |
| C2            | 下钻调查     | 4  | 3    | 4    | 1   | F2 | 交后修正负担    | 3  | 2.25 | 2.25 | 0     |
| C3            | 稳健性与替代解释 | 5  | 2.5  | 5    | 2.5 | F3 | 失败处理      | 2  | 2    | 2    | 0     |
| C4            | 据证据修正    | 4  | 4    | 4    | 0   | F4 | 资源使用      | 2  | 2    | 2    | 0     |
| C5            | 范围与停止    | 3  | 2.25 | 2.25 | 0   |    |           |    |      |      |       |

现行 S：第一轮 84.5 第二轮 85.25 变化 0.75

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 16 Grok 现行 S 25 项得分

附表 3 DeepSeek 评分细项

| DeepSeek   S 评分细项                 |          |    |      |      |      |    |           |    |      |      |      |
|-----------------------------------|----------|----|------|------|------|----|-----------|----|------|------|------|
| 编号                                | 评分项      | 满分 | 第一轮  | 第二轮  | 差    | 编号 | 评分项       | 满分 | 第一轮  | 第二轮  | 差    |
| A1                                | 粒度与语义    | 4  | 4    | 4    | 0    | D1 | 阅读入口与步骤   | 4  | 4    | 4    | 0    |
| A2                                | 数据质量判断   | 4  | 3    | 3    | 0    | D2 | 过程可理解     | 6  | 4.5  | 4.5  | 0    |
| A3                                | 问题可回答性   | 3  | 2.25 | 3    | 0.75 | D3 | 结果可重做     | 6  | 6    | 6    | 0    |
| A4                                | 问题优先级    | 4  | 4    | 4    | 0    | D4 | 更新与错误定位   | 6  | 3    | 4.5  | 1.5  |
| B1                                | 数字与口径    | 6  | 3    | 4.5  | 1.5  | D5 | 原AI的成品检查  | 3  | 1.5  | 1.5  | 0    |
| B2                                | 可比性      | 5  | 3.75 | 5    | 1.25 | E1 | 阅读与比较     | 4  | 3    | 3    | 0    |
| B3                                | 来源链      | 5  | 5    | 5    | 0    | E2 | 画面与交互     | 3  | 0.75 | 1.5  | 0.75 |
| B4                                | 解释成立     | 4  | 2    | 3    | 1    | E3 | 文件一致与完成声明 | 3  | 1.5  | 2.25 | 0.75 |
| C1                                | 差异分解     | 4  | 4    | 4    | 0    | F1 | 原运行独立性    | 3  | 3    | 3    | 0    |
| C2                                | 下钻调查     | 4  | 4    | 4    | 0    | F2 | 交后修正负担    | 3  | 1.5  | 2.25 | 0.75 |
| C3                                | 稳健性与替代解释 | 5  | 5    | 5    | 0    | F3 | 失败处理      | 2  | 1.5  | 2    | 0.5  |
| C4                                | 据证据修正    | 4  | 2    | 4    | 2    | F4 | 资源使用      | 2  | 2    | 2    | 0    |
| C5                                | 范围与停止    | 3  | 2.25 | 2.25 | 0    |    |           |    |      |      |      |
| 现行 S： 第一轮 76.5 第二轮 87.25 变化 10.75 |          |    |      |      |      |    |           |    |      |      |      |

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 17 DeepSeek 现行 S 25 项得分

附表 4 GLM 评分细项

| GLM   S 评分细项 |          |    |      |      |      |    |           |    |      |      |      |
|--------------|----------|----|------|------|------|----|-----------|----|------|------|------|
| 编号           | 评分项      | 满分 | 第一轮  | 第二轮  | 差    | 编号 | 评分项       | 满分 | 第一轮  | 第二轮  | 差    |
| A1           | 粒度与语义    | 4  | 4    | 4    | 0    | D1 | 阅读入口与步骤   | 4  | 3    | 2    | -1   |
| A2           | 数据质量判断   | 4  | 3    | 3    | 0    | D2 | 过程可理解     | 6  | 4.5  | 4.5  | 0    |
| A3           | 问题可回答性   | 3  | 2.25 | 2.25 | 0    | D3 | 结果可重做     | 6  | 6    | 6    | 0    |
| A4           | 问题优先级    | 4  | 3    | 4    | 1    | D4 | 更新与错误定位   | 6  | 3    | 3    | 0    |
| B1           | 数字与口径    | 6  | 4.5  | 4.5  | 0    | D5 | 原AI的成品检查  | 3  | 1.5  | 1.5  | 0    |
| B2           | 可比性      | 5  | 3.75 | 3.75 | 0    | E1 | 阅读与比较     | 4  | 3    | 3    | 0    |
| B3           | 来源链      | 5  | 5    | 5    | 0    | E2 | 画面与交互     | 3  | 1.5  | 2.25 | 0.75 |
| B4           | 解释成立     | 4  | 2    | 3    | 1    | E3 | 文件一致与完成声明 | 3  | 2.25 | 2.25 | 0    |
| C1           | 差异分解     | 4  | 3    | 4    | 1    | F1 | 原运行独立性    | 3  | 3    | 3    | 0    |
| C2           | 下钻调查     | 4  | 3    | 4    | 1    | F2 | 交后修正负担    | 3  | 2.25 | 2.25 | 0    |
| C3           | 稳健性与替代解释 | 5  | 1.25 | 3.75 | 2.5  | F3 | 失败处理      | 2  | 2    | 2    | 0    |
| C4           | 据证据修正    | 4  | 3    | 3    | 0    | F4 | 资源使用      | 2  | 2    | 2    | 0    |
| C5           | 范围与停止    | 3  | 2.25 | 3    | 0.75 |    |           |    |      |      |      |

现行 S：第一轮 74 第二轮 81 变化 7

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 18 GLM 现行 S 25 项得分

附表 5 Qwen 评分细项

| Qwen   S 评分细项                          |          |    |      |      |      |    |           |    |      |      |       |
|----------------------------------------|----------|----|------|------|------|----|-----------|----|------|------|-------|
| 编号                                     | 评分项      | 满分 | 第一轮  | 第二轮  | 差    | 编号 | 评分项       | 满分 | 第一轮  | 第二轮  | 差     |
| A1                                     | 粒度与语义    | 4  | 3    | 4    | 1    | D1 | 阅读入口与步骤   | 4  | 3    | 4    | 1     |
| A2                                     | 数据质量判断   | 4  | 2    | 4    | 2    | D2 | 过程可理解     | 6  | 4.5  | 4.5  | 0     |
| A3                                     | 问题可回答性   | 3  | 2.25 | 2.25 | 0    | D3 | 结果可重做     | 6  | 6    | 6    | 0     |
| A4                                     | 问题优先级    | 4  | 3    | 4    | 1    | D4 | 更新与错误定位   | 6  | 3    | 3    | 0     |
| B1                                     | 数字与口径    | 6  | 4.5  | 4.5  | 0    | D5 | 原AI的成品检查  | 3  | 1.5  | 1.5  | 0     |
| B2                                     | 可比性      | 5  | 3.75 | 1.25 | -2.5 | E1 | 阅读与比较     | 4  | 3    | 3    | 0     |
| B3                                     | 来源链      | 5  | 5    | 5    | 0    | E2 | 画面与交互     | 3  | 1.5  | 1.5  | 0     |
| B4                                     | 解释成立     | 4  | 2    | 2    | 0    | E3 | 文件一致与完成声明 | 3  | 2.25 | 2.25 | 0     |
| C1                                     | 差异分解     | 4  | 2    | 4    | 2    | F1 | 原运行独立性    | 3  | 3    | 3    | 0     |
| C2                                     | 下钻调查     | 4  | 3    | 4    | 1    | F2 | 交后修正负担    | 3  | 1.5  | 0.75 | -0.75 |
| C3                                     | 稳健性与替代解释 | 5  | 1.25 | 2.5  | 1.25 | F3 | 失败处理      | 2  | 2    | 2    | 0     |
| C4                                     | 据证据修正    | 4  | 1    | 2    | 1    | F4 | 资源使用      | 2  | 2    | 2    | 0     |
| C5                                     | 范围与停止    | 3  | 1.5  | 2.25 | 0.75 |    |           |    |      |      |       |
| 现行 S： 第一轮 67.5    第二轮 75.25    变化 7.75 |          |    |      |      |      |    |           |    |      |      |       |

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 19 Qwen 现行 S 25 项得分

附表 6 Gemini 评分细项

| Gemini   S 评分细项 |          |    |      |      |      |    |           |    |      |      |      |
|-----------------|----------|----|------|------|------|----|-----------|----|------|------|------|
| 编号              | 评分项      | 满分 | 第一轮  | 第二轮  | 差    | 编号 | 评分项       | 满分 | 第一轮  | 第二轮  | 差    |
| A1              | 粒度与语义    | 4  | 1    | 3    | 2    | D1 | 阅读入口与步骤   | 4  | 1    | 3    | 2    |
| A2              | 数据质量判断   | 4  | 2    | 3    | 1    | D2 | 过程可理解     | 6  | 3    | 3    | 0    |
| A3              | 问题可回答性   | 3  | 0.75 | 1.5  | 0.75 | D3 | 结果可重做     | 6  | 4.5  | 6    | 1.5  |
| A4              | 问题优先级    | 4  | 2    | 3    | 1    | D4 | 更新与错误定位   | 6  | 1.5  | 1.5  | 0    |
| B1              | 数字与口径    | 6  | 1.5  | 3    | 1.5  | D5 | 原AI的成品检查  | 3  | 0.75 | 0.75 | 0    |
| B2              | 可比性      | 5  | 2.5  | 3.75 | 1.25 | E1 | 阅读与比较     | 4  | 2    | 3    | 1    |
| B3              | 来源链      | 5  | 2.5  | 3.75 | 1.25 | E2 | 画面与交互     | 3  | 1.5  | 2.25 | 0.75 |
| B4              | 解释成立     | 4  | 0    | 0    | 0    | E3 | 文件一致与完成声明 | 3  | 0.75 | 0.75 | 0    |
| C1              | 差异分解     | 4  | 2    | 4    | 2    | F1 | 原运行独立性    | 3  | 3    | 3    | 0    |
| C2              | 下钻调查     | 4  | 2    | 3    | 1    | F2 | 交后修正负担    | 3  | 0    | 0    | 0    |
| C3              | 稳健性与替代解释 | 5  | 0    | 2.5  | 2.5  | F3 | 失败处理      | 2  | 1.5  | 2    | 0.5  |
| C4              | 据证据修正    | 4  | 1    | 1    | 0    | F4 | 资源使用      | 2  | 2    | 2    | 0    |
| C5              | 范围与停止    | 3  | 0.75 | 0.75 | 0    |    |           |    |      |      |      |

现行 S：第一轮 39.5 第二轮 59.5 变化 20

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 20 Gemini 现行 S 25 项得分

附表 7 Claude 评分细项

| Claude   S 评分细项         |          |    |      |     |   |    |           |    |      |     |   |
|-------------------------|----------|----|------|-----|---|----|-----------|----|------|-----|---|
| 编号                      | 评分项      | 满分 | 第一轮  | 第二轮 | 差 | 编号 | 评分项       | 满分 | 第一轮  | 第二轮 | 差 |
| A1                      | 粒度与语义    | 4  | 3    | —   | — | D1 | 阅读入口与步骤   | 4  | 4    | —   | — |
| A2                      | 数据质量判断   | 4  | 2    | —   | — | D2 | 过程可理解     | 6  | 4.5  | —   | — |
| A3                      | 问题可回答性   | 3  | 2.25 | —   | — | D3 | 结果可重做     | 6  | 4.5  | —   | — |
| A4                      | 问题优先级    | 4  | 4    | —   | — | D4 | 更新与错误定位   | 6  | 3    | —   | — |
| B1                      | 数字与口径    | 6  | 4.5  | —   | — | D5 | 原AI的成品检查  | 3  | 2.25 | —   | — |
| B2                      | 可比性      | 5  | 3.75 | —   | — | E1 | 阅读与比较     | 4  | 3    | —   | — |
| B3                      | 来源链      | 5  | 5    | —   | — | E2 | 画面与交互     | 3  | 1.5  | —   | — |
| B4                      | 解释成立     | 4  | 2    | —   | — | E3 | 文件一致与完成声明 | 3  | 1.5  | —   | — |
| C1                      | 差异分解     | 4  | 4    | —   | — | F1 | 原运行独立性    | 3  | 2.25 | —   | — |
| C2                      | 下钻调查     | 4  | 4    | —   | — | F2 | 交后修正负担    | 3  | 0.75 | —   | — |
| C3                      | 稳健性与替代解释 | 5  | 2.5  | —   | — | F3 | 失败处理      | 2  | 1    | —   | — |
| C4                      | 据证据修正    | 4  | 3    | —   | — | F4 | 资源使用      | 2  | 1.5  | —   | — |
| C5                      | 范围与停止    | 3  | 2.25 | —   | — |    |           |    |      |     |   |
| 现行 S: 第一轮 72 第二轮 — 变化 — |          |    |      |     |   |    |           |    |      |     |   |

六维25项；空白表示未运行或无可评分成品。逐项依据见表格单元格批注。

表 21 Claude 现行 S 25 项得分