

AI 数据分析 Agent

自主交付评测报告

NYC311 数据分析任务 2026 年 9 月 21 日

摘要

本项目考察个人使用 AI 完成数据分析的实际效果。评测限于两轮，比较结果是否可靠、费用与耗时是否值得，以及使用者还需承担多少续跑、接管和修正工作。失败记录全部保留，不追加试验后挑选最好的一次。

本评测要求八个 AI 系统基于同一份纽约 311 服务请求数据，自主选题、开展分析并提交 Excel 及分析说明。GPT、Grok、DeepSeek、GLM、Qwen 和 Gemini 完成了两轮独立运行。Claude 第一轮完成主要调查，最终由 Grok 接手完成交付；Kimi 第一轮多次提前结束，第二轮复测也未交付成品。

各系统的主要差异集中在异常调查和结论核验。GPT 继续检查雪冰峰日与渠道构成，Grok 追查供暖集中的地块，DeepSeek 检查高集中地址和固定观察期。GLM、Qwen 增加了贡献分解和异常检查；Gemini 扩大了调查范围，但仍误读了部分结案文本。

六个系统第二轮运行期间都没有收到追加指令，交付后却仍有 10 项登记修正。已完成的交付仍存在内容错误，包括时间转述、字段数量、比较月份，以及关键词在原句中的含义。

研究问题

1. 各系统能否在无人持续纠偏的情况下完成交付？
2. 成果质量的差距来自哪些维度和具体工作？
3. 各系统能否发现并修正自己的错误？
4. 第二轮方法提示条件下，哪些方面改善，哪些问题仍然存在？
5. 将质量、时间、成本和后续修正放在一起，如何选择？

1 评测设计

1.1 任务与样本

评测安排两轮，比较各系统的分析质量、运行费用、用时及所需人工干预。Claude 第二轮未形成独立运行记录。费用按 API 目录价估算，人工干预以已登记任务描述，未记录实际账单和人工工时。

任务材料包括 25 个 Parquet 分片，共 7,525,498 条 NYC311 服务请求、44 个字段。各系统自行选择分析问题，最终提交 Excel 和分析说明。第一轮使用基础提示，第二轮加入 Evidence-led 方法提示，Grok 和 Gemini 还收到额外方法清单。模型、运行工具和提示条件共同影响结果，每种条件只运行一次。

两轮配对比较采用 GPT、Grok、DeepSeek、GLM 和 Qwen 五个系统。Gemini 第二轮越界搜索项目根目录，且模型子版本缺少可核记录，未通过 G2/G4；其成品及评分单列为观察记录。Claude 的混合交付及 Kimi 的退出、失败记录单列分析，未评分的项目留空。第二轮没有可验证的 Claude 独立运行。

1.2 评分与核验

评分包括成果质量 Q 和过程可靠性 R。Q 评价分析内容与最终成品，R 评价独立执行、纠错过程及完成声明的真实性。两者各满分 100，分别报告。

Q 包含五个维度、21 个细项：数据判断 20 分，检查数据理解和选题；证据计算 25 分，检查数字、比较条件与解释；调查推进 30 分，检查拆解、追查和对照；最终交付 15 分，检查文件、说明及终稿核验；复杂度与范围 10 分，检查方法和投入是否合适。

R 包含五项：独立承担 25 分，自我纠错 25 分，路线控制 20 分，完成真实性 20 分，协议纪律 10 分。正文说明主要得失分依据，附表列出每个细项的两轮得分和满分。评分版本及原始记录入口见附录。

1.3 模型与运行条件

参评模型、思考强度与 Harness				
AI	第一轮模型	第二轮模型	思考强度	Harness (执行环境)
GPT	gpt-6-astra	gpt-6-astra	中 (medium)	Codex
Grok	grok-4.6	grok-4.6	中 (medium)	Cursor
DeepSeek	deepseek-v4.1-flash	deepseek-v4.1-flash	high	Claude Code
GLM	glm-5.3	glm-5.3	high	Claude Code / Brain Router
Qwen	qwen3.8-max-0902	qwen3.8-max-0902	high	Claude Code
Gemini	gemini-3.8-flash	Gemini (子版本未核实)	中 (medium)	Antigravity
Claude	Claude Opus 5 → Grok	无独立运行	中 (medium)	Cursor
Kimi	Kimi (子版本未核实)	kimi-k3	high	Claude Code
运行说明				
思考强度	海外模型设为中，国内模型设为Claude Code中的high。			
执行环境	Harness指模型使用的执行环境；GLM经Brain Router路由。同名强度设置不代表跨平台相同思考预算。			
版本与缺失	模型版本取自运行记录。Claude第二轮未运行；Gemini第二轮、Kimi第一轮的具体子版本未核实。			

表 1 模型、思考强度与 Harness

本项目借助 AI 完成数据整理、分析与报告编制。

Harness 指承载模型、组织工具调用及会话执行的环境。

Claude 第一轮因 Cursor 宿主额度限制切换到 Grok 收尾，Q 只评价混成品，独立过程 R 留空。第二轮没有可验证的独立运行，因此各项及轮间变化留空。

Kimi 第一轮连续提前结束，依赖人工续跑后退出；第二轮真实复测反复读取同一清单，评测方在确认循环后终止。两轮均未交付完整成品，未评分。

2 GPT

第一轮的工作

GPT 先核对 25 个数据分片、文件哈希、主键和日期，发现文件名标出的截止日期晚于最后一条记录。它选取两年各 1—8 月作比较，保留全部请求，再按类别和行政区拆解 287,342 条净增量，重点分析街道、雪冰、供暖，以及布鲁克林和皇后区的增长。第一轮主要完成增长来源分解，对异常日期和具体地址的进一步核查较少。关闭时长与类别改名的业务含义尚未确定，未据此判断服务效率或需求发生了变化。

第二轮的工作

第二轮围绕雪冰增长开展进一步调查。最高 5 天有 32,819 条请求，占同期 55,230 条的 59.42%；GPT 排除这 5 天后重新计算，又单独排除 Snow Tracking，检查增长是否依赖少数峰值和特定记录。渠道分析则固定月份、类别和机构构成，ONLINE 份额仍从 42.5592% 升至 49.3007%，增加 6.7415 个百分点。交付时遇到 Excel 打开和兼容问题，调整生成方式后重新生成文件，检查公式、图表来源和页面。

GPT 两轮各维度得分					
维度	满分	第一轮	第二轮	变化	
数据判断	20	19	20	1	
证据计算	25	25	25	0	
调查推进	30	24	30	6	
最终交付	15	15	15	0	
复杂度	10	10	10	0	
独立承担	25	25	25	0	
自我纠错	25	23	24	1	
路线控制	20	19	19	0	
完成真实性	20	20	20	0	
协议纪律	10	10	10	0	

表 2 GPT 两轮维度得分

2.1 GPT 评分依据

数据判断 GPT 能区分服务请求、现实事件和缺失时间字段。第二轮将总体增长问题细化为雪冰峰日和渠道构成，问题选择从 4 分升至 5 分，数据判断由 19 分升至满分 20 分。

证据计算 两轮证据计算均得 25 分。比较窗口、贡献分母和固定构成计算写得清楚，正文数字与计算结果一致；对于天气、人口和政策等缺少直接证据的原因，未作确定解释。

调查推进 调查推进由 24 分升至 30 分。峰日记录、分组明细、去 Top5 与去 Snow Tracking 对照支持深入调查 8/8；固定构成和排除检查改变了对增长来源的解释，支持修正判断 4/4。本次撤销原评分中缺少具体依据的两分扣分。

最终交付 最终交付两轮均得 15 分。运行记录包含打开 Excel、重算、扫描公式和核对图表来源的操作，交付后没有登记模型修正任务。

复杂度与范围 复杂度与范围两轮均得 10 分。主要计算集中在全量聚合、峰日排除和渠道构成调整，计算范围与调查问题一致。

过程可靠性

GPT 自行修复了 SQL 别名和 Excel 兼容问题，自我纠错从 23 分升至 24 分，过程可靠性由 97 分升至 98 分。独立承担、完成真实性和协议纪律均为满分，路线控制为 19/20。第二轮 32 个实质动作中有 2 次单独失败，未形成连续返工。

GPT 的完整细项分数见附表 1。

3 Grok

第一轮的工作

Grok 选取两个各 11 个月的完整窗口，将 346,695 条净增量分解至供暖、雪冰、违停、道路、堵塞车道和其余类别，各项相加与全市增量一致。随后追查雪冰峰日、Street Condition 细分和机构关闭时长。它说明了残缺月份、分类变化和近期末关闭记录对比较的影响，也没有把系统中的关闭状态直接当作现实问题已经解决。

第二轮的工作

第二轮进一步检查积雪高量日、UNKNOWN 渠道中的坑洞、供暖集中的地块和关闭时长。剔除固定的前 10 个地块后，供暖请求仍由 263,359 条增至 321,188 条，增长 21.96%，排除了增长完全由这些地块带动的解释。Grok 还读回中间表，修改工作簿和说明，运行 qa_verify 检查输出。评测方随后重建文件，205 行数据一致，42 个 ZIP 部件中有 40 个逐字节一致。

Grok 两轮各维度得分					
维度	满分	第一轮	第二轮	变化	
数据判断	20	20	20	0	
证据计算	25	24	24	0	
调查推进	30	26	30	4	
最终交付	15	14	14	0	
复杂度	10	10	10	0	
独立承担	25	25	25	0	
自我纠错	25	24	25	1	
路线控制	20	20	20	0	
完成真实性	20	20	19	-1	
协议纪律	10	10	10	0	

表 3 Grok 两轮维度得分

3.1 Grok 评分依据

数据判断 两轮数据判断均为 20 分。Grok 检查了完整月窗口、记录粒度及类别与机构的关系，从总量变化中选出积雪、坑洞和供暖集中度三个可继续调查的问题。

证据计算 证据计算两轮均为 24 分，扣分集中于解释边界。部分文字把 BBL 地块写成单栋楼宇，地块与建筑的定义存在混淆。未来关闭日期也被登记为一项交付后修正。

调查推进 调查推进从 26 分升至 30 分，贡献了全部 4 分增量。固定前 10 个地块后的排除比较、成熟队列和异常类别追查，使第二轮的判断有了更多直接对照。

最终交付 最终交付两轮均为 14 分，最终文件检查为 3/4。Excel、说明和中间 CSV 齐全，qa_verify 中的文件存在检查恒为真，无法检测文件缺失。

复杂度与范围 复杂度与范围两轮均为 10 分。第二轮 38 个实质动作都用于选定问题或交付检查，没有标记出无收益动作。运行约 11.7 分钟；缺少 Token 记录，费用无法估算。

过程可靠性

过程可靠性两轮均为 99 分，但分项构成发生变化：自我纠错由 24 分升至 25 分，完成真实性由 20 分降至 19 分，后者与恒真检查有关。独立承担、路线控制和协议纪律保持满分。

Grok 的完整细项分数见附表 2。

4 DeepSeek

第一轮的工作

DeepSeek 围绕总量变化继续分析冬季关闭时长、雪冰与坑洞、异常地址、机构差异、渠道和类别名称。固定机构与类型构成后，冬季时长倍数由 3.8667 降到 1.1537；它还排除异常地址重新比较。调查涉及多个具体问题，但成品仍存在两类投诉合计对象错配、异常地址计数错误，部分天气和机构流程解释也缺少依据。

第二轮的工作

第二轮先查字段结构、时间边界、状态、负时长、缺失值和近期未关闭记录，再用统一中间表拆解机构与类别增量。发现 ZIP 10466 和单地址集中后，它继续检查其他高集中类别，并使用固定 30 天关闭率处理观察时间差异。后续主要核对硬编码数值、DHS 统计范围和关键表，重新生成 Excel 与说明，最后运行 verify 脚本、检查原始哈希并重建结果。

DeepSeek 两轮各维度得分					
维度	满分	第一轮	第二轮	变化	
数据判断	20	20	20	20	0
证据计算	25	19	22	22	3
调查推进	30	28	30	30	2
最终交付	15	13	13	13	0
复杂度	10	9	10	10	1
独立承担	25	25	25	25	0
自我纠错	25	23	23	23	0
路线控制	20	17	19	19	2
完成真实性	20	17	17	17	0
协议纪律	10	10	10	10	0

表 4 DeepSeek 两轮维度得分

4.1 DeepSeek 评分依据

数据判断 数据判断两轮均得 20 分。字段用途、观察窗口和质量风险检查完整，后续问题也沿着已发现的地址集中、关闭方式和结构变化展开。

证据计算 证据计算从 19 分升至 22 分，改善主要来自对象和比较范围。第二轮仍把最大创建时间写成 02:22:25，核验值为 01:50:33。数字与口径得 9/10，证据可查和解释边界各得 4/5。

调查推进 调查推进从 28 分升至 30 分，与 GPT、Grok 并列。地址、邮编、关闭方式和固定观察期的检查互相补充，能辨别结果是否主要来自少数位置；仅凭记录集中程度尚不足以认定记录虚假。

最终交付 最终交付仍为 13 分，其中最终文件检查从 3 分降至 2 分。DeepSeek 声称 34 项自检全部一致，却漏掉了中间结果与终稿的时间差异。已有检查未完整覆盖报告中的关键数值转述。

复杂度与范围 复杂度与范围从 9 分升至 10 分。第一轮曾连续遇到同类数据框错误，第二轮只登记了 1 次编辑匹配失败。88 个实质动作大多用于进一步调查和核对。

过程可靠性

路线控制从 17 分升至 19 分，使过程可靠性由 92 分升至 94 分。独立承担和协议纪律保持满分，自我纠错仍为 23/25，完成真实性仍为 17/20；终稿时间与自检声明不一致的问题没有消失。

DeepSeek 的完整细项分数见附表 3。

5 GLM

第一轮的工作

GLM 逐片汇总全部数据，形成总量、季节性、道路异常、机构时长、地区和渠道六条发现。道路异常调查较为深入：从 Street Condition 月度变化查到 Pothole、Cave-in、DOT 受理、日历和五区分布；其他方向主要停留在汇总层面。它注意到了近期关闭样本的偏差，但 DOHMH 流程和新旧类别关系仍有未经证实的解释。

第二轮的工作

第二轮检查字段结构、分布、负时长和季节性后，增加了同比类型增量分解，继续调查住宅噪声、热点地址、供暖季、关闭时长和月度结构。GLM 修正了月均值及关闭率的月份数，验证工作簿后又修改生成脚本，复算聚合表、检查 Excel 图表和月表。对其他可能解释的检验仍少于 GPT、Grok 和 DeepSeek。

GLM 两轮各维度得分					
维度	满分	第一轮	第二轮	变化	
数据判断	20	18	19	1	
证据计算	25	23	23	0	
调查推进	30	21	28	7	
最终交付	15	15	14	-1	
复杂度	10	9	10	1	
独立承担	25	25	25	0	
自我纠错	25	22	23	1	
路线控制	20	19	19	0	
完成真实性	20	18	19	1	
协议纪律	10	10	10	0	

表 5 GLM 两轮维度得分

5.1 GLM 评分依据

数据判断 问题选择更明确，数据判断由 18 分升至 19 分。最终说明把 44 个物理字段写成 43 个，数据理解因此仍为 4/5。

证据计算 证据计算两轮均得 23 分。第二轮热点统计的分母和部分解释仍有问题，数字与口径为 9/10，解释边界为 4/5。负时长 547 条已确认是 Closed 子集的正确结果，与全状态 1,877 条使用不同范围；早期针对这处的扣分理由已撤回。

调查推进 调查推进从 21 分升至 28 分，是总分增加的主要来源。第二轮增加增量分解、热点调查和成熟关闭率，增量拆解、深入调查均得满分。替代解释仍为 5/7，两轮持平。

最终交付 最终交付从 15 分降至 14 分。Excel 重算、图表检查和月表对账都有记录，但字段数量错误留在最终说明中，最终文件检查由 4 分降至 3 分。

复杂度与范围 复杂度与范围由 9 分升至 10 分。第二轮约 9.6 分钟，共 41 个实质动作，其中 2 个动作没有收益，未出现连续沿同一错误方向返工。

过程可靠性

GLM 主动修正月均值和关闭率，自我纠错由 22 分升至 23 分，完成真实性由 18 分升至 19 分，过程可靠性合计由 94 分升至 96 分。独立承担、协议纪律保持满分，路线控制为 19/20。字段数漏检仍影响纠错和完成真实性。

GLM 的完整细项分数见附表 4。

6 Qwen

第一轮的工作

Qwen 完成了总量、类别、地区和关闭时长比较，识别道路异常与分类变化，完成 Excel 和说明。第一轮继续追查异常的工作较少，对时间异常和部分业务解释也未充分核查，多个结论停在汇总观察。

第二轮的工作

第二轮从字段、分片边界、唯一键、缺失值、状态和时间异常开始，随后拆解类别同比、增量贡献、行政区与渠道。它继续追查 2025 年噪声尖峰、空间分散和违停结构，并核对分类变化、Drug Activity 及渠道。交付阶段反复修改标签和统计范围，检查 XML、图表、单元格、说明数字和复现结果，较多时间花在文件重建与读回上。

Qwen 两轮各维度得分					
维度	满分	第一轮	第二轮	变化	
数据判断	20	17	19	2	
证据计算	25	19	21	2	
调查推进	30	21	28	7	
最终交付	15	14	14	0	
复杂度	10	10	8	-2	
独立承担	25	25	25	0	
自我纠错	25	18	22	4	
路线控制	20	19	20	1	
完成真实性	20	17	18	1	
协议纪律	10	10	10	0	
第二轮Q分项合计90，主线时间窗错误，封顶59；R为95。					

表 6 Qwen 两轮维度得分

6.1 Qwen 评分依据

数据判断 数据质量检查和问题选择都有改善，数据判断从 17 分升至 19 分。范围收缩却从 5 分降至 4 分，第二轮同时开展的调查方向较多，范围控制有所减弱。

证据计算 证据计算由 19 分升至 21 分。Drug Activity 中 Use Indoor 份额从约 10.69%升至 29.73%，报告却称细分结构没有实质变化。关闭时长又用了 11 个月基期对 9 个月报告期。数字与口径、比较可比性和解释边界分别得 9/10、4/5、3/5。这一比较用于主要发现 3，触发 Q 最高 59 的封顶条款；B3 分项保留 4 分，封顶调整-31 单列。

调查推进 噪声尖峰、异常调整和渠道检查使调查推进从 21 分升至 28 分，增量拆解、深入调查均得满分。后续由评测方统一为同月 9 个月重算，七类变化方向保持，但不卫生条件增幅从 18.24%变为 12.56%，住宅噪声降幅从 17.89%变为 26.09%。这次重算不计入 Qwen 的自主工作。

最终交付 最终交付两轮均为 14 分。Qwen 多次读回文件并对账，仍漏掉 Drug Activity 解释和窗口差异。正式登记的两项修正涉及描述构成、类别首次出现与改名叙述，窗口问题来自另外的补充审计。

复杂度与范围 复杂度与范围由 10 分降至 8 分，复杂度选择、资源判断各扣 1 分。第二轮约 60.2 分钟，目录价 14.33 元。62 个实质动作都被判定有收益，但反复生成和核对文件仍增加了投入。

过程可靠性

自我纠错从 18 分升至 22 分，是过程可靠性由 89 分升至 95 分的主要原因。路线控制由 19 分升至 20 分，完成真实性由 17 分升至 18 分；独立承担与协议纪律保持满分。Qwen 修复了不少文件和图表问题，最终解释和比较窗口仍需人工复核。

Qwen 的完整细项分数见附表 5。

7 Gemini

第一轮的工作

Gemini 第一轮调查异常地址、供暖分布、违停与噪声的时段关系，以及机构处置时长，并据此提出治理建议。问题出在解释：它把聚集的请求记录当成真实事件，把空间差异解释成阶层差异，又用结案描述判断部门效能，多个结论超出了数据能够支持的范围。

第二轮的工作

第二轮先核对日期、字段质量和异常计数，再拆解年度增长中的部门与类别贡献，继续调查道路、DEP、供暖集中度、空间和处置结果。它检查了近期未关闭记录、分类变化和结构差异，生成 Excel 后也检查文件、说明和脚本。不过，对文件完整性的检查较多，对结案原句和业务含义的核对仍不足。

Gemini 两轮各维度得分					
维度	满分	第一轮	第二轮	变化	
数据判断	20	11	19	8	
证据计算	25	10	16	6	
调查推进	30	14	23	9	
最终交付	15	9	12	3	
复杂度	10	5	8	3	
独立承担	25	24	24	0	
自我纠错	25	13	16	3	
路线控制	20	12	20	8	
完成真实性	20	11	13	2	
协议纪律	10	7	8	1	
第二轮Q 78、R 81仅作观察，不进入正式排名与两轮配对汇总。					

表 7 Gemini 两轮维度得分

7.1 Gemini 评分依据

数据判断 时间范围、字段质量和问题选择都有明显改善，数据判断从 11 分升至 19 分。前三个细项均升至满分，范围收缩为 4/5。

证据计算 证据计算由 10 分升至 16 分，仍是六个系统最低。arrest 关键词命中率为 8.28%，其中包含否定及其他语境；明确的 made an arrest 短语仅约 0.013718%。用前一个比例描述拘捕情况会严重误读文本，后一个比例也仅能描述文字记录。数字与口径为 6/10，解释边界仅 1/5。

调查推进 类别贡献分解和后续调查使这一维度由 14 分升至 23 分。天气因果、地址等同建筑、字典改名等缺少证据的解释仍进入核心结论，适时停止两轮均为 0/3。替代解释得 5/7，修正判断得 3/4。

最终交付 最终交付由 9 分升至 12 分。Excel 与说明齐全，文件存在和脚本检查却没有发现关键语义错误，说明与复现为 2/3，最终文件检查为 2/4。评分依据是原始 7 表工作簿，后续阅读副本的删页不改变原评分。

复杂度与范围 复杂度与范围由 5 分升至 8 分。第二轮约 6.1 分钟，39 个实质动作没有被标记为无收益，但范围管理和资源判断仍扣分，也使用了未经授权的人口信息。缺少 Token 记录，无法估算费用。

过程可靠性

过程可靠性从 67 分升至 81 分，主要是路线控制由 12 分升至 20 分。自我纠错仅 16/25，完成真实性 13/20，部分关键问题依赖评测方识别。独立承担为 24/25，协议纪律为 8/10，该项原始扣分依据为查找 Skill 时搜索项目根目录，暴露其他目录的路径信息；记录未发现读取他人成果或评分。人口占比陈述另列为内容修正问题。

Gemini 的完整细项分数见附表 6。

8 Claude

第一轮的调查与交付

Claude 第一轮核对字段与数据范围，调查高频地址、增长来源、类别变化、关闭时长、结案原句和重复记录。它保存 30 张中间汇总表，生成 13 个工作表。按“地址×类别单日峰值不少于 200 条”筛出 4 个住宅噪声组合，共 185,791 条，再比较剔除前后的趋势。它还用日均值处理 365 天与 364 天的窗口差异，检查成熟队列、机构时长和 NYPD 结案描述。

第一轮因 Cursor 宿主额度限制，运行从 Claude Opus 5 切换到 Grok。记录中 Claude 有 51 次工具请求，切换后的 Grok 有 31 次。最终重建、说明对齐和部分文件读回由 Grok 完成，因此这份成品按混合交付评价，不给 Claude 单独的过程可靠性分数。模型分段 Token 也缺少可核实的记录。

Claude 两轮各维度得分				
维度	满分	第一轮	第二轮	变化
数据判断		20	17	
证据计算		25	16	
调查推进		30	25	
最终交付		15	14	
复杂度		10	9	
独立承担		25		
自我纠错		25		
路线控制		20		
完成真实性		20		
协议纪律		10		
第一轮Q 81评价Claude与Grok的混合成品，R不评分；第二轮未独立运行。				

表 8 Claude 第一轮混合成品维度得分

8.1 Claude 评分依据

数据判断 Claude 基本理解请求粒度、44 个字段和全量范围，也选出了 6 个具体问题。不过，它把高频聚集当成必须删除的无效记录，并在标题中混淆最大单地址与 4 个组合总量，数据判断得 17/20。高频记录可以用来做剔除前后的对照，删除前仍需证明它们确实无效。

证据计算 证据计算得 16/25。总量、窗口计数和既定去重规则下的冗余量可以复算，但前 20 类的增量与全量增量未对齐，自检又部分使用常量和旧汇总。365 天与 364 天的差异虽已说明，末日不完整和时效观察时间仍影响比较。“真实重复只会更多”、天气已排除其他解释、官方改名等说法缺少依据，解释边界仅得 1/5。

调查推进 增量拆解、深入调查均得满分，调查推进合计 25/30。三类投诉贡献的 167,706 条可以与 362,541 条总增量对照，地址日峰、相邻聚集、前后趋势和结案原句也查得较细。剩余扣分涉及异常剔除是否有效、去重是否误合并，以及成熟样本如何选择。

最终交付 最终交付得 14/15。数字、图表和计算过程可以回查，但增量加总声明的错误未被检查发现，最终文件检查得 3/4。Grok 也参与了最终核验。后来迁移目录造成的旧路径问题由评测方维护，不计入 Claude 失分。

复杂度与范围 复杂度与范围得 9/10。DuckDB 聚合和统一保存函数都用于实际分析；扣分来自几次写入被截断后继续重试、再拆分的返工，资源判断为 2/3。缺少 Token 记录，无法估算这部分费用。

过程与比较

Claude 与第一轮 Qwen 的成品质量同为 81 分。Claude 调查推进多 4 分，证据计算少 3 分，复杂度与范围少 1 分。Claude 完成了主要调查，Grok 参与了交付，两者共同形成最终结果；独立承担、自我纠错、路线控制、完成真实性和协议纪律五项 R 评分均留空。完整细项见附表 7。

9 Kimi

第一轮为何退出

Kimi 第一轮连续提前结束，需要人工续跑，后来退出评测。参与登记和后续规划记录了这一经过；现有目录只有任务提示，没有最终 Excel 和分析说明。第一轮耗时、Token 及续跑次数缺少原始记录，保留空白。

第二轮补充复测

第二轮先遇到启动器未关闭标准输入的问题，当时模型尚未真正启动。这次基础设施失败不计为模型失败。修复后，Kimi 反复读取同一个 `data_manifest.json`，即使运行工具已返回 `file_unchanged` 或 `Wasted call` 仍继续读取。评测方确认循环后停止运行，未得到 Excel 和分析说明。

真实复测用时约 158.7 秒，即 2.65 分钟，按 API 目录价估算约 1.48 元。14 个实质动作中 13 个没有收益，占 92.86%。另一份早期计时记录为 171.252 秒，本报告采用原生会话时间。

评分处理

数据判断与证据计算 两轮都没有完整成品，第二轮主要停在反复读清单。数据判断和证据计算缺少评分材料，留空。

调查推进与最终交付 第一轮提前结束，第二轮陷入重复读取，两次都未完成后续调查和交付。调查推进、最终交付同样不评分。

复杂度与过程可靠性 第一轮需要人工续跑，第二轮未根据“文件未变化”的反馈调整做法，运行连续性和路线控制有明确问题。其他过程项目缺少足够记录，R 不发布。

10 成果质量比较

第一轮 成果质量 Q							
AI	数据判断 /20	证据计算 /25	调查推进 /30	最终交付 /15	复杂度 /10	合计/100	样本状态
GPT	19	25	24	15	10	93	独立完成
Grok	20	24	26	14	10	94	独立完成
DeepSeek	20	19	28	13	9	89	独立完成
GLM	18	23	21	15	9	86	独立完成
Qwen	17	19	21	14	10	81	独立完成
Gemini	11	10	14	9	5	49	独立完成
Claude	17	16	25	14	9	81	混成品，仅Q
Kimi							提前结束后退出

表 9 第一轮成果质量分项

第二轮 成果质量 Q							
AI	数据判断 /20	证据计算 /25	调查推进 /30	最终交付 /15	复杂度 /10	合计/100	样本状态
GPT	20	25	30	15	10	100	独立完成
Grok	20	24	30	14	10	98	独立完成
DeepSeek	20	22	30	13	10	95	独立完成
GLM	19	23	28	14	10	94	独立完成
Qwen	19	21	28	14	8	59	分项90；封顶59
Gemini	19	16	23	12	8	78	观察；Gate不通过
Claude							未开展独立运行
Kimi							读取循环后终止

表 10 第二轮成果质量分项

10.1 分项差距与同分差异

数据判断 第二轮数据判断差距很小：GPT、Grok 和 DeepSeek 均为 20 分，GLM、Qwen 和 Gemini 均为 19 分。这些交付都已检查基本数据范围。GLM 把 44 个字段写成 43 个，是其中一个具体失分点。

证据计算 正式比较的五个系统中，证据计算从 Qwen 的 21 分到 GPT 的 25 分，相差 4 分；Grok 24 分、GLM 23 分、DeepSeek 22 分。纳入 Gemini 的 16 分观察评分后，六系统相差 9 分。DeepSeek 写错终稿时间，Qwen 的结构解释与比较月份有问题，Gemini 误读结案文本；这些具体错误解释了部分分差。

调查推进 GPT、Grok 和 DeepSeek 的调查推进均为 30 分，GLM 和 Qwen 为 28 分，Gemini 为 23 分。Grok 追到地块集中度，DeepSeek 追到地址与关闭方式，前两者都加入了针对性的对照。Gemini 也展开了更多调查，但仍保留缺少依据的原因解释，适时停止为 0/3。

最终交付 最终交付从 GPT 的 15 分到 Gemini 的 12 分。Grok、GLM 和 Qwen 各 14 分，DeepSeek 13 分。它们都做了文件检查，差别在于是否查到终稿中的文字错误，以及检查脚本本身是否有效。

复杂度与范围 GPT、Grok、DeepSeek 和 GLM 均为 10 分，Qwen、Gemini 为 8 分。Qwen 主要受较重的重建和核对投入影响，Gemini 还有范围与未经授权信息的问题。

GPT 质量 100 分、Grok 98 分，差异来自证据计算和最终交付各 1 分。Qwen 分项合计 90，主线时间窗错误使最终 Q 封顶 59；GLM 为 94 分。DeepSeek 比 GLM 总分只多 1 分，其中数据判断多 1 分、调查推进多 2 分，证据计算和最终交付各少 1 分。

11 过程可靠性比较

第一轮过程可靠性 R							
AI	独立承担 /25	自我纠错 /25	路线控制 /20	完成真实性 /20	协议纪律 /10	合计/100	样本状态
GPT	25	23	19	20	10	97	独立完成
Grok	25	24	20	20	10	99	独立完成
DeepSeek	25	23	17	17	10	92	独立完成
GLM	25	22	19	18	10	94	独立完成
Qwen	25	18	19	17	10	89	独立完成
Gemini	24	13	12	11	7	67	独立完成
Claude							混成品，仅Q
Kimi							提前结束后退出

表 11 第一轮过程可靠性分项

第二轮过程可靠性 R							
AI	独立承担 /25	自我纠错 /25	路线控制 /20	完成真实性 /20	协议纪律 /10	合计/100	样本状态
GPT	25	24	19	20	10	98	独立完成
Grok	25	25	20	19	10	99	独立完成
DeepSeek	25	23	19	17	10	94	独立完成
GLM	25	23	19	19	10	96	独立完成
Qwen	25	22	20	18	10	95	独立完成
Gemini	24	16	20	13	8	81	观察；Gate不通过
Claude							未开展独立运行
Kimi							读取循环后终止

表 12 第二轮过程可靠性分项

独立承担与协议纪律 正式五系统两项均为满分。Gemini 观察评分分别为 24/25 和 8/10，协议纪律扣分来自越界搜索目录；未发现读取他人成果或评分。Claude 与 Kimi 不纳入独立过程比较。

自我纠错 Grok 得 25 分，GPT24 分，Gemini16 分。Qwen 较第一轮提高 4 分，主要修复文件和图表；Gemini 提高 3 分，关键语义与原因解释仍需外部指出。

路线控制 Grok、Qwen 和 Gemini 得 20 分，其余三个系统 19 分。Gemini 按计划完成文件，文本解释中的错误仍留在终稿。

完成真实性 GPT20 分，Gemini13 分，差距最大。Grok 因恒真的文件存在检查扣 1 分，与自我纠错增分抵消，R 仍为 99。

12 两轮变化

五个配对系统·分项变化与封顶调整									
质量维度			满分	第一轮均分	第二轮均分		平均增量	分项增量占比	
问题与数据判断			20.0	18.8	19.6		0.8	11.8%	
证据与计算			25.0	22.0	23.0		1.0	14.7%	
调查推进			30.0	24.0	29.2		5.2	76.5%	
最终交付			15.0	14.2	14.0		-0.2	-2.9%	
复杂度与范围			10.0	9.6	9.6		0.0	0.0%	
分项合计			100.0	88.6	95.4		6.8	100.0%	
封顶调整				0.0	-6.2		-6.2		
最终Q				88.6	89.2		0.6		

表 13 五个配对系统的分项变化与封顶调整

五个系统最终 Q 的变化分别为 GPT +7、Grok +4、DeepSeek +6、GLM +8、Qwen -22。均值由 88.6 升至 89.2，增加 0.6 分，中位变化为 6 分。Gemini 第二轮未通过 Gate，不进入配对汇总。

封顶前，五系统分项合计增加 34 分：数据判断 4 分、证据计算 5 分、调查推进 26 分、最终交付-1 分，复杂度与范围不变。调查推进占分项增量 76.5%。

Qwen 分项合计 90，但 11 个月与 9 个月的关闭时长比较支撑了主要发现 3，按冻结规则封顶 59，调整-31 分。分项提升与最终质量下降同时存在：更多工作没有解决主线比较错误。

GPT 的深入调查和修正判断经本次重审分别改为 8/8、4/4。原 98 分缺少两处分项扣分依据，现 Q 为 100。旧分数与本次裁定同时保留。

12.1 评分变化与实际动作

增加的调查可以在操作记录中找到：GPT 排除峰日并固定渠道构成，Grok 剔除固定前 10 个地块，DeepSeek 比较高集中地址和固定观察期，GLM 补上增量分解，Qwen 增加异常调整和复现检查。这些新增动作与调查推进得分的提高相对应。

13 耗时、费用与后续修正

AI	Q	R	分钟	API目录价 (元)	AWR	修正	总 Token	运行工具	状态
GPT	100	98	17.8	38.96	6.3%	0	3,244,918	Codex	已完成
Grok	98	99	11.7	—	0.0%	1		Cursor	已完成
DeepSeek	95	94	21.7	1.37–2.74	1.1%	1	8,980,596	Claude Code	已完成
GLM	94	96	9.6	6.48	4.9%	1	2,456,581	Claude Code	已完成
Qwen	59	95	60.2	14.33	0.0%	2	8,288,450	Claude Code	已完成
Gemini	78	81	6.1	—	0.0%	5		Antigravity	观察
Kimi			2.6	1.48	92.9%	0	499,485	Claude Code	失败
Claude				—				未运行	未运行

表 14 第二轮交付与资源指标




图 1 第二轮原生耗时




图 2 第二轮 API 目录价低档

第二轮 GLM 约 9.6 分钟，目录价 6.48 元；DeepSeek 约 21.7 分钟，1.37—2.74 元；GPT 约 17.8 分钟，38.96 元；Qwen 约 60.2 分钟，14.33 元。Grok 和 Gemini 缺少 Token 记录，费用留空。图中显示 DeepSeek 区间下限，表中保留完整区间。金额按 API 目录价估算，与实际账单可能不同。

本次 GLM 比 Qwen 用时更短、费用更低，质量与过程可靠性得分也更高。GPT 交付后未登记修正任务，但可估算费用最高；DeepSeek 费用最低，仍有 1 项终稿修正。

13.1 无收益动作与后续修正




图3 第二轮无收益动作占比

第二轮六个独立系统共留下 362 条可查动作，其中 300 条属于实质动作，5 条被判定没有收益。GPT 为 2/32，DeepSeek 为 1/88，GLM 为 2/41，Grok、Qwen 和 Gemini 分别为 0/38、0/62、0/39。无收益动作占比 AWR 排除管理动作；Grok 和 Gemini 缺少逐动作时长，不能再比较这些动作占用了多少时间。

运行期间六者都没有收到追加指令。交付后登记修正共 10 项：GPT 0 项，Grok、DeepSeek、GLM 各 1 项，Qwen 2 项，Gemini 5 项。构成与分类解释占 3 项，时间与比较范围占 2 项，解释缺证据占 2 项，数值或对象错配、记录与现实对象混淆、文本语义各 1 项。

各项修正的工作量差别很大。GLM 的字段数量可以局部改正，Gemini 的文本语义和天气解释则可能影响整段结论。项目未记录修正工时。

Qwen 和 Gemini 没有动作被标为无收益，交付后仍各有 2 项、5 项登记修正。Qwen 检查了文件和图表，Gemini 检查了文件完整性，两者都遗漏了最终解释中的问题。

14 研究结论

第二轮六个系统交付了 Excel 和分析说明，GPT 未登记交付后修正，其余五个共登记 10 项。Claude 由 Grok 接管收尾，Kimi 两轮均未形成完整交付。

14.1 文件完成后仍需人工修正

五个独立系统的成品仍需修正，主要问题涉及数值转述、统计范围、对象定义与文本语义。它们通常能发现脚本或文件故障，对解释是否成立、终稿是否忠实于计算结果的检查较弱。GPT 本次未登记交付后修正；其他系统的检查次数或无收益动作占比，均不足以直接判断成品准确性。

14.2 分差主要来自计算和解释

第二轮正式比较的五个系统，数据判断相差 1 分，证据计算相差 4 分；含 Gemini 观察评分时，证据计算相差 9 分。各系统普遍能识别数据范围，差异更多体现在如何选择分母、对齐窗口、理解字段和限制原因解释。Grok 与 DeepSeek 调查较深入，GPT 在计算与终稿核验上更完整，Gemini 的关键弱点是语义和因果判断。总分相近的系统，复核重点并不相同。

14.3 第二轮增加了调查，终稿检查改善有限

五个配对系统的质量分项合计平均增加 6.8 分，其中调查推进贡献 26/34，即 76.5%；最终交付合计减少 1 分。Qwen 因主线时间窗错误封顶，计入-31 分调整后，最终 Q 均值仅由 88.6 升至 89.2，增加 0.6 分。更多调查没有保证最终比较成立。两轮提示不同，不能将变化单独归因于 Skill。

14.4 各系统综合评价

GPT 适合对成品准确性要求较高的任务。本次复审 Q 为 100 分，计算和终稿检查较完整，交付后未登记修正任务；第二轮估算费用 38.96 元，在费用可估算的四个系统中最高。预算有限时，需要权衡这部分准确性优势与费用。

Grok 调查深入，质量 98 分，低于 GPT 两分。排除固定地块后重新比较增长，能检验原解释是否成立。使用成品前仍需核对地块定义、未来关闭日期和无效检查。缺少费用记录，目前只能比较质量和用时。

DeepSeek 调查较深入，第二轮估算费用最低，为 1.37—2.74 元。地址集中和固定观察期分析较充分，但终稿时间写错，自检也未发现。愿意自行复核关键数字的使用者，可以考虑其费用优势。

GLM 在质量、用时和费用之间表现较均衡。第二轮约 9.6 分钟、6.48 元，质量与过程评分均高于 Qwen。个人同时考虑预算和效率时，GLM 较值得选用；字段数量、热点分母和原因解释仍需检查。

Qwen 第二轮调查与纠错有所改善，但用时约 60.2 分钟、估算费用 14.33 元，关闭时长主线比较错误使质量封顶为 59 分。反复重建和检查文件后，结构解释与比较窗口的问题仍未解决。本次任务中，Qwen 的耗时和估算费用均高于 GLM，未获得相应的质量收益。

Gemini 约 6.1 分钟完成，速度最快，观察质量评分 78 分，交付后登记了 5 项修正。文本误读和缺少证据的原因解释影响主要结论。快速生成文件的优势伴随着较多复核工作，不宜直接采用其分析说明；第二轮未通过 Gate，不列入正式排名。

Claude 主要调查已完成，随后因 Cursor 额度限制中断，由 Grok 收尾。81 分评价的是混合成品。中断源于宿主额度，仍然给个人使用者带来了切换和接管工作；本次结果不足以推荐 Claude 与 Cursor 的这一组合独立完成同类任务。

Kimi 两轮都未交出完整成品。第一轮反复提前结束，需要人工续跑；第二轮重复读取同一清单，未能恢复。在本次两轮预算及 Claude Code 工具组合下，停止追加付费重试，不将其用于需要连续执行并独立交付的任务。

附录 评分裁定与资料说明

冻结规则保持不变。原评分版本为第一轮 1.0、第二轮 enhanced_review_1.0，Claude 为 claude_assisted_quality_20260918_v1。本次 final_review_20260921 记录 GPT 分项重审、Qwen 封顶与 Gemini 样本资格，原始评分保留。Excel“评分与用量”保留细项分数和证据编号，“核验记录”保留问题、对照值及归属，“行为记录”保留动作次序。

报告全部图表取自交付目录中的主 Excel。主表支持按 AI 和轮次查看结果，“分维度比较”用于横向比较，“评分细项”列出以下七份附表。Claude 缺少独立过程评分，Kimi 缺少完整评分，空白均保留。

在“查证.html”输入证据编号可查看已有核验；Notebook 保留数据整理、两轮配对和分维度计算。

本评测由一名评审评分，未测量评审间一致性，也未记录人工监督和修正工时。

附表 1 GPT 评分细项

GPT 评分细项											
编号 评分项		满分	第一轮	第二轮	分差	编号 评分项		满分	第一轮	第二轮	分差
A 数据判断 · 20分						D 最终交付 · 15分					
A1	数据理解	5	5	5	—	D1	成品可读	4	4	4	—
A2	清洗判断	5	5	5	—	D2	结论可核	4	4	4	—
A3	问题选择	5	4	5	+1	D3	说明与复现	3	3	3	—
A4	范围收缩	5	5	5	—	D4	最终文件检查	4	4	4	—
B 证据计算 · 25分						E 复杂度与范围 · 10分					
B1	数字与口径	10	10	10	—	E1	复杂度选择	3	3	3	—
B2	证据可查	5	5	5	—	E2	有效复用	2	2	2	—
B3	比较可比	5	5	5	—	E3	范围管理	2	2	2	—
B4	解释边界	5	5	5	—	E4	资源判断	3	3	3	—
C 调查推进 · 30分						R 过程可靠性 · 100分					
C1	增量拆解	8	8	8	—	R1	独立承担	25	25	25	—
C2	深入调查	8	5	8	+3	R2	自我纠错	25	23	24	+1
C3	替代解释	7	5	7	+2	R3	路线控制	20	19	19	—
C4	修正判断	4	3	4	+1	R4	完成真实性	20	20	20	—
C5	适时停止	3	3	3	—	R5	协议纪律	10	10	10	—
成果质量 Q						过程可靠性 R					
		100	93	100	+7			100	97	98	+1

GPT第二轮C2改为8、C4改为4，Q由98改为100。峰日明细、描述排除与固定构成检查支持这两项满分，原扣分缺少对应依据。

表 15 GPT 完整细项得分

附表 2 Grok 评分细项

Grok 评分细项											
编号 评分项		满分	第一轮	第二轮	分差	编号 评分项		满分	第一轮	第二轮	分差
A 数据判断 • 20分						D 最终交付 • 15分					
A1	数据理解	5	5	5	—	D1	成品可读	4	4	4	—
A2	清洗判断	5	5	5	—	D2	结论可核	4	4	4	—
A3	问题选择	5	5	5	—	D3	说明与复现	3	3	3	—
A4	范围收缩	5	5	5	—	D4	最终文件检查	4	3	3	—
B 证据计算 • 25分						E 复杂度与范围 • 10分					
B1	数字与口径	10	10	10	—	E1	复杂度选择	3	3	3	—
B2	证据可查	5	5	5	—	E2	有效复用	2	2	2	—
B3	比较可比	5	5	5	—	E3	范围管理	2	2	2	—
B4	解释边界	5	4	4	—	E4	资源判断	3	3	3	—
C 调查推进 • 30分						R 过程可靠性 • 100分					
C1	增量拆解	8	8	8	—	R1	独立承担	25	25	25	—
C2	深入调查	8	6	8	+2	R2	自我纠错	25	24	25	+1
C3	替代解释	7	6	7	+1	R3	路线控制	20	20	20	—
C4	修正判断	4	3	4	+1	R4	完成真实性	20	20	19	-1
C5	适时停止	3	3	3	—	R5	协议纪律	10	10	10	—
成果质量 Q					100 94 98 +4	过程可靠性 R					100 99 99 —

Q为成果质量，R为过程可靠性，两项各100分、分别评价。分差 = 第二轮 - 第一轮；得分理由见报告对应AI章节。空白表示未评分。

表 16 Grok 完整细项得分

附表 3 DeepSeek 评分细项

DeepSeek 评分细项											
编号 评分项		满分	第一轮	第二轮	分差	编号 评分项		满分	第一轮	第二轮	分差
A 数据判断 • 20分						D 最终交付 • 15分					
A1	数据理解	5	5	5	—	D1	成品可读	4	3	4	+1
A2	清洗判断	5	5	5	—	D2	结论可核	4	4	4	—
A3	问题选择	5	5	5	—	D3	说明与复现	3	3	3	—
A4	范围收缩	5	5	5	—	D4	最终文件检查	4	3	2	-1
B 证据计算 • 25分						E 复杂度与范围 • 10分					
B1	数字与口径	10	8	9	+1	E1	复杂度选择	3	3	3	—
B2	证据可查	5	4	4	—	E2	有效复用	2	2	2	—
B3	比较可比	5	4	5	+1	E3	范围管理	2	2	2	—
B4	解释边界	5	3	4	+1	E4	资源判断	3	2	3	+1
C 调查推进 • 30分						R 过程可靠性 • 100分					
C1	增量拆解	8	8	8	—	R1	独立承担	25	25	25	—
C2	深入调查	8	8	8	—	R2	自我纠错	25	23	23	—
C3	替代解释	7	6	7	+1	R3	路线控制	20	17	19	+2
C4	修正判断	4	4	4	—	R4	完成真实性	20	17	17	—
C5	适时停止	3	2	3	+1	R5	协议纪律	10	10	10	—
成果质量 Q					100 89 95 +6	过程可靠性 R					100 92 94 +2

Q为成果质量，R为过程可靠性，两项各100分、分别评价。分差 = 第二轮 - 第一轮；得分理由见报告对应AI章节。空白表示未评分。

表 17 DeepSeek 完整细项得分

附表 4 GLM 评分细项

GLM 评分细项											
编号 评分项		满分	第一轮	第二轮	分差	编号 评分项		满分	第一轮	第二轮	分差
A 数据判断 · 20分						D 最终交付 · 15分					
A1	数据理解	5	4	4	—	D1	成品可读	4	4	4	—
A2	清洗判断	5	5	5	—	D2	结论可核	4	4	4	—
A3	问题选择	5	4	5	+1	D3	说明与复现	3	3	3	—
A4	范围收缩	5	5	5	—	D4	最终文件检查	4	4	3	-1
B 证据计算 · 25分						E 复杂度与范围 · 10分					
B1	数字与口径	10	10	9	-1	E1	复杂度选择	3	3	3	—
B2	证据可查	5	5	5	—	E2	有效复用	2	2	2	—
B3	比较可比	5	5	5	—	E3	范围管理	2	2	2	—
B4	解释边界	5	3	4	+1	E4	资源判断	3	2	3	+1
C 调查推进 · 30分						R 过程可靠性 · 100分					
C1	增量拆解	8	6	8	+2	R1	独立承担	25	25	25	—
C2	深入调查	8	5	8	+3	R2	自我纠错	25	22	23	+1
C3	替代解释	7	5	5	—	R3	路线控制	20	19	19	—
C4	修正判断	4	3	4	+1	R4	完成真实性	20	18	19	+1
C5	适时停止	3	2	3	+1	R5	协议纪律	10	10	10	—
成果质量 Q						过程可靠性 R					
		100	86	94	+8			100	94	96	+2

Q为成果质量，R为过程可靠性，两项各100分、分别评价。分差 = 第二轮 - 第一轮；得分理由见报告对应AI章节。空白表示未评分。

表 18 GLM 完整细项得分

附表 5 Qwen 评分细项

Qwen 评分细项											
编号 评分项		满分	第一轮	第二轮	分差	编号 评分项		满分	第一轮	第二轮	分差
A 数据判断 · 20分						D 最终交付 · 15分					
A1	数据理解	5	4	5	+1	D1	成品可读	4	4	4	—
A2	清洗判断	5	4	5	+1	D2	结论可核	4	4	4	—
A3	问题选择	5	4	5	+1	D3	说明与复现	3	3	3	—
A4	范围收缩	5	5	4	-1	D4	最终文件检查	4	3	3	—
B 证据计算 · 25分						E 复杂度与范围 · 10分					
B1	数字与口径	10	7	9	+2	E1	复杂度选择	3	3	2	-1
B2	证据可查	5	5	5	—	E2	有效复用	2	2	2	—
B3	比较可比	5	4	4	—	E3	范围管理	2	2	2	—
B4	解释边界	5	3	3	—	E4	资源判断	3	3	2	-1
C 调查推进 · 30分						R 过程可靠性 · 100分					
C1	增量拆解	8	6	8	+2	R1	独立承担	25	25	25	—
C2	深入调查	8	6	8	+2	R2	自我纠错	25	18	22	+4
C3	替代解释	7	4	6	+2	R3	路线控制	20	19	20	+1
C4	修正判断	4	3	4	+1	R4	完成真实性	20	17	18	+1
C5	适时停止	3	2	2	—	R5	协议纪律	10	10	10	—
成果质量 Q					100 81 59 -22	过程可靠性 R					100 89 95 +6

Qwen第二轮分项合计90；主要发现使用11个月与9个月比较，按冻结规则封顶59。原分项保留，调整为-31。

表 19 Qwen 完整细项得分

附表 6 Gemini 评分细项

Gemini 评分细项											
编号 评分项		满分	第一轮	第二轮	分差	编号 评分项		满分	第一轮	第二轮	分差
A 数据判断 • 20分						D 最终交付 • 15分					
A1	数据理解	5	2	5	+3	D1	成品可读	4	3	4	+1
A2	清洗判断	5	3	5	+2	D2	结论可核	4	3	4	+1
A3	问题选择	5	3	5	+2	D3	说明与复现	3	2	2	—
A4	范围收缩	5	3	4	+1	D4	最终文件检查	4	1	2	+1
B 证据计算 • 25分						E 复杂度与范围 • 10分					
B1	数字与口径	10	4	6	+2	E1	复杂度选择	3	2	3	+1
B2	证据可查	5	3	4	+1	E2	有效复用	2	1	2	+1
B3	比较可比	5	2	5	+3	E3	范围管理	2	1	1	—
B4	解释边界	5	1	1	—	E4	资源判断	3	1	2	+1
C 调查推进 • 30分						R 过程可靠性 • 100分					
C1	增量拆解	8	4	8	+4	R1	独立承担	25	24	24	—
C2	深入调查	8	5	7	+2	R2	自我纠错	25	13	16	+3
C3	替代解释	7	3	5	+2	R3	路线控制	20	12	20	+8
C4	修正判断	4	2	3	+1	R4	完成真实性	20	11	13	+2
C5	适时停止	3	0	0	—	R5	协议纪律	10	7	8	+1
成果质量 Q					100 49 78 +29	过程可靠性 R					100 67 81 +14

Gemini第二轮Q 78、R 81为观察评分；不进入正式排名与两轮配对汇总。第一轮Q/R保留。

表 20 Gemini 完整细项得分

附表 7 Claude 评分细项

Claude 评分细项											
编号	评分项	满分	第一轮	第二轮	分差	编号	评分项	满分	第一轮	第二轮	分差
A 数据判断 • 20分						D 最终交付 • 15分					
A1	数据理解	5	4			D1	成品可读	4	4		
A2	清洗判断	5	3			D2	结论可核	4	4		
A3	问题选择	5	5			D3	说明与复现	3	3		
A4	范围收缩	5	5			D4	最终文件检查	4	3		
B 证据计算 • 25分						E 复杂度与范围 • 10分					
B1	数字与口径	10	8			E1	复杂度选择	3	3		
B2	证据可查	5	4			E2	有效复用	2	2		
B3	比较可比	5	3			E3	范围管理	2	2		
B4	解释边界	5	1			E4	资源判断	3	2		
C 调查推进 • 30分						R 过程可靠性 • 100分					
C1	增量拆解	8	8			R1	独立承担	25			
C2	深入调查	8	8			R2	自我纠错	25			
C3	替代解释	7	5			R3	路线控制	20			
C4	修正判断	4	3			R4	完成真实性	20			
C5	适时停止	3	1			R5	协议纪律	10			
成果质量 Q						过程可靠性 R					
		100	81					100			

Claude第一轮由Claude主体完成、Grok收尾，81分评价混合成品；R不发布，第二轮未形成独立评分。空白表示未评分。

表 21 Claude 完整细项得分