

AI 数据分析 Agent/自主交付评测简洁版

NYC311 数据分析任务 两轮自主交付评测

本项目沿用项目 1 的纽约市 311 非紧急市政服务请求（NYC311）数据，交给八个能调用工具执行任务的 AI 系统，文中称为 AI Agent。输入为 25 个 Parquet 格式数据文件、7,525,498 条请求、44 列信息。各系统自主选题，提交 Excel 和说明；第一轮用基础提示，第二轮增加方法提示，Grok 和 Gemini 另有检查清单。

下文先看各系统实际做了什么，再结合文件和计算核查解释评分，最后比较耗时、费用及接手工作。未形成成品的轮次保留状态，分数留空。

1 各系统完成的主要工作

GPT 第一轮分解类别、行政区增长，第二轮进一步核查雪冰峰日和渠道构成。最高 5 天占同期雪冰请求的 59.42%；排除峰日并固定不同月份、类别和机构的权重后继续比较，最终检查 Excel 公式和图表。

Grok 第一轮按互斥类别分解全市增量，第二轮检查供暖请求是否集中在少数地块、积雪高量日及坑洞。排除固定前 10 个地块后，供暖请求仍增长 21.96%。

DeepSeek 两轮均调查异常地址和关闭时长，第二轮增加邮编集中度、固定 30 天关闭率及数据重建。第一轮固定机构与类型的权重后，冬季时长倍数由 3.8667 降至 1.1537。

GLM 第一轮重点追查道路异常，第二轮增加同比增量分解、住宅噪声与热点地址分析，并修正月均值和关闭率的统计月份。

Qwen 第一轮完成类别、地区和时长比较，第二轮增加噪声尖峰、渠道及异常调整分析，但两轮分别留下描述结构和比较月份的核心解释错误。

Gemini 第一轮分析异常地址、供暖、违停及机构时长，第二轮完善日期与字段检查，扩大部门、类别和处置结果分析，但结案文本解释仍有错误。

Claude 第一轮保存 30 张中间汇总表、生成 13 个工作表，调查地址集中、重复规则与结案描述。Cursor 额度用尽后由 Grok 订正数字并重建终稿；72 分只评价 Claude 阶段可归属的工作。第二轮未运行。

Kimi 第一轮多次提前结束，经人工续跑后退出；第二轮反复读取同一清单，评测方终止运行。两轮均未形成完整成品。

2 两轮现行 S 评分及主要差异

S 是自主交付总分，满分 100，由 25 个细项相加。A—F 依次为数据与选题 15 分、证据计算 20 分、调查判断 20 分、人工维护 25 分、成品可用性 10 分、自主与资源 10 分。每项按完整满足、主要满足、部分完成、有限可用、未完成或不可用，分别给满分的 100%、75%、50%、25%、0。具体定义和依据见完整稿第 1.2 节及附录。

第1轮 现行 S 六维								
AI	数据基础/15	证据计算/20	调查判断/20	人工维护/25	成品可用/10	自主资源/10	合计/100	状态
GPT	14	20	14.25	19.75	10	10	88	已完成
Grok	15	19	15.75	17	8.5	9.25	84.5	已完成
DeepSeek	13.25	13.75	17.25	19	5.25	8	76.5	已完成
GLM	12.25	15.25	12.5	18	6.75	9.25	74	已完成
Qwen	10.25	15.25	8.75	18	6.75	8.5	67.5	已完成
Gemini	5.75	6.5	5.75	10.75	4.25	6.5	39.5	已完成
Claude	11.25	15.25	15.75	18.25	6	5.5	72	已完成
Kimi	—	—	—	—	—	—	—	未评分

表 1 第一轮现行 S 六维评分

第1轮 人工维护、成品与自主性				
AI	维护/25	成品/10	自主/10	S/100
GPT	19.75	10	10	88
Grok	17	8.5	9.25	84.5
DeepSeek	19	5.25	8	76.5
GLM	18	6.75	9.25	74
Qwen	18	6.75	8.5	67.5
Gemini	10.75	4.25	6.5	39.5
Claude	18.25	6	5.5	72
Kimi	—	—	—	—

表 2 第一轮人工维护、成品与自主性

第一轮总分：GPT88、Grok84.5、DeepSeek76.5、GLM74、Qwen67.5、Gemini39.5；Claude 接管前工作 72 分。Claude 第二轮未运行，Kimi 两轮无可评分成品，空白不作 0 分。

2.1 第二轮评分

第2轮 现行 S 六维								
AI	数据基础/15	证据计算/20	调查判断/20	人工维护/25	成品可用/10	自主资源/10	合计/100	状态
GPT	15	20	20	23.5	10	10	98.5	已完成
Grok	13	19	19.25	17	7.75	9.25	85.25	已完成
DeepSeek	14	17.5	19.25	20.5	6.75	9.25	87.25	已完成
GLM	13.25	16.25	17.75	17	7.5	9.25	81	已完成
Qwen	14.25	12.75	14.75	19	6.75	7.75	75.25	已完成
Gemini	10.5	10.5	11.25	14.25	6	7	59.5	已完成
Claude	—	—	—	—	—	—	—	未运行
Kimi	—	—	—	—	—	—	—	未评分

表 3 第二轮现行 S 六维评分

第2轮 人工维护、成品与自主性				
AI	维护/25	成品/10	自主/10	S/100
GPT	23.5	10	10	98.5
Grok	17	7.75	9.25	85.25
DeepSeek	20.5	6.75	9.25	87.25
GLM	17	7.5	9.25	81
Qwen	19	6.75	7.75	75.25
Gemini	14.25	6	7	59.5
Claude	—	—	—	—
Kimi	—	—	—	—

表 4 第二轮人工维护、成品与自主性

第二轮总分：GPT98.5、DeepSeek87.25、Grok85.25、GLM81、Qwen75.25、Gemini59.5。项目约定总分≥90、维护≥22/25、成品≥8/10、自主性≥8/10，且原 AI 已检查最终成品、核心结论无已确认而未处理的错误；这次只有 GPT 第二轮全部满足。

回看第二轮增加的工作，许多系统补做了异常追查和对照计算。调查判断平均增加 4.67 分，占总增量约 49.3%；人工维护增加 1.46 分，成品增加 0.54 分，交接说明和终稿仍有未解决的问题。

3 两轮得分与具体依据

箭头前后依次为第一轮和第二轮得分，“20/20”表示得 20 分、该组满分 20 分。D5 等编号表示组别及细项序号，D5 是原 AI 是否检查最终成品。下列分数对应本次逐项复核，采用现行 S v2.2。

GPT 88→98.5 第二轮排除雪冰峰日并固定不同月份、类别和机构的权重，调查判断升至 20/20，人工维护 23.5/25；成品和自主性均满分。

Grok 84.5→85.25。剔除固定前 10 个地块后复查供暖增长，调查得 19.25/20。核查时发现 BBL（税务地块编号）写成了建筑，一处文件存在检查始终通过，接手前还需补维护说明和有效检查。

DeepSeek 76.5→87.25。继续追查地址，并用固定 30 天观察窗比较关闭率。终稿检查仍发现最晚的请求创建时间写错、总览截字，成品得 6.75/10。

GLM 74→81 第二轮增加类型增量与热点调查，调查判断提高 5.25 分；热点定义、更新前置步骤及终稿字段数量仍有问题。

Qwen 67.5→75.25 第二轮调查增加，但关闭时长仍把 11 个月与 9 个月比较；第一轮 Drug Activity（涉毒活动类别）的描述占比也判断错误。第二轮约 60.21 分钟，费用参考约 14.33 元。

Gemini 39.5→59.5。第二轮增加贡献分解。回查结案原句时，arrest（拘捕）关键词命中的多数记录是否定表述，原文据此作出的拘捕解释需要修改；本轮共登记 5 项交后修正。

Claude 第一轮 72 调查与中间结果有价值，原脚本重做 28/30 张中间表一致；高频记录全局剔除和部分因果解释依据不足。后续 Grok 接续工作不倒填。

Kimi 两轮未评分 第一轮提前结束，第二轮重复读同一清单；真实复测 14 个实质动作中 13 个无收益，用时约 2.65 分钟。

4 两轮变化与投入比较

六系统配对 · 现行 S 平均变化				
维度	满分	第一轮	第二轮	增量
数据基础	15	11.75	13.33	1.58
证据计算	20	14.96	16	1.04
调查判断	20	12.38	17.04	4.67
人工维护	25	17.08	18.54	1.46
成品可用	10	6.92	7.46	0.54
自主资源	10	8.58	8.75	0.17

表 5 六系统配对的现行 S 六维平均变化

两轮都有评分的六个系统一一对应后求平均，称为配对均值；从 71.67 升至 81.13，增加 9.46 分。主要改善在调查判断。Gemini 增加 20 分，第二轮为 59.5 分，结案文本的解释仍需修改。

第二轮交付与资源指标					
AI	S/100	分钟	费用参考/元	修正	状态
GPT	98.5	17.78	38.96	0	已完成
Grok	85.25	11.71	9.86	1	已完成
DeepSeek	87.25	21.7	1.37—2.74	1	已完成
GLM	81	9.59	6.48	1	已完成
Qwen	75.25	60.21	14.33	2	已完成
Gemini	59.5	6.07	5.12	5	已完成
Kimi	—	2.65	1.48	0	失败
Claude	—	—	—	—	未运行

表 6 第二轮交付与资源指标

目录价按模型公开单价和用量估算：GPT 第二轮 38.96 元，GLM6.48 元，DeepSeek 按忙时、闲时单价列为 1.37—2.74 元。Grok 的 9.86 元为订阅额度消耗；Gemini 的 5.12 元为 Token 用量按 API 单价折算。Token 是文字处理的计量单位，API 是软件调用模型的接口；这些金额均不直接等于现金扣款。

无收益动作占比（AWR）是确认无收益动作数除以实质动作数，分母包括交付工作、必要探索和无收益动作，不含进度管理。六系统第二轮均无追加指令，交后仍有 10 项修正；Qwen 和 Gemini 的 AWR 为 0，却分别有 2 项和 5 项修正。

具体接手工作包括：Qwen 统一比较月份后重算，Gemini 重读结案文本并修改解释，Grok 与 GLM 补正定义和维护步骤。这些问题在增加调查后仍然存在。

5 评测结论与系统评价

这次两轮尝试中，六系统都有可评分成果，第二轮平均 81.13 分。逐项核查后，GPT 第二轮达到项目 1 参照要求；Claude 第一轮需要 Grok 接续，Kimi 未完成。以下选择仅依据本次任务和运行记录。

GPT：第二轮 S 为 98.5，主要计算和文件检查较完整，未登记交后修正。目录价约 38.96 元；在这次需要完整交付、减少接手工作的任务中，可优先考虑。

Grok：第二轮 S 为 85.25，约 11.71 分钟。供暖等调查可供参考，使用前要补正地块定义和维护检查。订阅额度计价约 9.86 元，与现金扣款口径不同。

DeepSeek：第二轮 S 为 87.25，地址与观察窗口调查较深入，目录价约 1.37—2.74 元。采用结果前需核对终稿时间并修正显示问题。

GLM：第二轮 S 为 81，约 9.59 分钟、6.48 元，比 Qwen 省时省费。若采用，需要先重定热点范围、重算相关结果，并补上维护步骤。

Qwen：第二轮 S 为 75.25，约 60.21 分钟、14.33 元。两轮分别有描述结构和时间窗口错误；就本次个人使用而言，已有结果不支持继续投入重试。

Gemini：第二轮 S 为 59.5，约 6.07 分钟。回查原句后，文本语义和治理解释存在核心错误，相关政策、人口或执法建议暂不宜采用。

Claude：接管前工作得 72 分，留下较多调查和中间表。Claude 阶段订阅额度计价约 153.57 元，含 Grok 接续约 165.69 元；后续仍需处理筛选与解释问题。

Kimi：两轮未得到可用交付，记录中已有时间、费用和人工催促。在本次工具组合下，暂不追加付费重试。

6 模型与运行条件

参评模型、思考强度与 Harness				
AI	第一轮模型	第二轮模型	思考强度	Harness (执行环境)
GPT	gpt-6-astra	gpt-6-astra	中 (medium)	Codex
Grok	grok-4.6	grok-4.6	中 (medium)	Cursor
DeepSeek	deepseek-v4.1-flash	deepseek-v4.1-flash	high	Claude Code
GLM	glm-5.3	glm-5.3	high	Claude Code / Brain Router
Qwen	qwen3.8-max-0902	qwen3.8-max-0902	high	Claude Code
Gemini	gemini-3.8-flash	gemini-3.8-flash	中 (medium)	Antigravity
Claude	Claude Opus 5 → Grok	无独立运行	Claude medium; Grok high-fast	Cursor
Kimi	kimi-k3	kimi-k3	high	Claude Code
运行说明				
思考强度	参赛原运行：海外模型为中，国内模型为Claude Code的high；Grok接续阶段为high-fast。			
执行环境	Harness指模型使用的执行环境；GLM经Brain Router路由。同名强度设置不代表跨平台相同思考预算。			
版本与缺失	Gemini两轮为gemini-3.8-flash；Kimi两轮为kimi-k3；Claude第二轮未运行。			

表 7 模型、思考强度与 Harness

表中 Harness 指调用工具、读写文件的软件环境；medium、high、high-fast 为思考强度设置，同名设置不保证投入相同。Gemini 两轮模型均为 gemini-3.8-flash，Kimi 两轮均为 kimi-k3。具体条件见 Excel“字段说明”，评分依据见“评分与用量”。

Claude 空白项原因 第二轮未运行。第一轮 72 分只评价 Claude 接管前有证据支持的工作，Grok 后续订正和重建分开归属。

Kimi 空白项原因 两轮均无完整成品。第二轮重复读取清单后由评测方终止，时间和费用仍计入使用判断。