

AI 数据分析 Agent 自主交付评测简洁版

NYC311 数据分析任务 2026 年 9 月 21 日

八个系统使用相同任务材料，自主选题并提交 Excel 与分析说明。数据包含 25 个 Parquet 分片、7,525,498 条服务请求和 44 个字段。第一轮使用基础提示，第二轮增加 Evidence-led 方法提示，Grok、Gemini 另有方法清单。

评测面向个人使用，限于两轮。除分析质量外，还比较费用、耗时，以及续跑、接管和修正工作。

1 各系统完成的主要工作

GPT 第一轮分解类别、行政区增长，第二轮进一步核查雪冰峰日和渠道构成。最高 5 天占同期雪冰请求的 59.42%；排除峰日并固定渠道构成后继续比较，最终检查 Excel 公式和图表。

Grok 第一轮按互斥类别分解全市增量，第二轮检查供暖地块集中度、积雪高量日及坑洞。排除固定前 10 个地块后，供暖请求仍增长 21.96%。

DeepSeek 两轮均调查异常地址和关闭时长，第二轮增加邮编集中度、固定 30 天关闭率及数据重建。第一轮固定机构与类型构成后，冬季时长倍数由 3.8667 降至 1.1537。

GLM 第一轮重点追查道路异常，第二轮增加同比增量分解、住宅噪声与热点地址分析，并修正月均值和关闭率的统计月份。

Qwen 第一轮完成类别、地区和时长比较，第二轮增加噪声尖峰、渠道及异常调整分析，多次重建工作簿并核对图表与说明。

Gemini 第一轮分析异常地址、供暖、违停及机构时长，第二轮完善日期与字段检查，扩大部门、类别和处置结果分析，但结案文本解释仍有错误。

Claude 第一轮保存 30 张中间汇总表、生成 13 个工作表，调查地址集中、重复规则与结案描述。Claude 因 Cursor 宿主额度限制切换到 Grok，由 Grok 重建和终检，按混合成品评价。第二轮无独立运行。

Kimi 第一轮多次提前结束，经人工续跑后退出；第二轮反复读取同一清单，评测方终止运行。两轮均未形成完整成品。

2 两轮评分及主要差异

成果质量 Q 与过程可靠性 R 各满分 100 分。Q 包括数据判断、证据计算、调查推进、最终交付、复杂度与范围五个维度；R 包括独立承担、自我纠错、路线控制、完成真实性、协议纪律五项。

第一轮 成果质量 Q							
AI	数据判断 /20	证据计算 /25	调查推进 /30	最终交付 /15	复杂度 /10	合计/100	样本状态
GPT	19	25	24	15	10	93	独立完成
Grok	20	24	26	14	10	94	独立完成
DeepSeek	20	19	28	13	9	89	独立完成
GLM	18	23	21	15	9	86	独立完成
Qwen	17	19	21	14	10	81	独立完成
Gemini	11	10	14	9	5	49	独立完成
Claude	17	16	25	14	9	81	混合成品，仅Q
Kimi							提前结束后退出

表 1 第一轮成果质量

第一轮过程可靠性 R							
AI	独立承担 /25	自我纠错 /25	路线控制 /20	完成真实性 /20	协议纪律 /10	合计/100	样本状态
GPT	25	23	19	20	10	97	独立完成
Grok	25	24	20	20	10	99	独立完成
DeepSeek	25	23	17	17	10	92	独立完成
GLM	25	22	19	18	10	94	独立完成
Qwen	25	18	19	17	10	89	独立完成
Gemini	24	13	12	11	7	67	独立完成
Claude							混合成品，仅Q
Kimi							提前结束后退出

表 2 第一轮过程可靠性

第一轮 Grok 的质量与可靠性均居首，Q 为 94、R 为 99；GPT 分别为 93、97。Gemini 为 49、67，与其余五个独立交付系统差距较大。Claude 的混合成品 Q 为 81，Kimi 未完成交付。

2.1 第二轮评分

第二轮 成果质量 Q							
AI	数据判断 /20	证据计算 /25	调查推进 /30	最终交付 /15	复杂度 /10	合计/100	样本状态
GPT	20	25	30	15	10	100	独立完成
Grok	20	24	30	14	10	98	独立完成
DeepSeek	20	22	30	13	10	95	独立完成
GLM	19	23	28	14	10	94	独立完成
Qwen	19	21	28	14	8	59	分项90；封顶59
Gemini	19	16	23	12	8	78	观察；Gate不通过
Claude							未开展独立运行
Kimi							读取循环后终止

表 3 第二轮成果质量

第二轮过程可靠性 R							
AI	独立承担 /25	自我纠错 /25	路线控制 /20	完成真实性 /20	协议纪律 /10	合计/100	样本状态
GPT	25	24	19	20	10	98	独立完成
Grok	25	25	20	19	10	99	独立完成
DeepSeek	25	23	19	17	10	94	独立完成
GLM	25	23	19	19	10	96	独立完成
Qwen	25	22	20	18	10	95	独立完成
Gemini	24	16	20	13	8	81	观察；Gate不通过
Claude							未开展独立运行
Kimi							读取循环后终止

表 4 第二轮过程可靠性

成果质量 正式五系统的证据计算为 21—25 分，相差 4 分。含 Gemini 观察评分时，证据计算为 16—25 分、调查推进为 23—30 分、最终交付为 12—15 分。GPT 质量 100、Grok98，差异来自证据计算和最终交付。Qwen 分项 90，按主线时间窗错误封顶 59；Gemini78 仅作观察。

过程可靠性 Grok 自我纠错得 25 分，GPT24，DeepSeek 与 GLM23，Qwen22，Gemini16。Gemini 路线控制得满分，但仍有语义与解释错误。Claude 不发布独立 R，Kimi 缺失分数留空。

3 两轮得分与具体依据

下列箭头依次表示第一轮、第二轮。Q 为成果质量，R 为过程可靠性。

GPT Q 93→100 R 97→98 新增雪冰峰日、固定构成和替代解释检查，调查推进增加 6 分。峰日明细与排除对照、固定构成检查支持 C2 和 C4 满分，撤销原来缺少依据的两分扣分。计算与最终交付也为满分。

Grok Q 94→98 R 99→99 质量增加的 4 分全部来自调查推进。地块排除比较和成熟队列支持深入调查；BBL 地块被表述为单栋建筑，解释边界扣 1 分，恒真的文件存在检查使最终核验扣 1 分。R 总分不变，自我纠错升 1 分、完成真实性降 1 分。

DeepSeek Q 89→95 R 92→94 地址与固定观察期检查使调查推进达到 30 分。第二轮将最大创建时间写成 02:22:25，核验值为 01:50:33，自检未发现，最终文件检查仅得 2/4。R 增加来自路线控制改善。

GLM Q 86→94 R 94→96 增量分解和热点调查使调查推进增加 7 分。月均值与关闭率修正提高过程评分，但最终说明仍将 44 个字段写成 43 个，最终交付由 15 分降至 14 分。Closed 子集 547 条负时长已经核实，不作为错误扣分。

Qwen Q 81→59 R 89→95 异常和渠道调查使调查推进增加 7 分，自我纠错增加 4 分。Use Indoor 份额由约 10.69%升至 29.73%，与“结构无实质变化”的表述冲突；关闭时长主要发现使用 11 个月与 9 个月比较，分项合计 90，按冻结规则封顶为 59。较重的重建和核对投入使复杂度与范围减少 2 分。

Gemini 观察评分 Q 49→78 R 67→81 字段检查和贡献分解明显改善，但 arrest 关键词命中率 8.28%包含否定等语境，明确肯定短语仅约 0.013718%。将宽泛命中率解释为拘捕情况导致解释边界仅得 1/5，交付后登记修正 5 项。第二轮越界搜索目录、模型子版本不可核，不进入正式配对汇总。

Claude 第一轮混合成品 Q 81 调查推进得 25 分，证据计算仅 16 分。地址聚集被认定为无效记录、部分因果解释缺证据，前 20 类增量与全量未对齐。Grok 参与最终交付，故不评价 Claude 的独立过程可靠性。

Kimi 未评分 缺少完整成品与足够评分材料。第二轮真实复测 14 个实质动作中 13 个无收益，用时约 2.65 分钟。

4 两轮变化与投入比较

五个配对系统·分项变化与封顶调整										
质量维度			满分	第一轮均分		第二轮均分		平均增量	分项增量占比	
问题与数据判断			20.0	18.8		19.6		0.8	11.8%	
证据与计算			25.0	22.0		23.0		1.0	14.7%	
调查推进			30.0	24.0		29.2		5.2	76.5%	
最终交付			15.0	14.2		14.0		-0.2	-2.9%	
复杂度与范围			10.0	9.6		9.6		0.0	0.0%	
分项合计			100.0	88.6		95.4		6.8	100.0%	
封顶调整				0.0		-6.2		-6.2		
最终Q				88.6		89.2		0.6		

表 5 五个配对系统的分项增量与封顶调整

五系统分项合计平均增加 6.8 分，调查推进贡献 76.5%，最终交付合计减少 1 分。Qwen 封顶调整-31 分后，最终 Q 平均仅增加 0.6 分，中位增加 6 分。Gemini 仅保留观察评分。

AI	Q	R	分钟	API目录价 (元)	AWR	修正	总 Token	运行工具	状态
GPT	100	98	17.8	38.96	6.3%	0	3,244,918	Codex	已完成
Grok	98	99	11.7	—	0.0%	1		Cursor	已完成
DeepSeek	95	94	21.7	1.37—2.74	1.1%	1	8,980,596	Claude Code	已完成
GLM	94	96	9.6	6.48	4.9%	1	2,456,581	Claude Code	已完成
Qwen	59	95	60.2	14.33	0.0%	2	8,288,450	Claude Code	已完成
Gemini	78	81	6.1	—	0.0%	5		Antigravity	观察
Kimi			2.6	1.48	92.9%	0	499,485	Claude Code	失败
Claude				—				未运行	未运行

表 6 第二轮交付与资源指标

GPT 未登记交付后修正，但可估算费用最高，为 38.96 元。GLM 约 9.6 分钟、6.48 元，Q 与 R 均高于 Qwen；DeepSeek 费用最低，为 1.37—2.74 元，仍需重点核对终稿数字。Grok 和 Gemini 缺少 Token 记录，费用不可比较。

六个系统第二轮均能在无追加指令下完成交付，后续仍登记 10 项修正。Qwen 与 Gemini 的无收益动作占比均为 0，仍分别有 2 项和 5 项修正，文件检查未充分覆盖解释错误。

第二轮增加了调查和对照，但 Qwen 的比较月份、Gemini 的文本解释等问题仍留在终稿。

5 评测结论与系统评价

第二轮六个系统交付了 Excel 和分析说明，GPT 未登记交付后修正，其余五个共登记 10 项。

Claude 由 Grok 接管收尾，Kimi 两轮均未形成完整交付。

GPT 适合对成品准确性要求较高的任务。本次复审 Q 为 100 分，计算和终稿检查较完整，交付后未登记修正任务；第二轮估算费用 38.96 元，在费用可估算的四个系统中最高。预算有限时，需要权衡这部分准确性优势与费用。

Grok 调查深入，质量 98 分，低于 GPT 两分。排除固定地块后重新比较增长，能检验原解释是否成立。使用成品前仍需核对地块定义、未来关闭日期和无效检查。缺少费用记录，目前只能比较质量和用时。

DeepSeek 调查较深入，第二轮估算费用最低，为 1.37—2.74 元。地址集中和固定观察期分析较充分，但终稿时间写错，自检也未发现。愿意自行复核关键数字的使用者，可以考虑其费用优势。

GLM 在质量、用时和费用之间表现较均衡。第二轮约 9.6 分钟、6.48 元，质量与过程评分均高于 Qwen。个人同时考虑预算和效率时，GLM 较值得选用；字段数量、热点分母和原因解释仍需检查。

Qwen 第二轮调查与纠错有所改善，但用时约 60.2 分钟、估算费用 14.33 元，关闭时长主线比较错误使质量封顶为 59 分。反复重建和检查文件后，结构解释与比较窗口的问题仍未解决。本次任务中，Qwen 的耗时和估算费用均高于 GLM，未获得相应的质量收益。

Gemini 约 6.1 分钟完成，速度最快，观察质量评分 78 分，交付后登记了 5 项修正。文本误读和缺少证据的原因解释影响主要结论。快速生成文件的优势伴随着较多复核工作，不宜直接采用其分析说明；第二轮未通过 Gate，不列入正式排名。

Claude 主要调查已完成，随后因 Cursor 额度限制中断，由 Grok 收尾。81 分评价的是混合成品。中断源于宿主额度，仍然给个人使用者带来了切换和接管工作；本次结果不足以推荐 Claude 与 Cursor 的这一组合独立完成同类任务。

Kimi 两轮都未交出完整成品。第一轮反复提前结束，需要人工续跑；第二轮重复读取同一清单，未能恢复。在本次两轮预算及 Claude Code 工具组合下，停止追加付费重试，不将其用于需要连续执行并独立交付的任务。

6 模型与运行条件

参评模型、思考强度与 Harness				
AI	第一轮模型	第二轮模型	思考强度	Harness (执行环境)
GPT	gpt-6-astra	gpt-6-astra	中 (medium)	Codex
Grok	grok-4.6	grok-4.6	中 (medium)	Cursor
DeepSeek	deepseek-v4.1-flash	deepseek-v4.1-flash	high	Claude Code
GLM	glm-5.3	glm-5.3	high	Claude Code / Brain Router
Qwen	qwen3.8-max-0902	qwen3.8-max-0902	high	Claude Code
Gemini	gemini-3.8-flash	Gemini (子版本未核实)	中 (medium)	Antigravity
Claude	Claude Opus 5 → Grok	无独立运行	中 (medium)	Cursor
Kimi	Kimi (子版本未核实)	kimi-k3	high	Claude Code
运行说明				
思考强度	海外模型设为中，国内模型设为Claude Code中的high。			
执行环境	Harness指模型使用的执行环境；GLM经Brain Router路由。同名强度设置不代表跨平台相同思考预算。			
版本与缺失	模型版本取自运行记录。Claude第二轮未运行；Gemini第二轮、Kimi第一轮的具体子版本未核实。			

表 7 模型、思考强度与 Harness

海外模型思考强度设为中，国内模型设为 Claude Code 中的 high。

Claude 空白项原因 第一轮因 Cursor 宿主额度限制，由 Claude Opus 5 切换到 Grok 收尾，81 分仅评价混合成品，独立过程 R 留空。第二轮没有可验证的独立运行，因此第二轮分数和两轮变化留空。

Kimi 空白项原因 第一轮反复提前结束，需要人工续跑，随后退出；第二轮陷入重复读取同一清单，评测方确认循环后终止。两轮均无完整成品，无法评定 Q 与 R。