

# AI 数据分析 Agent/自主交付评测简洁版

## NYC311 数据分析任务 两轮自主交付评测

本项目沿用项目 1 的纽约市 311 非紧急市政服务请求（NYC311）数据，交给八个能调用工具执行任务的 AI 系统，文中称为 AI Agent。输入为 25 个 Parquet 格式数据文件、7,525,498 条请求、44 列信息。各系统自主选题，提交 Excel 和说明；第一轮用基础提示，第二轮增加方法提示，Grok 和 Gemini 另有检查清单。

下文先看各系统实际做了什么，再结合文件和计算核查解释评分，最后比较耗时、费用及接手工作。未形成成品的轮次保留状态，分数留空。

## 1 各系统完成的主要工作

**GPT** 第一轮分解类别、行政区增长，第二轮进一步核查雪冰峰日和渠道构成。最高 5 天占同期雪冰请求的 59.42%；排除峰日并固定不同月份、类别和机构的权重后继续比较，最终检查 Excel 公式和图表。

**Grok** 第一轮按互斥类别分解全市增量，第二轮检查供暖请求是否集中在少数地块、积雪高量日及坑洞。排除固定前 10 个地块后，供暖请求仍增长 21.96%。

**DeepSeek** 两轮均调查异常地址和关闭时长，第二轮增加邮编集中度、固定 30 天关闭率及数据重建。第一轮固定机构与类型的权重后，冬季时长倍数由 3.8667 降至 1.1537。

**GLM** 第一轮重点追查道路异常，第二轮增加同比增量分解、住宅噪声与热点地址分析，并修正月均值和关闭率的统计月份。

**Qwen** 第一轮完成类别、地区和时长比较，第二轮增加噪声尖峰、渠道及异常调整分析，但两轮分别留下描述结构和比较月份的核心解释错误。

**Gemini** 第一轮分析异常地址、供暖、违停及机构时长，第二轮完善日期与字段检查，扩大部门、类别和处置结果分析，但结案文本解释仍有错误。

**Claude** 第一轮保存 30 张中间汇总表、生成 13 个工作表，调查地址集中、重复规则与结案描述。Cursor 额度用尽后由 Grok 订正数字并重建终稿；72 分只评价 Claude 阶段可归属的工作。第二轮未运行。

**Kimi** 第一轮多次提前结束，经人工续跑后退出；第二轮反复读取同一清单，评测方终止运行。两轮均未形成完整成品。

## 2 两轮现行 S 评分及主要差异

S 是自主交付总分，满分 100，由 25 个细项相加。A—F 依次为数据与选题 15 分、证据计算 20 分、调查判断 20 分、人工维护 25 分、成品可用性 10 分、自主与资源 10 分。每项按完整满足、主要满足、部分完成、有限可用、未完成或不可用，分别给满分的 100%、75%、50%、25%、0。具体定义和依据见完整稿第 1.2 节及附录。

| 第1轮 现行 S 六维 |         |         |         |         |         |         |        |     |
|-------------|---------|---------|---------|---------|---------|---------|--------|-----|
| AI          | 数据基础/15 | 证据计算/20 | 调查判断/20 | 人工维护/25 | 成品可用/10 | 自主资源/10 | 合计/100 | 状态  |
| GPT         | 14      | 20      | 14.25   | 19.75   | 10      | 10      | 88     | 已完成 |
| Grok        | 15      | 19      | 15.75   | 17      | 8.5     | 9.25    | 84.5   | 已完成 |
| DeepSeek    | 13.25   | 13.75   | 17.25   | 19      | 5.25    | 8       | 76.5   | 已完成 |
| GLM         | 12.25   | 15.25   | 12.5    | 18      | 6.75    | 9.25    | 74     | 已完成 |
| Qwen        | 10.25   | 15.25   | 8.75    | 18      | 6.75    | 8.5     | 67.5   | 已完成 |
| Gemini      | 5.75    | 6.5     | 5.75    | 10.75   | 4.25    | 6.5     | 39.5   | 已完成 |
| Claude      | 11.25   | 15.25   | 15.75   | 18.25   | 6       | 5.5     | 72     | 已完成 |
| Kimi        | —       | —       | —       | —       | —       | —       | —      | 未评分 |

表 1 第一轮现行 S 六维评分

| 第1轮 人工维护、成品与自主性 |       |       |       |       |
|-----------------|-------|-------|-------|-------|
| AI              | 维护/25 | 成品/10 | 自主/10 | S/100 |
| GPT             | 19.75 | 10    | 10    | 88    |
| Grok            | 17    | 8.5   | 9.25  | 84.5  |
| DeepSeek        | 19    | 5.25  | 8     | 76.5  |
| GLM             | 18    | 6.75  | 9.25  | 74    |
| Qwen            | 18    | 6.75  | 8.5   | 67.5  |
| Gemini          | 10.75 | 4.25  | 6.5   | 39.5  |
| Claude          | 18.25 | 6     | 5.5   | 72    |
| Kimi            | —     | —     | —     | —     |

表 2 第一轮人工维护、成品与自主性

第一轮总分：GPT88、Grok84.5、DeepSeek76.5、GLM74、Qwen67.5、Gemini39.5；Claude 接管前工作 72 分。Claude 第二轮未运行，Kimi 两轮无可评分成品，空白不作 0 分。

2.1 第二轮评分

| 第2轮 现行 S 六维 |         |         |         |         |         |         |        |     |
|-------------|---------|---------|---------|---------|---------|---------|--------|-----|
| AI          | 数据基础/15 | 证据计算/20 | 调查判断/20 | 人工维护/25 | 成品可用/10 | 自主资源/10 | 合计/100 | 状态  |
| GPT         | 15      | 20      | 20      | 23.5    | 10      | 10      | 98.5   | 已完成 |
| Grok        | 13      | 19      | 19.25   | 17      | 7.75    | 9.25    | 85.25  | 已完成 |
| DeepSeek    | 14      | 17.5    | 19.25   | 20.5    | 6.75    | 9.25    | 87.25  | 已完成 |
| GLM         | 13.25   | 16.25   | 17.75   | 17      | 7.5     | 9.25    | 81     | 已完成 |
| Qwen        | 14.25   | 12.75   | 14.75   | 19      | 6.75    | 7.75    | 75.25  | 已完成 |
| Gemini      | 10.5    | 10.5    | 11.25   | 14.25   | 6       | 7       | 59.5   | 已完成 |
| Claude      | —       | —       | —       | —       | —       | —       | —      | 未运行 |
| Kimi        | —       | —       | —       | —       | —       | —       | —      | 未评分 |

表 3 第二轮现行 S 六维评分

| 第2轮 人工维护、成品与自主性 |       |       |       |       |
|-----------------|-------|-------|-------|-------|
| AI              | 维护/25 | 成品/10 | 自主/10 | S/100 |
| GPT             | 23.5  | 10    | 10    | 98.5  |
| Grok            | 17    | 7.75  | 9.25  | 85.25 |
| DeepSeek        | 20.5  | 6.75  | 9.25  | 87.25 |
| GLM             | 17    | 7.5   | 9.25  | 81    |
| Qwen            | 19    | 6.75  | 7.75  | 75.25 |
| Gemini          | 14.25 | 6     | 7     | 59.5  |
| Claude          | —     | —     | —     | —     |
| Kimi            | —     | —     | —     | —     |

表 4 第二轮人工维护、成品与自主性

第二轮总分：GPT98.5、DeepSeek87.25、Grok85.25、GLM81、Qwen75.25、Gemini59.5。项目约定总分≥90、维护≥22/25、成品≥8/10、自主性≥8/10，且原 AI 已检查最终成品、核心结论无已确认而未处理的错误；这次只有 GPT 第二轮全部满足。

回看第二轮增加的工作，许多系统补做了异常追查和对照计算。调查判断平均增加 4.67 分，占总增量约 49.3%；人工维护增加 1.46 分，成品增加 0.54 分，交接说明和终稿仍有未解决的问题。

### 3 两轮得分与具体依据

箭头前后依次为第一轮和第二轮得分，“20/20”表示得 20 分、该组满分 20 分。D5 等编号表示组别及细项序号，D5 是原 AI 是否检查最终成品。下列分数对应本次逐项复核，旧版评分另存。

GPT 88→98.5 第二轮排除雪冰峰日并固定不同月份、类别和机构的权重，调查判断升至 20/20，人工维护 23.5/25；成品和自主性均满分。

Grok 84.5→85.25。剔除固定前 10 个地块后复查供暖增长，调查得 19.25/20。核查时发现 BBL（税务地块编号）写成了建筑，一处文件存在检查始终通过，接手前还需补维护说明和有效检查。

DeepSeek 76.5→87.25。继续追查地址，并用固定 30 天观察窗比较关闭率。终稿检查仍发现最晚的请求创建时间写错、总览截字，成品得 6.75/10。

GLM 74→81 第二轮增加类型增量与热点调查，调查判断提高 5.25 分；热点定义、更新前置步骤及终稿字段数量仍有问题。

Qwen 67.5→75.25 第二轮调查增加，但关闭时长仍把 11 个月与 9 个月比较；第一轮 Drug Activity（涉毒活动类别）的描述占比也判断错误。第二轮约 60.21 分钟，费用参考约 14.33 元。

Gemini 39.5→59.5。第二轮增加贡献分解。回查结案原句时，arrest（拘捕）关键词命中的多数记录是否定表述，原文据此作出的拘捕解释需要修改；本轮共登记 5 项交后修正。

Claude 第一轮 72 调查与中间结果有价值，原脚本重做 28/30 张中间表一致；高频记录全局剔除和部分因果解释依据不足。后续 Grok 接续工作不倒填。

Kimi 两轮未评分 第一轮提前结束，第二轮重复读同一清单；真实复测 14 个实质动作中 13 个无收益，用时约 2.65 分钟。

4 两轮变化与投入比较

| 六系统配对 · 现行 S 平均变化 |    |       |       |      |
|-------------------|----|-------|-------|------|
| 维度                | 满分 | 第一轮   | 第二轮   | 增量   |
| 数据基础              | 15 | 11.75 | 13.33 | 1.58 |
| 证据计算              | 20 | 14.96 | 16    | 1.04 |
| 调查判断              | 20 | 12.38 | 17.04 | 4.67 |
| 人工维护              | 25 | 17.08 | 18.54 | 1.46 |
| 成品可用              | 10 | 6.92  | 7.46  | 0.54 |
| 自主资源              | 10 | 8.58  | 8.75  | 0.17 |

表 5 六系统配对的现行 S 六维平均变化

两轮都有评分的六个系统一一对应后求平均，称为配对均值；从 71.67 升至 81.13，增加 9.46 分。主要改善在调查判断。Gemini 增加 20 分，第二轮为 59.5 分，结案文本的解释仍需修改。

| 第二轮交付与资源指标 |       |       |           |    |     |
|------------|-------|-------|-----------|----|-----|
| AI         | S/100 | 分钟    | 费用参考/元    | 修正 | 状态  |
| GPT        | 98.5  | 17.78 | 38.96     | 0  | 已完成 |
| Grok       | 85.25 | 11.71 | 9.86      | 1  | 已完成 |
| DeepSeek   | 87.25 | 21.7  | 1.37-2.74 | 1  | 已完成 |
| GLM        | 81    | 9.59  | 6.48      | 1  | 已完成 |
| Qwen       | 75.25 | 60.21 | 14.33     | 2  | 已完成 |
| Gemini     | 59.5  | 6.07  | 5.12      | 5  | 已完成 |
| Kimi       | —     | 2.65  | 1.48      | 0  | 失败  |
| Claude     | —     | —     | —         | —  | 未运行 |

表 6 第二轮交付与资源指标

目录价按模型公开单价和用量估算：GPT 第二轮 38.96 元，GLM6.48 元，DeepSeek 按忙时、闲时单价列为 1.37—2.74 元。Grok 的 9.86 元为订阅额度消耗；Gemini 的 5.12 元为 Token 用量按 API 单价折算。Token 是文字处理的计量单位，API 是软件调用模型的接口；这些金额均不直接等于现金扣款。

无收益动作占比（AWR）是确认无收益动作数除以实质动作数，分母包括交付工作、必要探索和无收益动作，不含进度管理。六系统第二轮均无追加指令，交后仍有 10 项修正；Qwen 和 Gemini 的 AWR 为 0，却分别有 2 项和 5 项修正。

具体接手工作包括：Qwen 统一比较月份后重算，Gemini 重读结案文本并修改解释，Grok 与 GLM 补正定义和维护步骤。这些问题在增加调查后仍然存在。

## 5 评测结论与系统评价

这次两轮尝试中，六系统都有可评分成果，第二轮平均 81.13 分。逐项核查后，GPT 第二轮达到项目 1 参照要求；Claude 第一轮需要 Grok 接续，Kimi 未完成。以下选择仅依据本次任务和运行记录。

**GPT：**第二轮 S 为 98.5，主要计算和文件检查较完整，未登记交后修正。目录价约 38.96 元；在这次需要完整交付、减少接手工作的任务中，可优先考虑。

**Grok：**第二轮 S 为 85.25，约 11.71 分钟。供暖等调查可供参考，使用前要补正地块定义和维护检查。订阅额度计价约 9.86 元，与现金扣款口径不同。

**DeepSeek：**第二轮 S 为 87.25，地址与观察窗口调查较深入，目录价约 1.37—2.74 元。采用结果前需核对终稿时间并修正显示问题。

**GLM：**第二轮 S 为 81，约 9.59 分钟、6.48 元，比 Qwen 省时省费。若采用，需要先重定热点范围、重算相关结果，并补上维护步骤。

**Qwen：**第二轮 S 为 75.25，约 60.21 分钟、14.33 元。两轮分别有描述结构和时间窗口错误；就本次个人使用而言，已有结果不支持继续投入重试。

**Gemini：**第二轮 S 为 59.5，约 6.07 分钟。回查原句后，文本语义和治理解释存在核心错误，相关政策、人口或执法建议暂不宜采用。

**Claude：**接管前工作得 72 分，留下较多调查和中间表。Claude 阶段订阅额度计价约 153.57 元，含 Grok 接续约 165.69 元；后续仍需处理筛选与解释问题。

**Kimi：**两轮未得到可用交付，记录中已有时间、费用和人工催促。在本次工具组合下，暂不追加付费重试。

6 模型与运行条件

| 参评模型、思考强度与 Harness |                                                          |                     |                                  |                            |
|--------------------|----------------------------------------------------------|---------------------|----------------------------------|----------------------------|
| AI                 | 第一轮模型                                                    | 第二轮模型               | 思考强度                             | Harness (执行环境)             |
| GPT                | gpt-6-astra                                              | gpt-6-astra         | 中 (medium)                       | Codex                      |
| Grok               | grok-4.6                                                 | grok-4.6            | 中 (medium)                       | Cursor                     |
| DeepSeek           | deepseek-v4.1-flash                                      | deepseek-v4.1-flash | high                             | Claude Code                |
| GLM                | glm-5.3                                                  | glm-5.3             | high                             | Claude Code / Brain Router |
| Qwen               | qwen3.8-max-0902                                         | qwen3.8-max-0902    | high                             | Claude Code                |
| Gemini             | gemini-3.8-flash                                         | gemini-3.8-flash    | 中 (medium)                       | Antigravity                |
| Claude             | Claude Opus 5 → Grok                                     | 无独立运行               | Claude medium;<br>Grok high-fast | Cursor                     |
| Kimi               | kimi-k3                                                  | kimi-k3             | high                             | Claude Code                |
| 运行说明               |                                                          |                     |                                  |                            |
| 思考强度               | 参赛原运行：海外模型为中，国内模型为Claude Code的high；Grok接续阶段为high-fast。   |                     |                                  |                            |
| 执行环境               | Harness指模型使用的执行环境；GLM经Brain Router路由。同名强度设置不代表跨平台相同思考预算。 |                     |                                  |                            |
| 版本与缺失              | Gemini两轮为gemini-3.8-flash；Kimi两轮为kimi-k3；Claude第二轮未运行。   |                     |                                  |                            |

表 7 模型、思考强度与 Harness

表中 Harness 指调用工具、读写文件的软件环境；medium、high、high-fast 为思考强度设置，同名设置不保证投入相同。Gemini 两轮模型均为 gemini-3.8-flash，Kimi 两轮均为 kimi-k3。具体条件见 Excel“字段说明”，评分依据见“评分与用量”。

Claude 空白项原因 第二轮未运行。第一轮 72 分只评价 Claude 接管前有证据支持的工作，Grok 后续订正和重建分开归属。

Kimi 空白项原因 两轮均无完整成品。第二轮重复读取清单后由评测方终止，时间和费用仍计入使用判断。